



Présentation PFA: Détection de pneumonie sur radiographie

Conception, Modélisation et Développement.

HANFAOUI Karim¹ KAFIF. Imane²

¹EMSI, 4ème Année IADO G2 -
Karim.Hanfaoui@emsi-edu.ma

²EMSI, 4ème Année IADO G2 -
Imane.Kafif@emsi-edu.ma

EMSI Les Orangers, Mars 2026

Table des Matières

Role : Présenter la structure complète du rapport et l'ordre des étapes

Etape du projet : Navigation / cadrage global

- 1 Acronymes et terminologie
 - Glossaire initial
- 2 Problématique et Méthodologie
 - Entrepreneuriat et valorisation
- 3 Analyse SOTA
 - Phase 1 — DenseNet / CheXNet
 - Phase 2 — Optimisation et efficacité
 - Phase 3 — Vision Transformers et contexte global
 - Phase 4 — Confiance et explicabilité
- 4 Solution proposée
 - Architecture et conception
 - Pipeline détaillé
 - Implémentation et Outils techniques
- 5 Résultats et Finalisation

Table des figures

Rôle : Référencer automatiquement toutes les figures du document **Etape du projet :** Navigation / repérage documentaire

Figure 1. Réseau PERT de MedFusionNet avec liaisons temporelles annotées et chemin critique mis en évidence.	19
Figure 2. Vue d'ensemble du pipeline complet	40
Figure 3. Échantillon brut provenant du dataset	41
Figure 4. Image après normalisation et redimensionnement	42
Figure 5. Représentation locale extraite par la branche CNN	43
Figure 6. Représentation globale extraite par la branche Swin	44
Figure 7. Fusion adaptative entre la branche locale et la branche globale	45
Figure 8. Passage de la représentation fusionnée au score de classe	46
Figure 9. Heatmap explicative et estimation d'incertitude	47
Figure 10. Schéma de la perte totale et de ses composantes	48
Figure 11. Sortie finale utilisable par le clinicien	49
Figure 12. Répartition et flux des données d'imagerie	50
Figure 13. Pile Technologique du système MedFusionNet	51
Figure 14. Arborescence du répertoire de travail (Git)	52

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit

Etape du projet : Navigation / structuration

- 1 Acronymes et terminologie
 - Glossaire initial
- 2 Problématique et Méthodologie
 - Entrepreneuriat et valorisation
- 3 Analyse SOTA
 - Phase 1 — DenseNet / CheXNet
 - Phase 2 — Optimisation et efficacité
 - Phase 3 — Vision Transformers et contexte global
 - Phase 4 — Confiance et explicabilité
- 4 Solution proposée
 - Architecture et conception
 - Pipeline détaillé
 - Implémentation et Outils techniques
- 5 Résultats et Finalisation

Acronymes — Domaine et modèles

Role : Donner les sigles du domaine avant les slides techniques

Etape du projet : Référence documentaire

Domaine médical et IA

IA : Intelligence Artificielle.

DL : Deep Learning, famille de modèles à plusieurs couches.

CXR : Chest X-Ray, radiographie thoracique.

SOTA : State Of The Art, meilleur niveau connu au moment de l'étude.

Modèles et approches

CNN : Convolutional Neural Network, réseau fondé sur les convolutions.

ViT : Vision Transformer, adaptation du Transformer aux images.

Swin : Shifted Window Transformer, Transformer hiérarchique à fenêtres décalées.

Grad-CAM : Gradient-weighted Class Activation Mapping, outil d'explicabilité visuelle.

Acronymes — Blocs techniques

Role : Définir les sigles techniques utilisés dans les architectures et l'évaluation **Etape du projet** : Référence documentaire

Architecture

BN : Batch Normalization, normalisation des activations sur un mini-batch.

ReLU : Rectified Linear Unit, activation $f(x) = \max(0, x)$.

GAP : Global Average Pooling, moyenne spatiale par canal.

FC : Fully Connected, couche dense finale de décision.

Efficacité et confiance

MBConv : Mobile Inverted Bottleneck Convolution, bloc compact d'EfficientNet.

SE : Squeeze-and-Excitation, mécanisme de ré-pondération des canaux.

FLOPs : Floating Point Operations, estimation du coût de calcul.

ECE : Expected Calibration Error, mesure de calibration des probabilités.

Notations mathématiques

Rôle : Définir les notations qui reviennent dans les équations et les schémas **Etape du projet :** Référence documentaire

Tailles et dimensions

H, W : Hauteur et largeur spatiales d'une image ou d'une carte de features.

C : Nombre de canaux.

L : Nombre de couches ou de blocs, selon le contexte.

k : Growth rate DenseNet, nombre de nouveaux canaux ajoutés par couche.

Variables de modélisation

ϕ : Facteur global de scaling dans EfficientNet.

X : Image d'entrée.

F : Tensor de features appris par le modèle.

$p(y|X)$: Probabilité prédite pour une classe y conditionnée par l'image X .

Terminologie d'architecture

Role : Définir les termes techniques utilisés sans alourdir les slides principales **Etape du projet** : Référence documentaire

CNN et représentations

Feature map : Carte d'activation produite par un bloc du réseau.

Backbone : Extracteur principal de représentations d'une architecture.

Bottleneck : Réduction intermédiaire des canaux pour baisser le coût.

Skip connection : Chemin de contournement transmettant une information plus tôt dans le réseau.

Transformers et fiabilité

Token : Unité d'entrée d'un Transformer, ici un patch projeté.

Embedding : Représentation vectorielle dense d'un objet discret ou local.

Calibration : Adéquation entre probabilité annoncée et fréquence réelle de succès.

Heatmap : Carte colorée montrant des zones activées ou importantes pour la décision.

Guide de lecture du document

Rôle : Préciser le rôle exact de chaque groupe de slides dans la fabrication du projet **Etape du projet** : Lecture guidée du rapport

Cadrage

Problématique / Méthodologie :

Définir le besoin clinique, la question scientifique et l'organisation du travail.

Analyse SOTA : Comparer les approches existantes avant de choisir une direction.

Conception

Solution proposée : Définir l'architecture cible, sa logique et ses sorties.

Validation

Résultats : Mesurer la performance finale et lire les indicateurs.

Annexes : Documenter les notions techniques non développées dans le flux principal.

Principe de lecture

Chaque slide technique indique explicitement :

- son **role** dans le document,
- l'**etape du projet** à laquelle il appartient.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit

Etape du projet : Navigation / structuration

- 1 Acronymes et terminologie
 - Glossaire initial
- 2 Problématique et Méthodologie
 - Entrepreneuriat et valorisation
- 3 Analyse SOTA
 - Phase 1 — DenseNet / CheXNet
 - Phase 2 — Optimisation et efficacité
 - Phase 3 — Vision Transformers et contexte global
 - Phase 4 — Confiance et explicabilité
- 4 Solution proposée
 - Architecture et conception
 - Pipeline détaillé
 - Implémentation et Outils techniques
- 5 Résultats et Finalisation

Role : Poser le besoin clinique, la question de recherche et la contrainte d'explicabilité scientifique

Etape du projet : Cadrage


Question Centrale de Recherche

Face à la complexité visuelle des pathologies pulmonaires et à la pénurie mondiale de radiologues experts, comment pouvons-nous concevoir un système automatisé basé sur le Deep Learning capable non seulement de détecter la pneumonie avec une précision clinique supérieure à l'interprétation humaine, mais aussi de fournir une justification visuelle explicable afin de garantir une intégration sécurisée et fiable dans le flux de travail médical d'urgence ?

Méthodologie : Approche Agile (Scrum)

Role : Montrer comment le projet est découpé en phases de travail et d'itération
planification

Etape du projet : Organisation /



- **Flexibilité :** Adaptation aux contraintes des données médicales.
- **Itérations :** Optimisation progressive des hyperparamètres.

Gestion de Projet — Tableau des Tâches (PFA)

Role : Détailler les tâches, leur charge et le type exact de liaison temporelle **Etape du projet :** Organisation / planification

Le tableau ci-dessous affine la planification en ajoutant les décalages et les relations PERT.

ID	Nom de la Tâche	Durée	Antécédent(s) + liaison
A	Cadrage et problématique clinique	3 j	—
B	Analyse SOTA CNN (DenseNet / CheXNet)	4 j	A (0FD)
C	Analyse SOTA Swin Transformer / ViT	4 j	A (0FD)
D	Étude d'explicabilité XAI et lecture Grad-CAM	2 j	B (1DD), C (0FF)
E	Prétraitement $T(X)$, resize et normalisation	5 j	A (0FD)
F	Développement de la branche locale CNN	6 j	B (0FD), E (0FD)
G	Développement de la branche globale Swin	7 j	C (0FD), E (0FD)
H	Intégration du module de gated fusion	5 j	F (0FD), G (0FD)
I	Sortie clinique Ψ : score + incertitude	4 j	H (0FD)
J	Configuration GPU / Colab / environnement	2 j	A (1DD)
K	Entraînement, calibration et optimisation	10 j	I (0FD), J (0FD)
L	Évaluation finale, benchmark et métriques	3 j	K (0FD)
M	Finalisation rapport, slides et démonstration	5 j	L (0FD), D (0FD)

Lecture de la notation

Exemple : 0FD signifie *Fin-Début sans décalage*, 1DD signifie *Début-Début avec 1 jour de décalage*. La notation générale est : [décalage] + [type de liaison].

Gestion de Projet — Typologie des Dépendances PERT

Role : Préciser les quatre types de relations temporelles utilisés dans un ordonnancement PERT
Organisation / planification

Etape du projet :

FD — Fin à Début

La tâche successeur démarre après la fin de la tâche précédente.

Exemple projet : $A \rightarrow B = 0FD$.

FF — Fin à Fin

La fin de la tâche successeur est contrainte par la fin d'une autre tâche.

Exemple projet : $C \rightarrow D = 0FF$.

DD — Début à Début

La tâche successeur peut commencer après le début du précédent, avec un éventuel décalage.

Exemple projet : $A \rightarrow J = 1DD$.

DF — Début à Fin

Relation plus rare : la fin d'une tâche dépend du début d'une autre.

Exemple de notation : 2DF. Elle est documentée dans la méthode, mais non structurante ici.

Lecture managériale

Dans MedFusionNet, la planification repose surtout sur des relations **FD** pour sécuriser les jalons de validation, avec des liaisons **DD** et **FF** pour modéliser les travaux menés en parallèle sans perdre la cohérence globale.

Méthodologie — Analyse du Réseau de PERT

Role : Interpréter les dates, les marges et les zones critiques du planning **Etape du projet :** Organisation / planification

Principes de lecture

- Le réseau PERT calcule des dates au plus tôt et au plus tard pour chaque activité.
- L'écart entre ces deux positions donne la flexibilité réelle de la tâche.
- Une activité sans marge devient immédiatement sensible à tout retard.
- Les relations **FD**, **DD** et **FF** modifient directement les dates admissibles.

Lecture des dépendances

- **B** et **C** sont lancées en parallèle après **A**.
- **J** démarre en **1DD** pour préparer l'infrastructure sans attendre la fin complète du cadrage.
- **D** démarre tôt, mais se ferme en même temps que **C** via la contrainte **OFF**.

Méthodologie — Lecture du Chemin Critique

Role : Mettre en avant les tâches à marge nulle et les points de pilotage du projet
planification

Etape du projet : Organisation /

Interprétation projet

- **H** concentre la convergence des deux branches **F** et **G**.
- **K** attend simultanément la sortie clinique **I** et l'environnement **J**.
- **D** et **J** restent importantes, mais elles ne pilotent pas la date finale.

Lecture managériale

- Les nœuds critiques pilotent directement la livraison finale.
- Les tâches quasi critiques, comme **C** et **F**, doivent rester sous surveillance.
- Les activités très flexibles, comme **D** et **J**, absorbent les aléas sans casser le planning.

Conséquence managériale

Priorité de pilotage : toute dérive sur une tâche à marge nulle décale immédiatement la démonstration finale.

Chemin critique

A → E → G → H → I → K → L → M

Durée totale estimée : 42 jours

Gestion de Projet — Interprétation Opérationnelle

Role : Transformer le planning théorique en lecture de pilotage concrète pour le projet **Etape du projet** : Organisation / planification

Hypothèses de conduite

- Le cadrage **A** alimente rapidement l'état de l'art et le prétraitement pour éviter un démarrage séquentiel trop long.
- Les branches **F** et **G** sont parallélisées afin de réduire la durée totale avant l'étape de fusion.
- L'environnement **J** démarre tôt et l'entraînement **K** reste le lot le plus long, car il concentre essais, calibration et choix du meilleur checkpoint.

Lecture de risque

- Le verrou principal est la séquence **E-G-H-I-K**, car elle relie directement données, architecture et validation du modèle.
- Un retard sur **D** ou **J** reste absorbable grâce aux marges, alors qu'un retard sur **H** ou **K** décale toute la démonstration.
- Les tâches à faible marge, comme **C** et **F**, restent à surveiller, tandis que **L** et **M** sécurisent la transformation du travail technique en livrables académiques.

Message clé

Le planning montre que la réussite du PFA dépend moins du nombre de tâches que de la bonne maîtrise des quelques étapes critiques qui structurent tout le projet.

Gestion de Projet — Tableau des Marges

Role : Quantifier la flexibilité de chaque tâche à travers la marge libre et la marge totale **Etape du projet :** Organisation / planification

ID	A	B	C	D	E	F	G	H	I	J	K	L	M
ML	0	1	0	30	0	1	0	0	0	21	0	0	0
MT	0	2	1	30	0	1	0	0	0	21	0	0	0

ML = marge libre ; **MT** = marge totale. Les tâches critiques vérifient **ML = MT = 0**, tandis que **D** et **J** concentrent l'essentiel de la souplesse du planning.

Méthodologie — Schéma du Réseau de PERT

Role : Visualiser le réseau PERT avec les décalages, les convergences et le chemin critique
Organisation / planification

Etape du projet :





Figure 1: Réseau PERT de MedFusionNet avec liaisons temporelles annotées et chemin critique mis en évidence.

Gestion de Projet — Diagramme de Gantt

Rôle : Projeter le planning sur un calendrier opérationnel tout en respectant les liaisons DD, FD et FF **Etape du projet :** Organisation / planification



Entrepreneuriat — Vision de valorisation

Role : Introduire simplement comment une idee technique peut devenir un projet entrepreneurial
Ouverture business / entrepreneuriat

Etape du projet :

Le point de depart

- Les hopitaux et centres d'imagerie doivent traiter beaucoup d'examens en peu de temps.
- Une radiographie thoracique peut etre difficile a interpreter rapidement.
- Un outil d'aide peut donc avoir une vraie utilite pratique.

Notre idee

- signaler les cas suspects,
- aider a prioriser les urgences,
- montrer une explication visuelle.

Ce que l'on vend

- une aide au triage,
- une aide a la lecture,
- un service utile pour les structures medicales.

Idee cle

On ne vend pas un “medecin automatique”, mais une **solution d'assistance** qui aide les professionnels a travailler plus vite et plus sereinement.

Entrepreneuriat — A qui vendre le projet ?

Role : Identifier les clients potentiels avec un vocabulaire simple **Etape du projet** : Etude de marche / premiers concepts

Clients potentiels

- hopitaux publics et privés,
- cliniques,
- centres de radiologie,
- plateformes de teleradiologie.

Leur besoin

- gagner du temps,
- mieux organiser les priorites,
- reduire le risque d'oubli,
- utiliser un outil simple.

Comment presenter le projet ?

Comme une **aide au triage**, une **seconde lecture** et un **outil explicable** pour la radiographie thoracique.

Positionnement

Le projet se vend en **B2B** : a des etablissements de sante, et non directement au grand public.

Entrepreneuriat — Comment vendre concrètement le projet ?

Role : Montrer simplement les etapes commerciales possibles **Etape du projet :** Demarche commerciale / entrepreneuriat debutant

Etapes simples

- 1 **Presenter le probleme** du client
- 2 **Montrer une demonstration** du systeme
- 3 **Proposer un petit pilote**
- 4 **Recueillir les retours**
- 5 **Transformer le test en offre**



A retenir

Pour un premier cours d'entrepreneuriat, il suffit deja de montrer **qui peut acheter, comment tester et comment vendre.**

Entrepreneuriat — Budget simple et modalités de vente

Rôle : Donner une vision accessible du budget et des revenus possibles
modele simple

Etape du projet : Faisabilité économique /

Poste	Estimation
Hebergement / cloud / GPU	30 000 MAD
Developpement / amelioration	50 000 MAD
Tests / pilote / documentation	25 000 MAD
Communication / déplacement	20 000 MAD
Total simplifié	125 000 MAD

Modes de vente

- pilote payant,
- abonnement mensuel,
- licence annuelle.

Exemple simple

- Pilote : 10 000 a 20 000 MAD
- Abonnement : 3 000 a 6 000 MAD / mois

Lecture entrepreneuriale

Pour notre niveau, l'essentiel est de montrer qu'il existe un **marché possible**, un **mode de vente simple** et un **budget de départ raisonnable**.

Table des Matières

Rôle : Repérer la section courante et le type de contenu qui suit

Etape du projet : Navigation / structuration

- 1 Acronymes et terminologie
 - Glossaire initial
- 2 Problématique et Méthodologie
 - Entrepreneuriat et valorisation
- 3 Analyse SOTA
 - Phase 1 — DenseNet / CheXNet
 - Phase 2 — Optimisation et efficacité
 - Phase 3 — Vision Transformers et contexte global
 - Phase 4 — Confiance et explicabilité
- 4 Solution proposée
 - Architecture et conception
 - Pipeline détaillé
 - Implémentation et Outils techniques
- 5 Résultats et Finalisation

SOTA : Architecture DenseNet-121

Role : Présenter le modèle CNN de référence utilisé comme base de comparaison

Etape du projet : Analyse SOTA /

Dense Block
Chaque couche reçoit les sorties
des couches précédentes
(concaténation)



Dense Block : $x_\ell = H_\ell([x_0, x_1, \dots, x_{\ell-1}])$

Transition
Compression des canaux
par conv 1×1
+ réduction spatiale par AvgPool

Dense Block

Concaténation de toutes les cartes précédentes :

$$x_\ell = H_\ell([x_0, x_1, \dots, x_{\ell-1}])$$

Réutilisation des features + meilleur flux de gradient.

Croissance des canaux : $C_{out} = C_0 + L \cdot k$.

Exemple : $k = 32, L = 6 \Rightarrow C_{out} = C_0 + 192$.

Où C_0 = canaux initiaux, L = nb de couches, k = growth rate.

Transition

Entre blocs denses, compresse et réduit.

$$X \in \mathbb{R}^{H \times W \times C}$$

$$\rightarrow \text{Conv}_{1 \times 1}(X) = Y \in \mathbb{R}^{H \times W \times C'}$$

$$Y_{h,w,c'} = \sum_c W_{c',c} X_{h,w,c} + b_{c'}$$

$$\rightarrow \text{AvgPool}(Y) = Z \in \mathbb{R}^{H/2 \times W/2 \times C'}$$

$$Z_{i,j,c'} = \frac{1}{4} \sum_{u,v \in \{0,1\}} Y_{2i+u, 2j+v, c'}$$

Compression, efficacité, préparation du bloc suivant.

Où H, W = hauteur/largeur, C = canaux, C' = canaux compressés.

Stem / Entrée

Entrée $224 \times 224 \times 3$.

Conv 7×7 ($s = 2$) puis MaxPool 3×3 ($s = 2$).

Extrait des bords/textures et réduit tôt la résolution.

Exemple : $224 \times 224 \rightarrow 112 \times 112 \rightarrow 56 \times 56$.

Où H, W = dimensions spatiales, s = stride.

Tête de classification

Global Avg Pooling : moyenne spatiale par canal.

$$7 \times 7 \times 1024 \rightarrow 1 \times 1 \times 1024.$$


$$g_c = \frac{1}{HW} \sum_{h,w} F_{h,w,c}, \text{ puis FC.}$$

$$\text{Exemple : } g \in \mathbb{R}^{1024} \rightarrow \text{scores} \in \mathbb{R}^K.$$

Où F = carte de features, g = vecteur global, K = nb de classes.

DenseNet-121 : Structure d'une couche dense

Role : Expliquer le calcul interne d'une couche dense pour comprendre le baseline choisi **Etape du projet :** Analyse SOTA / compréhension mécanistique



Séquence : $\text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv } 1 \times 1$
 $\rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv } 3 \times 3$

Transformation H_ℓ

H_ℓ est la transformation appliquée par la couche ℓ dans un bloc dense ; elle produit de **nouvelles** cartes de features.

Formule :

$$H_\ell(x) = \text{Conv}_{3 \times 3} \left(\text{ReLU}(\text{BN}(\text{Conv}_{1 \times 1}(\text{ReLU}(\text{BN}(x)))))) \right)$$

Si $x = [x_0, x_1, \dots, x_{\ell-1}]$, alors $x_\ell = H_\ell(x)$.

Interprétation : 1×1 = mélange/réduction des canaux (bottleneck),

3×3 = extraction spatiale locale, BN+ReLU = stabilité + non-linéarité.

Croissance : la couche ajoute k canaux :

$$C_{\text{out}} = C_{\text{in}} + k.$$


Après L couches : $C_{\text{out}} = C_0 + Lk.$

Où C_{in} = canaux d'entrée, C_0 = canaux initiaux, k = growth rate.

Phase 2 — EfficientNet : idée générale et scaling

Rôle : Comparer une stratégie d'optimisation du coût de calcul par scaling équilibré

Etape du projet : Analyse SOTA / comparaison



Idée centrale

EfficientNet est une famille de CNN conçue pour **mieux exploiter** un budget de calcul donné.

Le **scaling naïf** (uniquement profondeur, largeur ou résolution) crée un déséquilibre :
trop profond $\Rightarrow$ gradient fragile,
trop large $\Rightarrow$ surcoût mémoire,
trop haute résolution $\Rightarrow$ coût quadratique.

Compound Scaling


On augmente **ensemble** profondeur, largeur et résolution par un facteur global ϕ pour rester efficace.

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi, \\ \alpha \beta^2 \gamma^2 \approx 2$$

ϕ contrôle l'échelle globale ; la contrainte équilibre coût et performance.

Phase 2 — MBConv : bloc clé d'EfficientNet

Rôle : Détailler le bloc opératoire central qui rend EfficientNet efficace **Etape du projet :** Analyse SOTA / modélisation d'un bloc



Depthwise Convolution

Chaque canal est filtré séparément :

$$Y_{h,w,c} = \sum_{i,j} K_{i,j}^{(c)} X_{h+i,w+j,c}$$

Coût paramétrique : $k^2 C$

au lieu de $k^2 CC'$ (conv standard).

Réduit fortement les paramètres et FLOPs.

MBConv en pratique

1) Expansion

$$C_e = t \cdot C_{in},$$

2) Depthwise 3×3 ,

3) SE (ré-pondération canal),

4) Projection vers C_{out} ,

5) Skip si stride $s = 1$

et dimensions

compatibles.

Objectif :

expressivité élevée

avec coût réduit.

Phase 2 — EfficientNetV2 et impact médical

Role : Montrer l'évolution d'EfficientNet vers une version plus rapide à entraîner et à déployer **Etape du projet :** Analyse SOTA / comparaison

EfficientNetV2 : améliorations

Optimise l'entraînement (plus rapide et stable) via :


- **Fused-MBConv** sur les petits étages (meilleur débit GPU),
- règles de scaling adaptées,
- stratégies de régularisation plus efficaces.

Résultat : **meilleure précision** à coût d'entraînement réduit.

Intérêt en imagerie médicale

Meilleur compromis précision/temps :

- utile pour stations avec GPU limités,
- facilite l'expérimentation rapide,
- déploiement clinique plus réaliste.



Phase 2 — EfficientNet : ce que fait le modèle

Role : Relier le mécanisme d'EfficientNet aux besoins pratiques de la détection sur CXR **Etape du projet :** Analyse SOTA / pertinence applicative

Mécanisme effectif

Le réseau apprend une fonction f_θ qui transforme X en **cartes hiérarchiques** (bords, textures, motifs complexes).

Les blocs MBConv alternent **mixage de canaux** (1×1), **filtrage spatial local** (depthwise) et **ré-pondération** (SE).

Après agrégation globale :

$$z = \text{GAP}(F_L(X)), \quad p(y|X) = \sigma(w^\top z)$$

Le scaling compound règle **profondeur/largeur/résolution** pour préserver détail et contexte.

Aide en imagerie médicale

Capte des patterns **multi-échelles** (opacités diffuses, consolidations).
Bon compromis précision/coût $\Rightarrow$ utile en contexte GPU limité.
Permet d'exploiter des images haute résolution sans explosion de paramètres.

Limites et risques



Downsampling peut effacer des signes **très fins**.
Sensibilité aux biais (texte, position, appareil, contraste).
Pas de localisation directe : nécessite un outil d'explicabilité.

Phase 3 — ViT : patches et tokens

Role : Introduire la représentation en patches qui remplace la grille convolutive classique
SOTA / comparaison

Etape du projet : Analyse

Image $\rightarrow$ patches



Tokenisation d'image

Image $X \in \mathbb{R}^{H \times W \times C}$ découpée en patches $P \times P$.

Nombre de tokens : $N = \frac{HW}{P^2}$.

Chaque patch est aplati et projeté :

$$z_i = E x_i + e_i^{\text{pos}}, \quad z_i \in \mathbb{R}^D.$$

On traite ensuite $(z_1, \dots, z_N)$ comme une **séquence**.

Intuition : les patches jouent le rôle de “mots” visuels ; l'attention relie des régions éloignées.

Phase 3 — Auto-attention : mécanisme et coût

Role : Expliquer le calcul d'attention, son intérêt et son coût computationnel modélisation

Etape du projet : Analyse SOTA /

Auto-attention

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$


$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Q : requêtes, K : clés, V : valeurs.

Chaque token "regarde" tous les autres (**contexte global**).

Limite de ViT

Complexité quadratique : $O(N^2)$ avec N tokens.
Pour grandes images médicales, N devient très élevé $\Rightarrow$ coût prohibitif.




Phase 3 — Swin Transformer : fenêtres et décalage


Role : Montrer comment Swin conserve le contexte global tout en réduisant la complexité
SOTA / comparaison

Etape du projet : Analyse


Global (ViT)



Fenêtres (Swin)



Fenêtres décalées



Attention par fenêtres

Swin limite l'attention à des fenêtres $M \times M$:

complexité

$$O\left(\frac{HW}{M^2} \cdot M^4\right) = O(HW M^2),$$

au lieu de $O(N^2)$ global.

Le **décalage** des fenêtres connecte les régions voisines.

Intérêt médical

Capte des relations à longue distance tout en restant scalable.

Meilleure adaptation aux images haute résolution (radiographies).

Permet de relier des patterns subtils répartis dans l'image.

Phase 3 — ViT/Swin : ce que fait le modèle

Role : Relier Transformers et radiographie thoracique en termes de bénéfices et de limites
SOTA / pertinence applicative

Etape du projet : Analyse

Mécanisme effectif

Chaque patch devient un token ; l'attention calcule l'importance **entre régions**.

$$a_{ij} = \text{softmax}\left(\frac{q_i k_j}{\sqrt{d}}\right), \quad \tilde{z}_i = \sum_j a_{ij} v_j$$

Le modèle combine ainsi **contexte global** et information locale.

Swin ajoute attention par **fenêtres + décalage**, puis **fusion de patches** (hiérarchie multi-échelle).

Aide en imagerie médicale

Relie des régions éloignées (symétrie pulmonaire, contexte global).

Utile pour motifs diffus et structures larges.

Swin reste efficace sur grandes images tout en gardant du détail.

Limites

Moins d'inductif bias que les CNN $\Rightarrow$ besoin de pré-entraînement.

Patches trop grands $\Rightarrow$ perte de lésions fines ; trop petits $\Rightarrow$ coût élevé.

Attention peut suivre des corrélats non pathologiques.

Phase 4 — Grad-CAM : principe et formulation

Role : Définir l'outil d'explicabilité utilisé pour interpréter les prédictions interprétable

Etape du projet : Analyse SOTA / évaluation

Idée

Grad-CAM met en évidence **où** le réseau “regarde” pour une classe donnée.
On utilise les gradients du score y^c par rapport aux cartes A^k .

Formules

Poids d'importance :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

Carte Grad-CAM :

$$L_{\text{Grad-CAM}}^c = \text{ReLU}\left(\sum_k \alpha_k^c A^k\right)$$

Interprétation

A^k : carte de features de la dernière couche conv.

α_k^c : contribution de la carte k à la classe c .


ReLU conserve les contributions positives.

Le modèle donne “**quoi**”, Grad-CAM suggère “**où**”.

Phase 4 — Grad-CAM : schéma de génération

Role : Visualiser le pipeline complet de production d'une heatmap explicative
évaluation interprétable

Etape du projet : Analyse SOTA /



Lecture : l'overlay montre les régions activées associées à la classe prédite.

Phase 4 — Grad-CAM : ce que ça aide (et ce que ça n'aide pas)

Role : Préciser l'utilité clinique réelle de Grad-CAM et ses limites méthodologiques
validation critique

Etape du projet : Analyse SOTA /

Ce que Grad-CAM apporte

Explication **post-hoc** : montre quelles zones augmentent le score y^c .

Ne modifie pas la prédiction, mais **guide l'analyse** (triage, relecture).

Utile pour repérer des biais (texte, marqueurs, position).

Permet d'aligner le modèle avec l'expertise clinique.

Ce que Grad-CAM ne garantit pas

Carte **grossière** (résolution = stride de la dernière couche).

Importance $\neq$ causalité ; une heatmap "plausible" peut être trompeuse.

Sensibilité à la couche choisie, au prétraitement et au bruit.

Interprétabilité = aide, pas preuve diagnostique.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit

Etape du projet : Navigation / structuration

- 1 Acronymes et terminologie
 - Glossaire initial
- 2 Problématique et Méthodologie
 - Entrepreneuriat et valorisation
- 3 Analyse SOTA
 - Phase 1 — DenseNet / CheXNet
 - Phase 2 — Optimisation et efficacité
 - Phase 3 — Vision Transformers et contexte global
 - Phase 4 — Confiance et explicabilité
- 4 Solution proposée
 - Architecture et conception
 - Pipeline détaillé
 - Implémentation et Outils techniques
- 5 Résultats et Finalisation

Solution proposée — Étape 0 : vue d'ensemble

Role : Présenter la logique globale du modèle avant le détail des étapes

Etape du projet : Conception de la solution

Principe et formule globale

MedFusionNet combine deux lectures d'une même radiographie :

- une branche **CNN** pour les indices locaux : contours, textures, petites opacités ;
- une branche **Swin** pour le contexte global : symétrie thoracique, bilatéralité, cohérence anatomique ;
- une **fusion guidée** qui pondère automatiquement les deux branches.

Chaîne mathématique.

$$\tilde{X} = T(X)$$

$$F_c = \Phi_c(\tilde{X}), \quad F_s = \Phi_s(\tilde{X})$$

$$g = \sigma(W_g[\text{GAP}(F_c), \text{GAP}(F_s)] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

La sortie finale vérifie $\Psi(F) = (p, L^c, u)$: score p , heatmap L^c , incertitude u .




Figure 2: Vue d'ensemble du pipeline complet

Solution proposée — Étape 1 : échantillon d'entrée

Role : Définir la donnée d'entrée et ce qu'elle contient avant tout calcul

Etape du projet : Conception détaillée

Image et variabilité

Une radiographie thoracique est modélisée par :

$$X \in \mathbb{R}^{H \times W}$$

avec une étiquette binaire :

$$\begin{cases} y = 1 & \text{pneumonie} \\ y = 0 & \text{normal ou autre classe négative} \end{cases}$$

Pourquoi l'entrée est difficile. L'image brute contient à la fois le signal clinique et des facteurs parasites :

- variations d'intensité et de contraste selon l'appareil ;
- bruit, annotations, câbles et autres artefacts ;
- cadrage, résolution et structures normales parfois trompeuses.

Exemple : deux clichés de même classe peuvent avoir un contraste ou un centrage très différents ; le modèle doit ignorer cette variabilité non pathologique.




Figure 3: Échantillon brut provenant du dataset

Solution proposée — Étape 2 : prétraitement

Role : Standardiser l'image avant son entrée dans les deux branches du modèle
préparation des données

Etape du projet : Développement /

Transformation

Le prétraitement applique une chaîne de standardisation :

$$\tilde{X} = T(X) = A(R(N(X)))$$

où N normalise les intensités, R redimensionne et A peut améliorer localement le contraste.

Ce que la donnée devient

normalisation :
$$X_{norm} = \frac{X - \mu}{\sigma}$$

redimensionnement :
$$X \in \mathbb{R}^{H \times W} \longrightarrow \tilde{X} \in \mathbb{R}^{H_0 \times W_0}$$

Exemple : $1024 \times 1024 \rightarrow 384 \times 384$. Cette étape réduit le coût mémoire, homogénéise les entrées et diminue le risque que le modèle prenne une différence d'acquisition pour une pneumonie.




Figure 4: Image après normalisation et redimensionnement

Solution proposée — Étape 3 : branche CNN locale

Role : Extraire les motifs fins et localisés par une lecture convolutive **Etape du projet :** Modélisation de la branche locale

Lecture locale par CNN

La branche locale produit :

$$F_c = \Phi_c(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_c}$$

Une convolution applique un filtre sur un voisinage restreint :



$$F_{i,j,c'}^{(\ell)} = \sum_{u,v,c} W_{u,v,c,c'}^{(\ell)} F_{i+u,j+v,c}^{(\ell-1)} + b_{c'}^{(\ell)}$$

Ce que la branche voit réellement.

- bords pleuraux, côtes, contours pulmonaires ;
- textures diffuses ou focales ;
- petites consolidations et opacités locales ;
- transitions fines entre tissu sain et tissu suspect.

Exemple : une opacité basale discrète peut être amplifiée par la comparaison locale entre intensités voisines.

Image / Feature Map



Couche suivante

Champ récepteur local ($k \times k$)

Figure 5: Représentation locale extraite par la branche CNN

Solution proposée — Étape 4 : branche Swin globale

Role : Extraire une représentation de contexte capable de relier des régions éloignées **Etape du projet :** Modélisation de la branche globale

Lecture globale par Swin

L'image prétraitée est découpée en patches puis projetée :

$$z_i = E x_i + e_i^{pos}$$

La branche globale calcule ensuite :


$$F_s = \Phi_s(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_s}$$

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Dans Swin, cette attention est calculée par fenêtres, puis les fenêtres sont décalées pour reconnecter les régions voisines. **Ce que la branche globale apporte.** Elle relie des zones éloignées : apex, bases, hémithorax droit/gauche, médiastin. Si une anomalie n'a de sens que par sa **distribution spatiale**, Swin la capture mieux qu'un CNN purement local.

**Attention Globale
(Longue distance)**



Patches d'image

Figure 6: Représentation globale extraite par la branche Swin

Solution proposée — Étape 5 : fusion guidée

Role : Combiner les indices locaux et globaux sans imposer un poids fixe à chaque branche **Etape du projet :** Conception du coeur de fusion

Porte de fusion et interprétation

On résume d'abord chaque branche par un vecteur global :

$$\bar{F}_c = \text{GAP}(F_c), \quad \bar{F}_s = \text{GAP}(F_s)$$

Puis on apprend un coefficient de fusion :

$$g = \sigma(W_g[\bar{F}_c, \bar{F}_s] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si $g \approx 1$, le modèle privilégie l'indice local ; si $g \approx 0$, il privilégie le contexte global. **Exemples. Exemple 1** : foyer net et compact $\Rightarrow g \approx 0.8$.

Exemple 2 : atteinte diffuse ou bilatérale $\Rightarrow g \approx 0.3$.

La fusion n'est donc pas une moyenne fixe : elle s'adapte à la structure réelle de l'image.




Figure 7: Fusion adaptative entre la branche locale et la branche globale

Solution proposée — Étape 6 : classification

Role : Transformer la représentation fusionnée en probabilité de pneumonie

Etape du projet : Tête de décision

Score de classe

La représentation fusionnée est condensée en un vecteur :

$$z = \text{GAP}(F)$$

puis convertie en probabilité :

$$p(y = 1|X) = \sigma(w^\top z + b)$$

Décision pratique

Avec un seuil τ :

$$\hat{y} = \begin{cases} 1 & \text{si } p(y = 1|X) \geq \tau \\ 0 & \text{sinon} \end{cases}$$

Exemple : si $p = 0.91$ et $\tau = 0.5$, la prédiction est positive avec une forte marge. Si $p = 0.54$, la décision reste positive mais devient fragile : elle doit être lue avec la heatmap et l'incertitude.




Figure 8: Passage de la représentation fusionnée au score de classe

Solution proposée — Étape 7 : localisation et incertitude

Role : Produire une explication spatiale et mesurer la fiabilité de la décision

Etape du projet : Sorties interprétables

Localisation et incertitude

À partir des cartes finales A^k :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

$$L^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right)$$

La heatmap montre **où** le modèle a trouvé des indices pour la classe prédite. **Incertainité**. En répétant plusieurs passes avec dropout actif :

$$u = \text{Var}_t(p_t)$$

Exemple : si $p_t = \{0.87, 0.88, 0.89\}$, la variance est faible ; si $p_t = \{0.42, 0.81, 0.57\}$, la décision est instable et doit être relue.




Figure 9: Heatmap explicative et estimation d'incertitude

Solution proposée — Étape 8 : apprentissage

Role : Définir exactement ce qui est optimisé pendant l'entraînement **Etape du projet :** Développement / entraînement

Fonction objectif

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{loc} + \lambda_2 \mathcal{L}_{cons} + \lambda_3 \mathcal{L}_{cal}$$

Sens de chaque terme

$\mathcal{L}_{cls}$: apprendre la bonne classe.

$\mathcal{L}_{loc}$: contraindre la heatmap à rester cliniquement plausible.

$\mathcal{L}_{cons}$: garder une prédiction stable sous augmentation.

$\mathcal{L}_{cal}$: mieux aligner confiance prédite et fréquence réelle d'erreur.

Exemple : sur un dataset déséquilibré, $\mathcal{L}_{cls}$ peut être une Focal Loss afin de mieux traiter les cas rares ou difficiles.




Figure 10: Schéma de la perte totale et de ses composantes

Solution proposée — Étape 9 : sortie clinique

Role : Montrer comment les sorties du modèle deviennent une aide concrète pour le workflow médical **Etape du projet :** Validation métier / déploiement

Sortie exploitable pour le clinicien

Pour une image X , le modèle renvoie :

$$(p(y = 1|X), L^c, u)$$

soit un score de pneumonie, une heatmap explicative et une estimation d'incertitude.

Comment cela aide le clinicien.

- score élevé + faible incertitude : cas à prioriser ;
- score modéré + incertitude élevée : revue humaine prioritaire ;
- score faible + faible incertitude : cas probablement normal.

Limite : une heatmap plausible reste un support de lecture, pas une preuve diagnostique.




Figure 11: Sortie finale utilisable par le clinicien

Implémentation — Dataset Chest X-Ray

Role : Justifier la sélection et les caractéristiques des données d'apprentissage **Etape du projet :** Préparation des données

Spécifications & Accès aux données

Dataset Kaggle de Paul Mooney (5 856 images).

- **Classes :** *NORMAL* vs *PNEUMONIA*.
- **Défi :** Déséquilibre fort (plus de cas malades).
- **Choix :** Utilisation de la *Focal Loss* pour corriger le biais de majorité et focaliser sur les cas difficiles.



Lien Kaggle :
(Scanner pour accéder
au dataset)




Figure 12: Répartition et flux des données d'imagerie

Implémentation — Choix Technologiques

Role : Exposer et justifier la stack matérielle et logicielle du projet

Etape du projet : Configuration de l'environnement

Framework & Langage

Code source intégral en **Python 3**.

L'orchestration du Deep Learning repose sur l'écosystème **PyTorch**.

Environnement et Accélération

Face aux contraintes matérielles de machine locale (crash mémoire liés aux larges matrices *Swin*), le modèle a migré sur **Google Colab** :

- Accès direct aux GPU (T4 ou A100).
- Injection de l'AMP (*Automatic Mixed Precision*) pour basculer en float16 et réduire drastiquement la consommation VRAM.




Figure 13: Pile Technologique du système MedFusionNet

Implémentation — Architecture du Projet

Role : Montrer la robustesse de l'arborescence et la modularité des composants

Etape du projet : Gestion de Projet

Séparation des responsabilités

Notre socle algorithmique sépare rigoureusement la donnée, la logique métier, l'entraînement et l'inférence. Cette compartimentation favorise une évolutivité sans bugs spatiaux :

- Dossiers checkpoints/ isolant les poids sauvegardés des écrasements.
- Fichiers modulaires .py clairs et réutilisables.
- Carnet MedFusionNet_Colab.ipynb agissant comme un orchestrateur important l'environnement ciblé du Cloud vers nos scripts natifs.




Figure 14: Arborescence du répertoire de travail (Git)

Implémentation — Les Modules de Code (API)

Role : Documenter les scripts métiers Python principaux et leurs relations

Etape du projet : Architecture Logicielle

Cœur Algorithmique

preprocessing.py & dataset.py : Pipeline de normalisation (CLAHE) et orchestration PyTorch *DataLoaders* fournissant des batchs au GPU en parallèle.

model.py & losses.py : Définition déclarative de la double branche (CNN + Swin + Gate) et des équations de la fonction *Objective* (Focal Loss, ...).

inference.py : API finale (MedFusionInference) destinée au clinicien : génère le score, calcule l'incertitude via MC-Dropout en 20 passes rapides, puis tisse la masque explicative (Heatmap).




Figure 15: Interaction logique entre les fichiers source principaux

Implémentation — API REST locale

Role : Montrer comment le moteur d'inférence a été exposé à des clients externes sans casser l'interface web
projet : Architecture Logicielle

Etape du

Composants d'exposition

api.py : Blueprint Flask sous `/api/v1` exposant `/health`, `/predict`, `/predict/gradcam` et `/benchmark`.


app.py : Enregistre le Blueprint sans toucher aux routes HTML déjà utilisées par l'interface Flask.

service.py : Conserve `model_store` : le chargement du checkpoint reste **lazy** et partagé.

client.py : CLI local pour tester l'API, afficher les métriques et exporter les images Grad-CAM.

Intérêt pratique

- même moteur d'inférence pour le navigateur, curl et les scripts externes ;
- point d'intégration propre pour une future interface plus riche ;
- smoke tests simples via `/api/v1/health` et le client CLI.



Implémentation — Workflow d'une requête API

Rôle : Expliquer le cycle complet d'une requête, la validation de l'image et la structure des réponses JSON
projet : Déploiement local / intégration

Etape du

Cycle de traitement

- 1 Entrée : multipart/form-data ou octets image bruts.
- 2 Validation : extension autorisée, ouverture PIL conversion RGB.
- 3 Traitement : `engine.predict(...)` ou `run_benchmark(max_images)`.
- 4 Sortie : réponse **JSON** avec probabilités, métadonnées et temps d'inférence.

Routes exposées

- GET `/api/v1/health`
- POST `/api/v1/predict`
- POST `/api/v1/predict/gradcam`
- GET `/api/v1/benchmark?max_images=20`

Choix d'implémentation

- `/predict` : score simple, sans heatmap.
- `/predict/gradcam` : overlay et heatmap en PNG Base64.
- `/benchmark` : métriques seulement, graphes exclus.

Exemples d'appel

```
curl /api/v1/health
```

```
curl -X POST /api/v1/predict  
-F "image=@radio.jpeg"
```

```
python client.py predict image.jpeg  
--gradcam --save overlay.png
```

Implémentation — Exécution et Hyperparamètres

Role : Justifier les variables d'ajustement du code lors de l'apprentissage **Etape du projet :** Lancement de l'Entraînement

Lancement via `train.py`

L'exécution de l'entraînement a été finement calibrée sur l'environnement Colab :

- `--epochs 50` : Temps de chauffe suffisant pour stabiliser le réseau Transformer.
- `--batch_size 16` : Contrainte optimale GPU allégeant la VRAM tout en maintenant le batch normalization fonctionnel.
- `--lr 1e-4` & **AdamW** : Taux d'apprentissage modéré afin d'éviter l'oubli catastrophique du pré-entraînement CNN.




Figure 16: Flux d'exécution de l'entraînement et enregistrements

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit

Etape du projet : Navigation / structuration

- 1 Acronymes et terminologie
 - Glossaire initial
- 2 Problématique et Méthodologie
 - Entrepreneuriat et valorisation
- 3 Analyse SOTA
 - Phase 1 — DenseNet / CheXNet
 - Phase 2 — Optimisation et efficacité
 - Phase 3 — Vision Transformers et contexte global
 - Phase 4 — Confiance et explicabilité
- 4 Solution proposée
 - Architecture et conception
 - Pipeline détaillé
 - Implémentation et Outils techniques
- 5 Résultats et Finalisation

Résultats obtenus — synthèse quantitative

Rôle : Donner les performances finales du modèle sur le jeu de test et les interpréter **Etape du projet :** Évaluation finale

Protocole d'évaluation

- **Jeu de test final :** 624 radiographies.
- **Répartition :** 234 cas NORMAL et 390 cas PNEUMONIA.
- **Checkpoint évalué :**
Model_19Apr26.pth.

Indicateurs globaux

- **Accuracy :** 92.79%
- **AUC-ROC :** 0.976
- **Average Precision :** 0.984
- **Erreurs totales :** 45 images sur 624 seulement

Classe PNEUMONIA

- **Recall / Sensibilité :** 96.92%
- **Precision :** 91.97%
- **F1-score :** 94.38%

Classe NORMAL

- **Recall / Spécificité :** 85.90%
- **Precision :** 94.37%
- **F1-score :** 89.93%

Résultats obtenus — matrice de confusion et lecture métier

Rôle : Expliquer précisément où le modèle se trompe et pourquoi ces erreurs comptent
détaillée des sorties

Etape du projet : Analyse

Matrice de confusion

Vrai / Prédit	NORMAL	PNEUMONIA
NORMAL	201	33
PNEUMONIA	12	378

Bilan chiffré

- **Vrais positifs :** 378
- **Vrais négatifs :** 201
- **Faux positifs :** 33
- **Faux négatifs :** 12

Interprétation





- Sur **390** cas de pneumonie, le système en détecte **378**.
- Le taux de cas pneumonie manqués est de $12 / 390 = 3.08\%$.
- Sur **234** images normales, **33** sont surclassées à tort en pneumonie.
- Le modèle est donc **volontairement plus sensible que spécifique** : il déclenche plus facilement une alerte plutôt que de laisser passer une pneumonie.
- En contexte de triage, ce compromis reste **cohérent médicalement**.

Résultats obtenus — benchmark visuel sur le jeu de test

Role : Montrer visuellement la qualité de séparation du modèle à l'échelle du test complet **Etape du projet :** Benchmark final

Benchmark final — Test set (624 images)

Accuracy 92.79% | AUC 0.976 | AP 0.984 | Recall pneumo 96.92%



TN=201 FP=33 FN=12 TP=378

Ce que montrent les courbes

- **ROC** : courbe très proche du coin supérieur gauche.
- **PR** : AP = **0.984**, donc très bon classement des cas pneumonie.
- Les scores sont **bien séparés** ; peu d'ambiguïté autour du seuil 0.5.

Résultats obtenus — comportement durant l'entraînement

Role : Lire les courbes d'apprentissage et signaler les limites de validation

Etape du projet : Analyse du run conservé



Lecture des courbes


- La **train loss** baisse régulièrement : le modèle apprend effectivement.
- La **val loss** oscille davantage : la validation est plus instable.
- Les métriques montent vite, mais la validation ne contient que **16 images**.
- La conclusion finale doit donc s'appuyer sur le **test set à 624 images**.

Résultats obtenus — validation qualitative par Grad-CAM

Role : Montrer comment l'explicabilité visuelle aide à valider le comportement du modèle
Interprétabilité

Etape du projet :

GradCAM — What MedFusionNet sees in each X-ray



Ce que l'on observe

- Les activations se concentrent surtout sur les **champs pulmonaires** et sur des zones cohérentes avec des opacités.
- Le modèle ne semble pas décider uniquement à partir des bords ou du fond de l'image.
- Grad-CAM aide à expliquer **où** le réseau regarde, mais reste un **outil qualitatif**.

Finalisation du projet

Rôle : Résumer les livrables concrets du projet et la suite logique **Etape du projet :** Clôture / mise en production locale

Livrables finalisés

- **Modèle final entraîné** et checkpoint exporté.
- **Runtime Python** modulaire avec CLI et API locale.
- **Interface web Flask** pour charger une image, lancer l'inférence et voir le Grad-CAM.
- **Benchmark local** avec ROC, PR, matrice de confusion et distribution des scores.

Conclusion technique

- Le système est **fonctionnel de bout en bout**.
- Les performances sont **suffisamment fortes** pour démontrer la viabilité de l'approche hybride Swin + DenseNet.
- Le compromis retenu favorise la **détection des cas positifs**, ce qui est cohérent avec l'objectif médical.

Améliorations futures

- augmenter la taille du jeu de validation
- renforcer la spécificité
- tester sur un dataset externe et améliorer la calibration

Mots clés

Role : Synthétiser les thèmes techniques majeurs couverts par le document

Etape du projet : Clôture documentaire

Intelligence Artificielle

Deep Learning

Vision par Ordinateur

Radiographie Thoracique (CXR)

Pneumonie

CNN / Transformers

Transfer Learning

Interprétabilité (Grad-CAM)

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit

Etape du projet : Navigation / structuration

6 Annexes

- Références techniques

Annexe A — Convolution, stride et pooling

Rôle : Définir les opérations de base des CNN utilisées dans les architectures étudiées **Etape du projet :** Annexe technique

Definitions

Convolution $k \times k$: Filtre local glissant sur l'image ou sur une carte de features.

Stride s : Pas de déplacement du filtre ; quand s augmente, la résolution baisse plus vite.

Padding : Bordure ajoutée pour contrôler la taille de sortie.

MaxPool : Conserve la plus forte activation dans une fenêtre locale.

AvgPool : Remplace une fenêtre locale par sa moyenne.

Formules utiles

$$Y_{i,j,c'} = \sum_{u,v,c} W_{u,v,c,c'} X_{i+u,j+v,c} + b_{c'}$$

$$H_{out} = \left\lfloor \frac{H + 2p - k}{s} \right\rfloor + 1$$

Intuition

Les convolutions extraient des motifs locaux. Le pooling résume l'information et réduit la taille spatiale pour rendre le calcul plus efficace.

Annexe B — BN, ReLU, bottleneck et connexions

Role : Clarifier les briques de stabilisation et d'efficacité citées dans DenseNet et EfficientNet **Etape du projet** : Annexe technique

Stabilisation

BN : Normalise les activations d'un mini-batch pour stabiliser et accélérer l'entraînement.

ReLU : Garde les valeurs positives et annule les négatives, ce qui introduit une non-linéarité simple.

Skip connection : Réinjecte une information plus tôt dans le réseau pour faciliter le gradient.

Efficacité

Bottleneck : Réduit les canaux avant une opération coûteuse, puis projette de nouveau si besoin.

Growth rate k : Nombre de nouveaux canaux ajoutés par chaque couche dense.

SE : Mécanisme qui ré-pondère les canaux selon leur importance.

Fused-MBConv : Version simplifiée de MBConv, souvent plus rapide à entraîner sur GPU dans les premiers étages.

Annexe C — DenseNet et MBConv

Role : Reprendre proprement les blocs spécifiques les plus utilisés dans l'analyse SOTA technique

Etape du projet : Annexe

Bloc dense

DenseNet concatène les sorties précédentes au lieu de simplement les additionner.

$$x_\ell = H_\ell([x_0, \dots, x_{\ell-1}])$$

Cela favorise la réutilisation des features et un meilleur flux de gradient.

MBConv

MBConv combine :

- une expansion 1×1 ,
- une convolution depthwise,
- un module SE,
- une projection finale 1×1 .

L'objectif est d'obtenir une bonne expressivité à coût réduit.

Annexe D — Vocabulaire Transformer

Role : Définir les notions de patches, tokens et embeddings utilisées dans ViT et Swin **Etape du projet :** Annexe technique

Definitions

Patch : Sous-image locale de taille $P \times P$.

Token : Vecteur obtenu après projection d'un patch.

Embedding : Représentation vectorielle dense envoyée dans le Transformer.

Encodage positionnel : Information ajoutée pour conserver l'ordre spatial des patches.

Formule de tokenisation

$$N = \frac{HW}{P^2}, \quad z_i = E x_i + e_i^{pos}$$

Intuition

Le Transformer traite l'image comme une séquence de morceaux visuels, de la même façon qu'un modèle de langage traite une phrase comme une séquence de mots.

Annexe E — Attention et Swin

Rôle : Détailler le calcul d'attention et la logique des fenêtres décalées de Swin

Etape du projet : Annexe technique

Attention

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Q : Ce que le token courant cherche.

K : Ce que les autres tokens proposent pour être reliés à lui.

V : L'information qui sera effectivement transmise.

Pourquoi Swin

Fenêtre : Sous-ensemble local de tokens traité ensemble.

Fenêtres décalées : Décalage d'une couche à la suivante pour reconnecter des zones voisines.

Bénéfice : Réduire le coût du contexte global tout en conservant des interactions spatiales utiles.

Complexité

L'attention globale est quadratique en nombre de tokens. Swin réduit ce coût en limitant l'attention à des fenêtres locales.

Annexe F — Entraînement complémentaire

Rôle : Définir les notions d'entraînement mentionnées sans détail dans la solution proposée technique

Etape du projet : Annexe

Concepts de base

Transfer learning : Réutiliser un modèle pré-entraîné puis l'adapter à la radiographie thoracique.

Augmentation : Modifier l'image pendant l'entraînement pour rendre le modèle plus robuste.

Pseudo-masque : Zone approximative utilisée comme supervision faible quand on n'a pas d'annotation pixel exacte.

Logit : Score brut avant application de la sigmoïde ou du softmax.

Pourquoi c'est utile

Ces mécanismes servent à :

- mieux généraliser,
- réduire la dépendance à un seul centre hospitalier,
- exploiter des annotations incomplètes,
- stabiliser l'apprentissage quand les données sont déséquilibrées.

Annexe G — Pertes et calibration

Role : Définir les fonctions objectif et la notion de confiance calibrée

Etape du projet : Annexe technique

Fonctions de perte

BCE : Binary Cross-Entropy, perte standard de classification binaire.

Focal loss : Version de BCE qui met davantage l'accent sur les exemples difficiles ou rares.

$\mathcal{L}_{cons}$: Impose des sorties proches pour deux vues augmentées d'une même image.

$\mathcal{L}_{loc}$: Contraint la carte explicative à rester cohérente avec une zone plausible.

Calibration

Calibration : Une probabilité 0.8 devrait correspondre à environ 80% de prédictions correctes.

Temperature scaling : Correction post-hoc des logits par un scalaire de température.

ECE : Mesure l'écart entre confiance moyenne et précision réelle.

$$ECE = \sum_{m=1}^M \frac{|B_m|}{n} |\text{acc}(B_m) - \text{conf}(B_m)|$$

$$\mathcal{L}_{BCE} = -(y \log p + (1 - y) \log(1 - p))$$

Annexe H — Fusion, explicabilité et incertitude

Role : Documenter les sorties avancées de la solution proposée

Etape du projet : Annexe technique

Fusion et gating

Le gating apprend le poids relatif des branches locale et globale.

$$g = \sigma(W_g[\text{GAP}(F_c), \text{GAP}(F_s)])$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si g est grand, la branche CNN domine ; sinon la branche Swin domine.

Explicabilité et confiance

Grad-CAM : Carte visuelle des zones qui contribuent positivement au score choisi.

MC-Dropout : Plusieurs passes avec dropout actif à l'inférence pour estimer l'incertitude.

Variance prédictive : Plus elle est grande, moins la décision est fiable.

$$u = \text{Var}_t(p_t)$$

Annexe I — Metriques d'évaluation

Role : Définir précisément les mesures de performance et leur lecture clinique

Etape du projet : Annexe technique

Definitions

Accuracy : Proportion totale de prédictions correctes.

Recall / Sensibilité : Capacité à retrouver les cas positifs.

Spécificité : Capacité à rejeter les cas négatifs.

AUC-ROC : Qualité de séparation entre classes quand on fait varier le seuil.

Faux positif : Cas sain déclaré malade.

Faux négatif : Cas malade déclaré sain.

Formules

$$\text{Recall} = \frac{TP}{TP+FN}, \quad \text{Specificite} = \frac{TN}{TN+FP}$$

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Lecture en contexte médical

En dépistage de pneumonie, réduire les faux négatifs est souvent prioritaire : manquer un cas pathologique est généralement plus grave que sur-appeler un cas douteux.