Présentation PFA: Détection de pneumonie sur radiographie

Conception, Modélisation et Développement.

HANFAOUI Karim[1] KAFIF. Imane[2]

[1]EMSI, 4ème Année IADO G2 - Karim.Hanfaoui@emsi-edu.ma
[2]EMSI, 4ème Année IADO G2 - Imane.Kafif@emsi-edu.ma

EMSI Les Orangers, Mars 2026

Table des Matières

Role : Présenter la structure complète du rapport et l'ordre des étapes **Etape du projet :** Navigation / cadrage global

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
5. Résultats et Finalisation

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
5. Résultats et Finalisation

Acronymes — Domaine et modèles

Role : Donner les sigles du domaine avant les slides techniques | **Etape du projet :** Référence documentaire

Domaine médical et IA

IA : Intelligence Artificielle.

DL : Deep Learning, famille de modèles à plusieurs couches.

CXR : Chest X-Ray, radiographie thoracique.

SOTA : State Of The Art, meilleur niveau connu au moment de l'étude.

Modèles et approches

CNN : Convolutional Neural Network, réseau fondé sur les convolutions.

ViT : Vision Transformer, adaptation du Transformer aux images.

Swin : Shifted Window Transformer, Transformer hiérarchique à fenêtres décalées.

Grad-CAM : Gradient-weighted Class Activation Mapping, outil d'explicabilité visuelle.

Acronymes — Blocs techniques

Role : Définir les sigles techniques utilisés dans les architectures et l'évaluation **Etape du projet :** Référence documentaire

Architecture

BN : Batch Normalization, normalisation des activations sur un mini-batch.

ReLU : Rectified Linear Unit, activation $f(x) = \max(0, x)$.

GAP : Global Average Pooling, moyenne spatiale par canal.

FC : Fully Connected, couche dense finale de décision.

Efficacité et confiance

MBConv : Mobile Inverted Bottleneck Convolution, bloc compact d'EfficientNet.

SE : Squeeze-and-Excitation, mécanisme de ré-pondération des canaux.

FLOPs : Floating Point Operations, estimation du coût de calcul.

ECE : Expected Calibration Error, mesure de calibration des probabilités.

Notations mathématiques

Role : Définir les notations qui reviennent dans les équations et les schémas **Etape du projet :** Référence documentaire

Tailles et dimensions

H, W : Hauteur et largeur spatiales d'une image ou d'une carte de features.

C : Nombre de canaux.

L : Nombre de couches ou de blocs, selon le contexte.

k : Growth rate DenseNet, nombre de nouveaux canaux ajoutés par couche.

Variables de modélisation

ϕ : Facteur global de scaling dans EfficientNet.

X : Image d'entrée.

F : Tensor de features appris par le modèle.

$p(y|X)$: Probabilité prédite pour une classe y conditionnée par l'image X.

Terminologie d'architecture

Role : Définir les termes techniques utilisés sans alourdir les slides principales **Etape du projet :** Référence documentaire

CNN et représentations

Feature map : Carte d'activation produite par un bloc du réseau.

Backbone : Extracteur principal de représentations d'une architecture.

Bottleneck : Réduction intermédiaire des canaux pour baisser le coût.

Skip connection : Chemin de contournement transmettant une information plus tôt dans le réseau.

Transformers et fiabilité

Token : Unité d'entrée d'un Transformer, ici un patch projeté.

Embedding : Représentation vectorielle dense d'un objet discret ou local.

Calibration : Adéquation entre probabilité annoncée et fréquence réelle de succès.

Heatmap : Carte colorée montrant des zones activées ou importantes pour la décision.

Guide de lecture du document

Role : Préciser le rôle exact de chaque groupe de slides dans la fabrication du projet **Etape du projet :** Lecture guidée du rapport

Cadrage

Problématique / Méthodologie : Définir le besoin clinique, la question scientifique et l'organisation du travail.

Analyse SOTA : Comparer les approches existantes avant de choisir une direction.

Conception

Solution proposée : Définir l'architecture cible, sa logique et ses sorties.

Validation

Résultats : Mesurer la performance finale et lire les indicateurs.

Annexes : Documenter les notions techniques non développées dans le flux principal.

Principe de lecture

Chaque slide technique indique explicitement :

- son **role** dans le document,
- l'**etape du projet** à laquelle il appartient.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
5. Résultats et Finalisation

Problématique

Role : Poser le besoin clinique, la question de recherche et la contrainte d'explicabilité **Etape du projet :** Cadrage scientifique

Question Centrale de Recherche

Face à la complexité visuelle des pathologies pulmonaires et à la pénurie mondiale de radiologues experts, comment pouvons-nous concevoir un système automatisé basé sur le Deep Learning capable non seulement de détecter la pneumonie avec une précision clinique supérieure à l'interprétation humaine, mais aussi de fournir une justification visuelle explicable afin de garantir une intégration sécurisée et fiable dans le flux de travail médical d'urgence ?

Méthodologie : Approche Agile (Scrum)

Role : Montrer comment le projet est découpé en phases de travail et d'itération **Etape du projet :** Organisation / planification

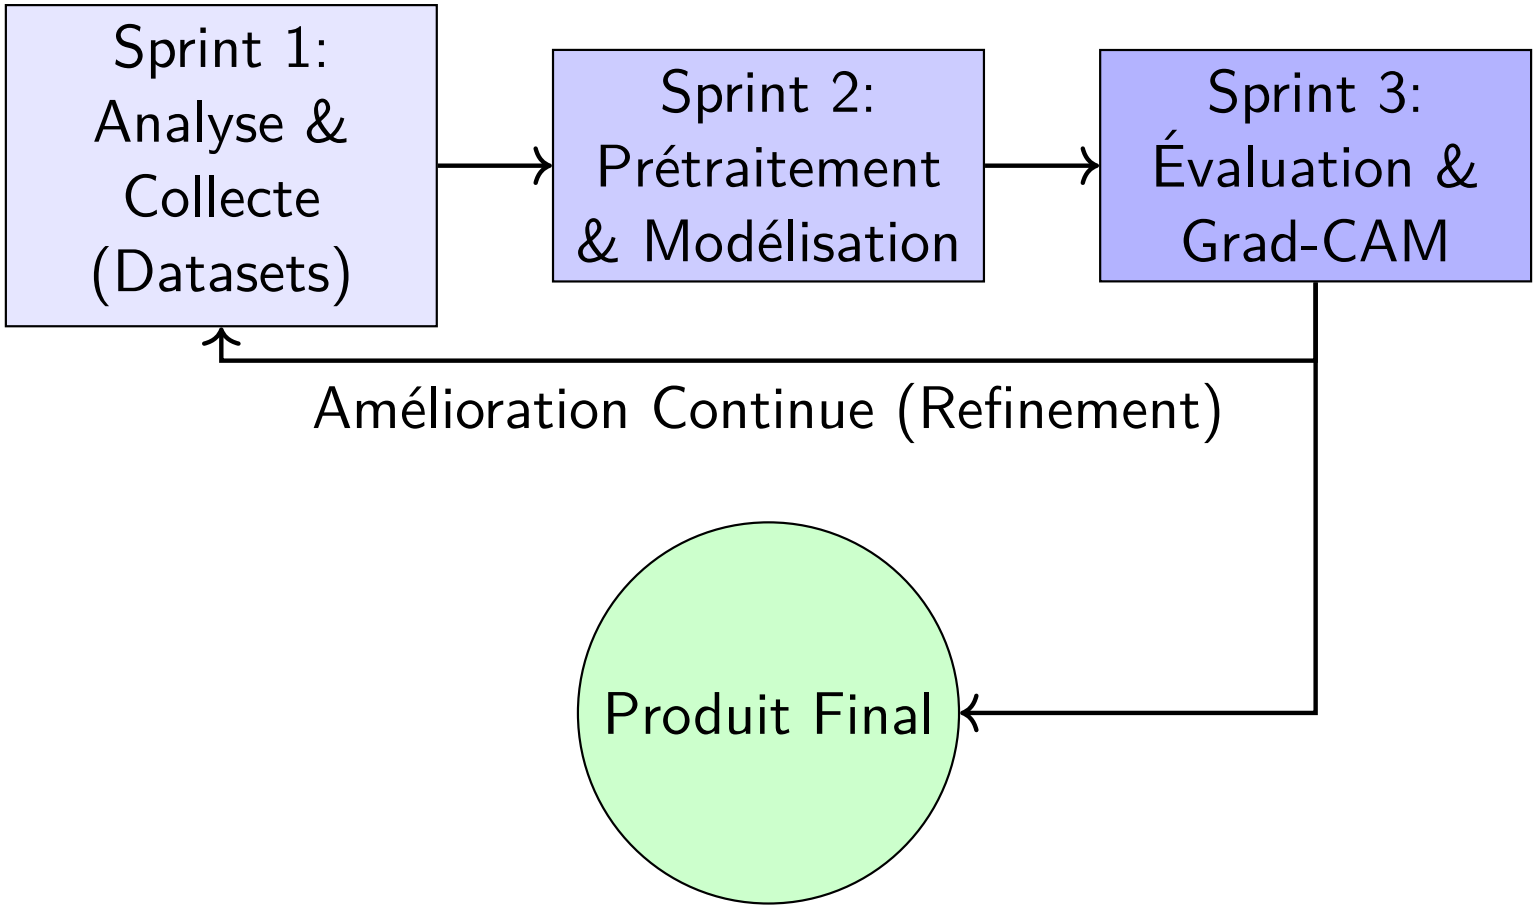

- **Flexibilité :** Adaptation aux contraintes des données médicales.
- **Itérations :** Optimisation progressive des hyperparamètres.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
5. Résultats et Finalisation

SOTA : Architecture DenseNet-121

Role : Présenter le modele CNN de référence utilisé comme base de comparaison **Etape du projet :** Analyse SOTA / comparaison

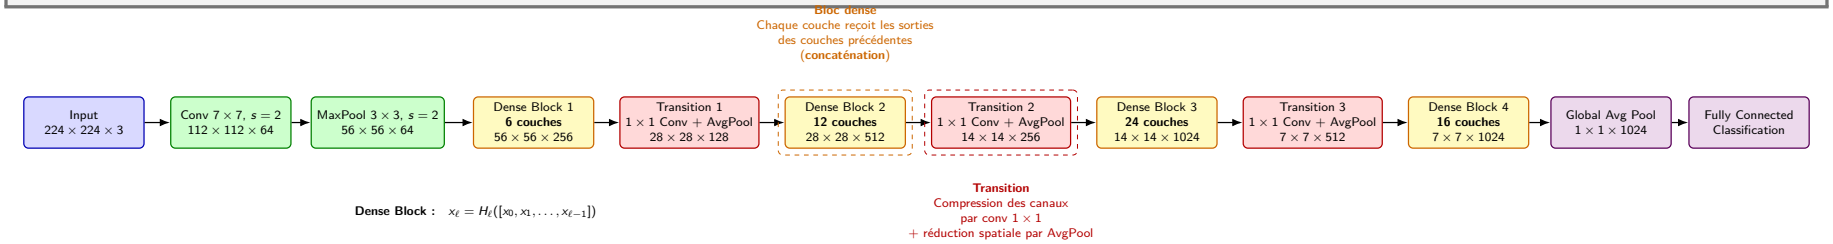

Dense Block
Concaténation de toutes les cartes précédentes :
$x_\ell = H_\ell([x_0, x_1, \ldots, x_{\ell-1}])$
Réutilisation des features + meilleur flux de gradient.
Croissance des canaux : $C_{\text{out}} = C_0 + L \cdot k$.
Exemple : $k = 32$, $L = 6 \Rightarrow C_{\text{out}} = C_0 + 192$.
Où C_0 = canaux initiaux, L = nb de couches, k = growth rate.

Transition
Entre blocs denses, compresse et réduit.
$X \in \mathbb{R}^{H \times W \times C}$
$\rightarrow \text{Conv}_{1\times1}(X) = Y \in \mathbb{R}^{H \times W \times C'}$
$Y_{h,w,c'} = \sum_c W_{c',c} X_{h,w,c} + b_{c'}$
$\rightarrow \text{AvgPool}(Y) = Z \in \mathbb{R}^{H/2 \times W/2 \times C'}$
$Z_{i,j,c'} = \frac{1}{4} \sum_{u,v \in \{0,1\}} Y_{2i+u,2j+v,c'}$
Compression, efficacité, préparation du bloc suivant.
Où H, W = hauteur/largeur, C = canaux, C' = canaux compressés.

Stem / Entrée
Entrée $224 \times 224 \times 3$.
Conv 7×7 ($s = 2$) puis MaxPool 3×3 ($s = 2$).
Extrait des bords/textures et réduit tôt la résolution.
Exemple : $224 \times 224 \rightarrow 112 \times 112 \rightarrow 56 \times 56$.
Où H, W = dimensions spatiales, s = stride.

Tête de classification
Global Avg Pooling : moyenne spatiale par canal.
$7 \times 7 \times 1024 \rightarrow 1 \times 1 \times 1024$.
$g_c = \frac{1}{HW} \sum_{h,w} F_{h,w,c}$, puis FC.
Exemple : $g \in \mathbb{R}^{1024} \rightarrow$ scores $\in \mathbb{R}^K$.
Où F = carte de features, g = vecteur global, K = nb de classes.

DenseNet-121 : Structure d'une couche dense

Role : Expliquer le calcul interne d'une couche dense pour comprendre le baseline choisi **Etape du projet :** Analyse SOTA / compréhension mécanistique

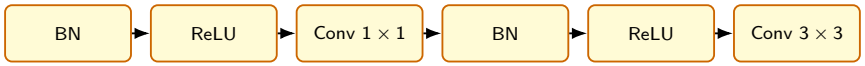

Séquence : BN $\rightarrow$ ReLU $\rightarrow$ Conv 1×1 $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ Conv 3×3

Transformation H_ℓ
H_ℓ est la transformation appliquée par la couche ℓ dans un bloc dense ; elle produit de **nouvelles** cartes de features.
Formule :
$H_\ell(x) = \mathrm{Conv}_{3\times3}\big(\mathrm{ReLU}(\mathrm{BN}(\mathrm{Conv}_{1\times1}(\mathrm{ReLU}(\mathrm{BN}(x))))))\big)$
Si $x = [x_0, x_1, \ldots, x_{\ell-1}]$, alors $x_\ell = H_\ell(x)$.
Interprétation : 1×1 = mélange/réduction des canaux (bottleneck),
3×3 = extraction spatiale locale, BN+ReLU = stabilité + non-linéarité.
Croissance : la couche ajoute k canaux :
$C_{\text{out}} = C_{\text{in}} + k$.
Après L couches : $C_{\text{out}} = C_0 + Lk$.
Où C_{in} = canaux d'entrée, C_0 = canaux initiaux, k = growth rate.

Phase 2 — EfficientNet : idée générale et scaling

Role : Comparer une stratégie d'optimisation du coût de calcul par scaling équilibré **Etape du projet :** Analyse SOTA / comparaison

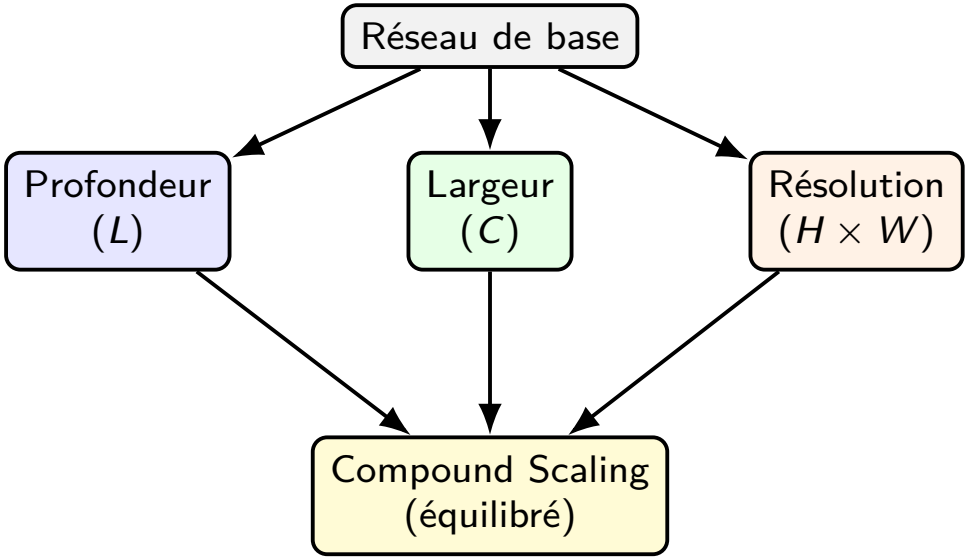

Idée centrale
EfficientNet est une famille de CNN conçue pour **mieux exploiter** un budget de calcul donné.
Le **scaling naïf** (uniquement profondeur, largeur ou résolution) crée un déséquilibre :
trop profond $\Rightarrow$ gradient fragile,
trop large $\Rightarrow$ surcoût mémoire,
trop haute résolution $\Rightarrow$ coût quadratique.

Compound Scaling
On augmente **ensemble** profondeur, largeur et résolution par un facteur global ϕ pour rester efficace.

$$d = \alpha^{\phi}, \quad w = \beta^{\phi}, \quad r = \gamma^{\phi},$$
$$\alpha\,\beta^2\,\gamma^2 \approx 2$$

ϕ contrôle l'échelle globale ; la contrainte équilibre coût et performance.

Phase 2 — MBConv : bloc clé d'EfficientNet

Role : Détailler le bloc opératoire central qui rend EfficientNet efficace **Etape du projet :** Analyse SOTA / modélisation d'un bloc

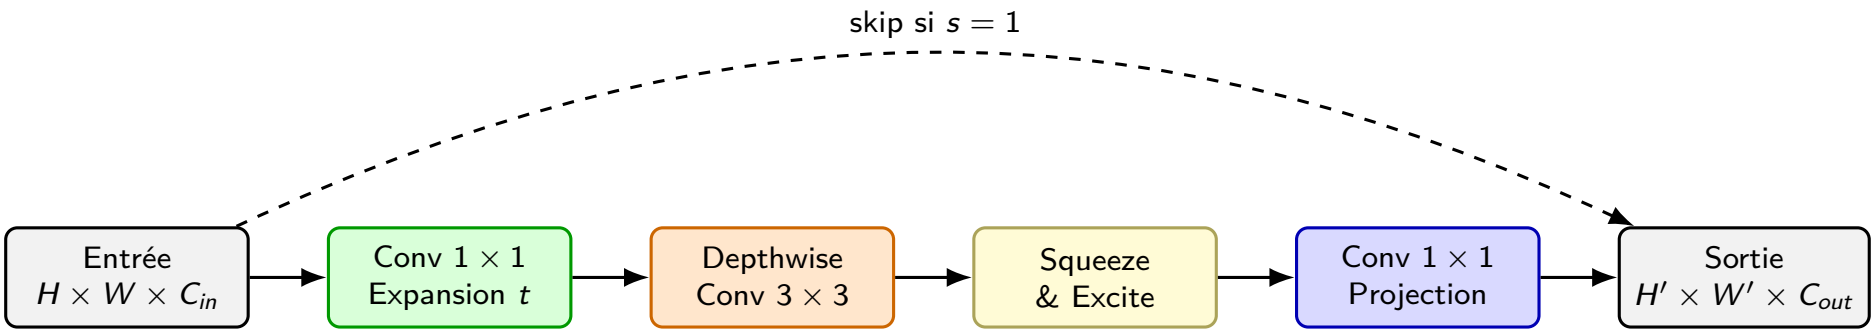

Depthwise Convolution
Chaque canal est filtré séparément :
$Y_{h,w,c} = \sum_{i,j} K_{i,j}^{(c)} X_{h+i,w+j,c}$
Coût paramétrique : $k^2 C$
au lieu de $k^2 CC'$ (conv standard).
Réduit fortement les paramètres et FLOPs.

MBConv en pratique
1) Expansion
$C_e = t \cdot C_{in}$,
2) Depthwise 3×3,
3) SE (ré-pondération canal),
4) Projection vers C_{out},
5) Skip si stride $s = 1$
et dimensions
compatibles.
Objectif :
expressivité élevée
avec coût réduit.

Phase 2 — EfficientNetV2 et impact médical

Role : Montrer l'évolution d'EfficientNet vers une version plus rapide à entraîner et à déployer **Etape du projet :** Analyse SOTA / comparaison

EfficientNetV2 : améliorations
Optimise l'entraînement (plus rapide et stable) via :
- **Fused-MBConv** sur les petits étages (meilleur débit GPU),
- règles de scaling adaptées,
- stratégies de régularisation plus efficaces.

Résultat : **meilleure précision** à coût d'entraînement réduit.

Intérêt en imagerie médicale
Meilleur compromis précision/temps :
- utile pour stations avec GPU limités,
- facilite l'expérimentation rapide,
- déploiement clinique plus réaliste.

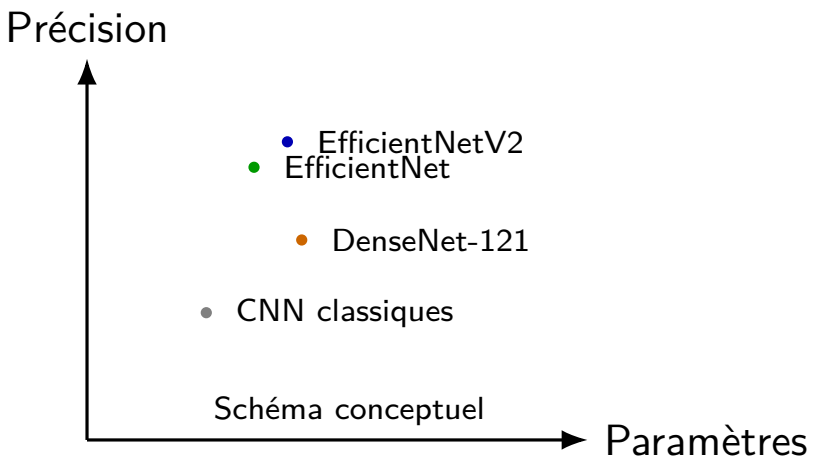

Phase 2 — EfficientNet : ce que fait le modèle

Role : Relier le mécanisme d'EfficientNet aux besoins pratiques de la détection sur CXR **Etape du projet :** Analyse SOTA / pertinence applicative

Mécanisme effectif

Le réseau apprend une fonction f_θ qui transforme X en **cartes hiérarchiques** (bords, textures, motifs complexes).
Les blocs MBConv alternent **mixage de canaux** (1×1), **filtrage spatial local** (depthwise) et **ré-pondération** (SE).
Après agrégation globale :
$z = \mathrm{GAP}(F_L(X)), \quad p(y|X) = \sigma(w^\top z)$
Le scaling compound règle **profondeur/largeur/résolution** pour préserver détail et contexte.

Aide en imagerie médicale

Capte des patterns **multi-échelles** (opacités diffuses, consolidations).
Bon compromis précision/coût $\Rightarrow$ utile en contexte GPU limité.
Permet d'exploiter des images haute résolution sans explosion de paramètres.

Limites et risques

Downsampling peut effacer des signes **très fins**.
Sensibilité aux biais (texte, position, appareil, contraste).
Pas de localisation directe : nécessite un outil d'explicabilité.

Phase 3 — ViT : patches et tokens

Role : Introduire la représentation en patches qui remplace la grille convolutive classique **Etape du projet :** Analyse SOTA / comparaison

Image → patches

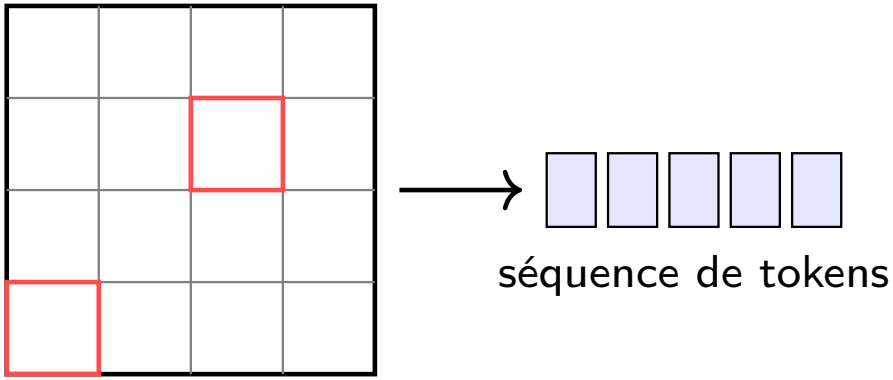

Tokenisation d'image
Image $X \in \mathbb{R}^{H \times W \times C}$ découpée en patches $P \times P$.
Nombre de tokens : $N = \frac{HW}{P^2}$.
Chaque patch est aplati et projeté :
$z_i = E\, x_i + e_i^{\text{pos}}, \quad z_i \in \mathbb{R}^D$.
On traite ensuite $(z_1, \ldots, z_N)$ comme une **séquence**.

Intuition : les patches jouent le rôle de "mots" visuels ; l'attention relie des régions éloignées.

Phase 3 — Auto-attention : mécanisme et coût

Role : Expliquer le calcul d'attention, son intérêt et son coût computationnel **Etape du projet :** Analyse SOTA / modélisation

Auto-attention

$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Q : requêtes, K : clés, V : valeurs.
Chaque token "regarde" tous les autres **(contexte global)**.

Limite de ViT

Complexité quadratique : $O(N^2)$ avec N tokens.
Pour grandes images médicales, N devient très élevé $\Rightarrow$ coût prohibitif.

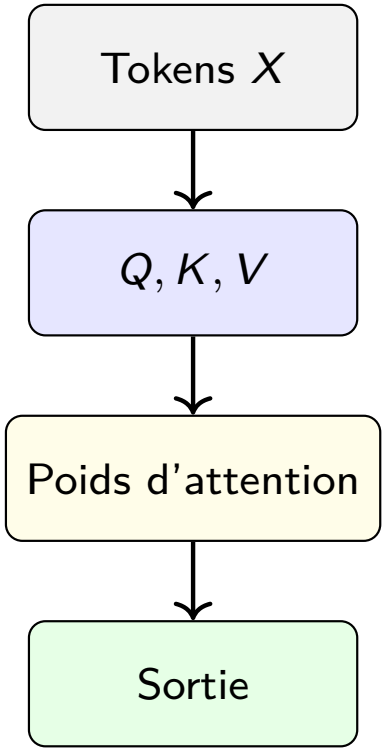

Phase 3 — Swin Transformer : fenêtres et décalage

Role : Montrer comment Swin conserve le contexte global tout en réduisant la complexité **Etape du projet :** Analyse SOTA / comparaison

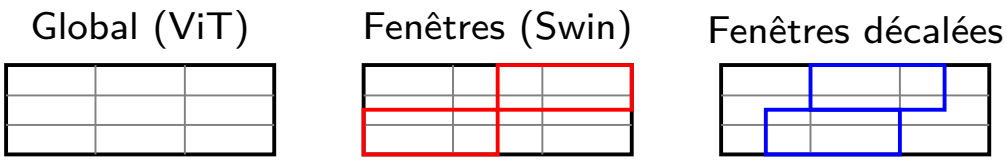

Attention par fenêtres
Swin limite l'attention à des fenêtres $M \times M$:
complexité
$O\left(\frac{HW}{M^2} \cdot M^4\right) = O(HW\,M^2)$,
au lieu de $O(N^2)$ global.
Le **décalage** des fenêtres connecte les régions voisines.

Intérêt médical
Capte des relations à longue distance tout en restant scalable.
Meilleure adaptation aux images haute résolution (radiographies).
Permet de relier des patterns subtils répartis dans l'image.

Phase 3 — ViT/Swin : ce que fait le modèle

Role : Relier Transformers et radiographie thoracique en termes de bénéfices et de limites **Etape du projet :** Analyse SOTA / pertinence applicative

Mécanisme effectif
Chaque patch devient un token ; l'attention calcule l'importance **entre régions**.

$$a_{ij} = \mathrm{softmax}\left(\frac{q_i k_j}{\sqrt{d}}\right), \quad \tilde{z}_i = \sum_j a_{ij} v_j$$

Le modèle combine ainsi **contexte global** et information locale.
Swin ajoute attention par **fenêtres** + **décalage**, puis **fusion de patches** (hiérarchie multi-échelle).

Aide en imagerie médicale
Relie des régions éloignées (symétrie pulmonaire, contexte global).
Utile pour motifs diffus et structures larges.
Swin reste efficace sur grandes images tout en gardant du détail.

Limites
Moins d'inductif bias que les CNN ⇒ besoin de pré-entraînement.
Patches trop grands ⇒ perte de lésions fines ; trop petits ⇒ coût élevé.
Attention peut suivre des corrélats non pathologiques.

Phase 4 — Grad-CAM : principe et formulation

Role : Définir l'outil d'explicabilité utilisé pour interpréter les prédictions **Etape du projet :** Analyse SOTA / évaluation interprétable

Idée

Grad-CAM met en évidence **où** le réseau "regarde" pour une classe donnée.
On utilise les gradients du score y^c par rapport aux cartes A^k.

Formules

Poids d'importance :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

Carte Grad-CAM :

$$L_{\text{Grad-CAM}}^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k\right)$$

Interprétation

A^k : carte de features de la dernière couche conv.
α_k^c : contribution de la carte k à la classe c.
ReLU conserve les contributions positives.
Le modèle donne **"quoi"**, Grad-CAM suggère **"où"**.

Phase 4 — Grad-CAM : schéma de génération

Role : Visualiser le pipeline complet de production d'une heatmap explicative **Etape du projet :** Analyse SOTA / évaluation interprétable

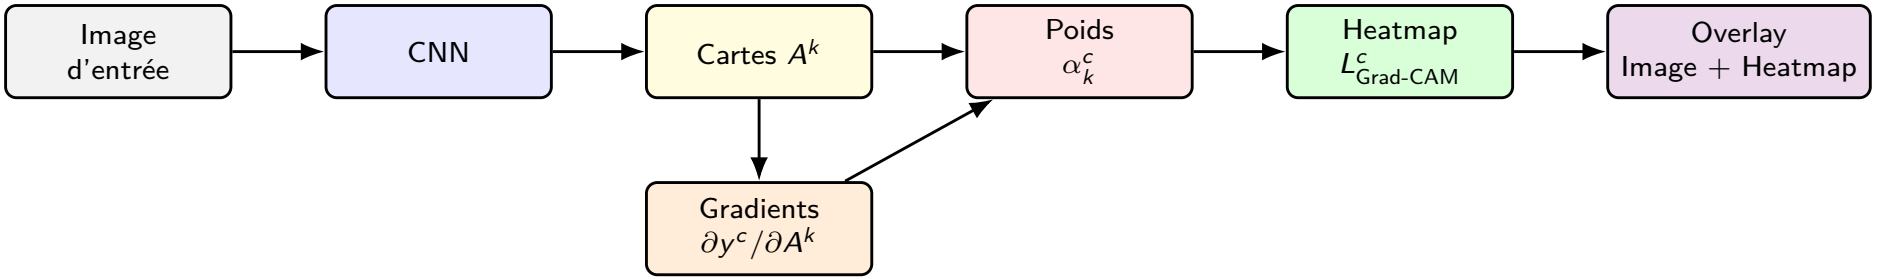

Lecture : l'overlay montre les régions activées associées à la classe prédite.

Phase 4 — Grad-CAM : ce que ça aide (et ce que ça n'aide pas)

Role : Préciser l'utilité clinique réelle de Grad-CAM et ses limites méthodologiques **Etape du projet :** Analyse SOTA / validation critique

Ce que Grad-CAM apporte

Explication **post-hoc** : montre quelles zones augmentent le score y^c.
Ne modifie pas la prédiction, mais **guide l'analyse** (triage, relecture).
Utile pour repérer des biais (texte, marqueurs, position).
Permet d'aligner le modèle avec l'expertise clinique.

Ce que Grad-CAM ne garantit pas

Carte **grossière** (résolution = stride de la dernière couche).
Importance $\neq$ causalité ; une heatmap "plausible" peut être trompeuse.
Sensibilité à la couche choisie, au prétraitement et au bruit.
Interprétabilité = aide, pas preuve diagnostique.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
5. Résultats et Finalisation

Solution proposée — *MedFusionNet* (concept)

Role : Présenter l'architecture cible qui sera effectivement développée **Etape du projet :** Conception de la solution

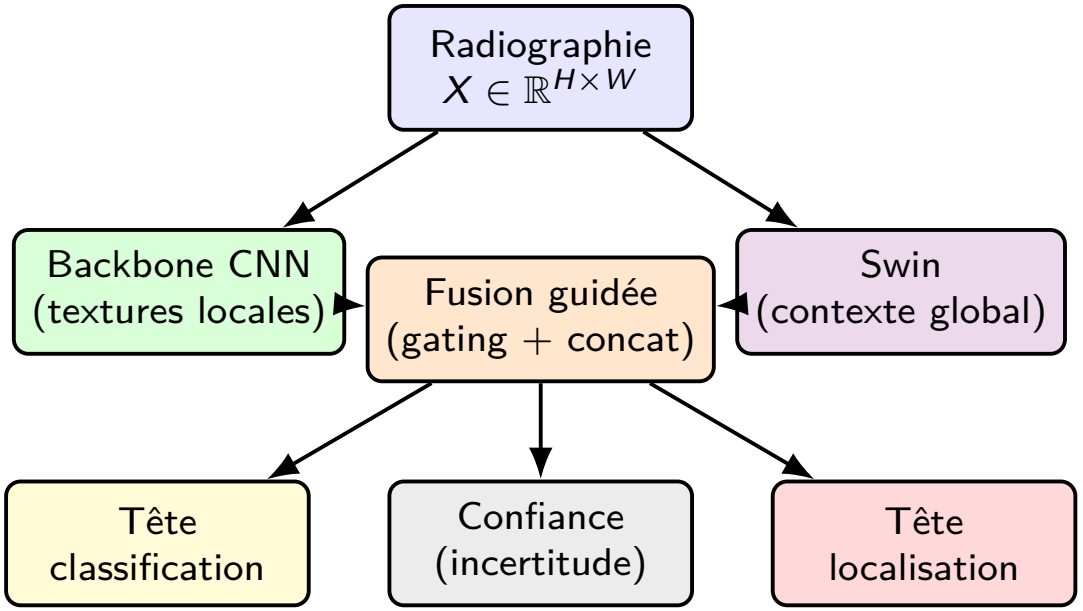

Idée clé
Combiner **textures locales** (CNN) et **contexte global** (Swin) pour éviter les faux positifs liés aux artefacts ou aux régions isolées.

Nouveauté proposée
Fusion **guidée** par un mécanisme de gating qui apprend **quand** faire confiance aux détails locaux vs au contexte global.

Solution proposée — Formulation mathématique

Role : Formaliser mathématiquement les blocs principaux et les sorties du modele proposé **Etape du projet :** Modélisation mathématique

Fusion guidée

Features CNN : $F_c \in \mathbb{R}^{H' \times W' \times C_c}$

Features Swin : $F_s \in \mathbb{R}^{H' \times W' \times C_s}$

Gating : $g = \sigma(W_g[\mathrm{GAP}(F_c), \mathrm{GAP}(F_s)])$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Classification : $p(y|X) = \sigma(w^\top \mathrm{GAP}(F))$

Localisation + confiance

Carte explicative :

$$L^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k\right)$$

Incertitude prédictive :

$u = \mathrm{Var_}t(p_t)$ (MC-Dropout)

Sortie finale : $(p,\ L^c,\ u)$

Solution proposée — Pipeline complet (étape par étape)

Role : Dérouler la chaîne complète d'exécution du modèle de l'entrée jusqu'aux sorties **Etape du projet :** Conception détaillée

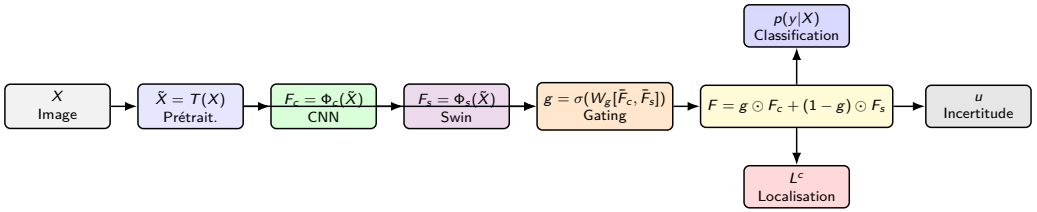

Étapes mathématiques

1) Prétraitement : $\tilde{X} = T(X)$ (normalisation, redimensionnement).
2) Extraction locale : $F_c = \Phi_c(\tilde{X})$.
3) Contexte global : $F_s = \Phi_s(\tilde{X})$.
4) Gating : $g = \sigma(W_g[\mathrm{GAP}(F_c), \mathrm{GAP}(F_s)])$.
5) Fusion : $F = g \odot F_c + (1-g) \odot F_s$.
6) Classification : $p(y|X) = \sigma(w^\top \mathrm{GAP}(F))$.
7) Localisation : $L^c = \mathrm{ReLU}(\sum_k \alpha_k^c A^k)$.
8) Incertitude : $u = \mathrm{Var}_t(p_t)$ (MC-Dropout).

Apprentissage

$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{loc} + \lambda_2 \mathcal{L}_{cons} + \lambda_3 \mathcal{L}_{cal}$

Optimise précision, robustesse et calibration.

Solution proposée — Apprentissage et robustesse

Role : Définir la fonction objectif, la robustesse et les garde-fous d'entraînement **Etape du projet :** Développement / entraînement

Objectif global

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{loc} + \lambda_2 \mathcal{L}_{cons} + \lambda_3 \mathcal{L}_{cal}$$

$\mathcal{L}_{cls}$: BCE ou Focal (déséquilibre classes).
$\mathcal{L}_{loc}$: cohérence entre L^c et zones plausibles (pseudo-masques).
$\mathcal{L}_{cons}$: invariance aux augmentations (robustesse).
$\mathcal{L}_{cal}$: calibration (température / ECE).

Pourquoi c'est utile

Réduit les faux positifs dus aux artefacts.
Renforce la généralisation inter-hopitaux.
Donne un score + une carte + une confiance.

Limites résiduelles

Dépendance à la qualité des données.
Risque de biais systématiques.
Doit être validé cliniquement.

Solution proposée — Impact clinique attendu

Role : Montrer à quoi sert la solution proposée dans un usage réel de lecture radiologique **Etape du projet :** Validation métier / déploiement

Bénéfices
Triage rapide : prioriser les examens à haut risque.
Explicabilité intégrée : aide la lecture et la relecture.
Confiance mesurée : alerte en cas d'incertitude élevée.
Adapté aux contraintes de déploiement réel.

Ce que la solution fait
Elle combine deux vues du même signal :
- **local** (signes fins, bords, textures)
- **global** (distribution pulmonaire, symétrie)
Puis elle décide avec un **contrôle de confiance**.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
5. Résultats et Finalisation

Résultats obtenus

Role : Présenter les indicateurs de performance et leur interprétation métier | **Etape du projet :** Évaluation finale

Métriques de Performance

- **Précision (Accuracy) :** $\approx 92\%$
- **Sensibilité (Recall) :** 94%
- **AUC-ROC :** 0.96

- Réduction significative des faux négatifs.
- Génération de **Grad-CAM** fonctionnelle pour valider les zones d'intérêt.

Mots clés

Role : Synthétiser les thèmes techniques majeurs couverts par le document **Etape du projet :** Clôture documentaire

Intelligence Artificielle

Deep Learning

Vision par Ordinateur

Radiographie Thoracique (CXR)

Pneumonie

CNN / Transformers

Transfer Learning

Interprétabilité (Grad-CAM)

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit	**Etape du projet :** Navigation / structuration

6 Annexes
- Références techniques

Annexe A — Convolution, stride et pooling

Role : Définir les opérations de base des CNN utilisées dans les architectures étudiées **Etape du projet :** Annexe technique

Definitions

Convolution $k \times k$: Filtre local glissant sur l'image ou sur une carte de features.

Stride s : Pas de déplacement du filtre ; quand s augmente, la résolution baisse plus vite.

Padding : Bordure ajoutée pour contrôler la taille de sortie.

MaxPool : Conserve la plus forte activation dans une fenêtre locale.

AvgPool : Remplace une fenêtre locale par sa moyenne.

Formules utiles

$$Y_{i,j,c'} = \sum_{u,v,c} W_{u,v,c,c'} X_{i+u,j+v,c} + b_{c'}$$

$$H_{out} = \left\lfloor \frac{H + 2p - k}{s} \right\rfloor + 1$$

Intuition

Les convolutions extraient des motifs locaux. Le pooling résume l'information et réduit la taille spatiale pour rendre le calcul plus efficace.

Annexe B — BN, ReLU, bottleneck et connexions

Role : Clarifier les briques de stabilisation et d'efficacité citées dans DenseNet et EfficientNet **Etape du projet :** Annexe technique

Stabilisation

BN : Normalise les activations d'un mini-batch pour stabiliser et accélérer l'entraînement.

ReLU : Garde les valeurs positives et annule les négatives, ce qui introduit une non-linéarité simple.

Skip connection : Réinjecte une information plus tôt dans le réseau pour faciliter le gradient.

Efficacité

Bottleneck : Réduit les canaux avant une opération coûteuse, puis projette de nouveau si besoin.

Growth rate k : Nombre de nouveaux canaux ajoutés par chaque couche dense.

SE : Mécanisme qui ré-pondère les canaux selon leur importance.

Fused-MBConv : Version simplifiée de MBConv, souvent plus rapide à entraîner sur GPU dans les premiers étages.

Annexe C — DenseNet et MBConv

Role : Reprendre proprement les blocs spécifiques les plus utilisés dans l'analyse SOTA **Etape du projet :** Annexe technique

Bloc dense

DenseNet concatène les sorties précédentes au lieu de simplement les additionner.

$$x_\ell = H_\ell([x_0, \ldots, x_{\ell-1}])$$

Cela favorise la réutilisation des features et un meilleur flux de gradient.

MBConv

MBConv combine :

- une expansion 1×1,
- une convolution depthwise,
- un module SE,
- une projection finale 1×1.

L'objectif est d'obtenir une bonne expressivité à coût réduit.

Annexe D — Vocabulaire Transformer

Role : Définir les notions de patchs, tokens et embeddings utilisées dans ViT et Swin **Etape du projet :** Annexe technique

Definitions

Patch : Sous-image locale de taille $P \times P$.

Token : Vecteur obtenu après projection d'un patch.

Embedding : Représentation vectorielle dense envoyée dans le Transformer.

Encodage positionnel : Information ajoutée pour conserver l'ordre spatial des patches.

Formule de tokenisation

$$N = \frac{HW}{P^2}, \qquad z_i = E\,x_i + e_i^{pos}$$

Intuition

Le Transformer traite l'image comme une séquence de morceaux visuels, de la même façon qu'un modèle de langage traite une phrase comme une séquence de mots.

Annexe E — Attention et Swin

Role : Détailler le calcul d'attention et la logique des fenêtres décalées de Swin **Etape du projet :** Annexe technique

Attention

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Q : Ce que le token courant cherche.

K : Ce que les autres tokens proposent pour être reliés à lui.

V : L'information qui sera effectivement transmise.

Pourquoi Swin

Fenêtre : Sous-ensemble local de tokens traité ensemble.

Fenêtres décalées : Décalage d'une couche à la suivante pour reconnecter des zones voisines.

Bénéfice : Réduire le coût du contexte global tout en conservant des interactions spatiales utiles.

Complexité

L'attention globale est quadratique en nombre de tokens. Swin réduit ce coût en limitant l'attention à des fenêtres locales.

Annexe F — Entraînement complémentaire

Role : Définir les notions d'entraînement mentionnées sans détail dans la solution proposée **Etape du projet :** Annexe technique

Concepts de base

Transfer learning : Réutiliser un modèle pré-entraîné puis l'adapter à la radiographie thoracique.

Augmentation : Modifier l'image pendant l'entraînement pour rendre le modèle plus robuste.

Pseudo-masque : Zone approximative utilisée comme supervision faible quand on n'a pas d'annotation pixel exacte.

Logit : Score brut avant application de la sigmoïde ou du softmax.

Pourquoi c'est utile

Ces mécanismes servent à :

- mieux généraliser,
- réduire la dépendance à un seul centre hospitalier,
- exploiter des annotations incomplètes,
- stabiliser l'apprentissage quand les données sont déséquilibrées.

Annexe G — Pertes et calibration

Role : Définir les fonctions objectif et la notion de confiance calibrée | **Etape du projet :** Annexe technique

Fonctions de perte

BCE : Binary Cross-Entropy, perte standard de classification binaire.

Focal loss : Version de BCE qui met davantage l'accent sur les exemples difficiles ou rares.

$\mathcal{L}_{cons}$: Impose des sorties proches pour deux vues augmentées d'une même image.

$\mathcal{L}_{loc}$: Contraint la carte explicative à rester cohérente avec une zone plausible.

Calibration

Calibration : Une probabilité 0.8 devrait correspondre à environ 80% de prédictions correctes.

Temperature scaling : Correction post-hoc des logits par un scalaire de température.

ECE : Mesure l'écart entre confiance moyenne et précision réelle.

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{n} \left|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\right|$$

$$\mathcal{L}_{BCE} = -(y \log p + (1-y)\log(1-p))$$

Annexe H — Fusion, explicabilité et incertitude

Role : Documenter les sorties avancées de la solution proposée	**Etape du projet :** Annexe technique

Fusion et gating

Le gating apprend le poids relatif des branches locale et globale.

$$g = \sigma(W_g[\mathrm{GAP}(F_c), \mathrm{GAP}(F_s)])$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si g est grand, la branche CNN domine ; sinon la branche Swin domine.

Explicabilité et confiance

Grad-CAM : Carte visuelle des zones qui contribuent positivement au score choisi.

MC-Dropout : Plusieurs passes avec dropout actif à l'inférence pour estimer l'incertitude.

Variance prédictive : Plus elle est grande, moins la décision est fiable.

$$u = \mathrm{Var}_t(p_t)$$

Annexe I — Metriques d'evaluation

Role : Définir précisément les mesures de performance et leur lecture clinique **Etape du projet :** Annexe technique

Definitions

Accuracy : Proportion totale de prédictions correctes.

Recall / Sensibilité : Capacité à retrouver les cas positifs.

Spécificité : Capacité à rejeter les cas négatifs.

AUC-ROC : Qualité de séparation entre classes quand on fait varier le seuil.

Faux positif : Cas sain déclaré malade.

Faux négatif : Cas malade déclaré sain.

Formules

$$\text{Recall} = \frac{TP}{TP+FN}, \qquad \text{Specificite} = \frac{TN}{TN+FP}$$

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Lecture en contexte médical

En dépistage de pneumonie, réduire les faux négatifs est souvent prioritaire : manquer un cas pathologique est généralement plus grave que sur-appeler un cas douteux.