Présentation PFA: Détection de pneumonie sur radiographie

Conception, Modélisation et Développement.

HANFAOUI Karim[1] KAFIF. Imane[2]

[1]EMSI, 4ème Année IADO G2 - Karim.Hanfaoui@emsi-edu.ma
[2]EMSI, 4ème Année IADO G2 - Imane.Kafif@emsi-edu.ma

EMSI Les Orangers, Mars 2026

Table des Matières

Role : Présenter la structure complète du rapport et l'ordre des étapes **Etape du projet :** Navigation / cadrage global

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
   - Pipeline détaillé
5. Résultats et Finalisation

Table des figures

Role : Référencer automatiquement toutes les figures du document **Etape du projet :** Navigation / repérage documentaire

Figure 1. Vue d'ensemble du pipeline complet 28
Figure 2. Échantillon brut provenant du dataset 29
Figure 3. Image après normalisation et redimensionnement 30
Figure 4. Représentation locale extraite par la branche CNN 31
Figure 5. Représentation globale extraite par la branche Swin 32
Figure 6. Fusion adaptative entre la branche locale et la branche globale 33
Figure 7. Passage de la représentation fusionnée au score de classe 34
Figure 8. Heatmap explicative et estimation d'incertitude 35
Figure 9. Schéma de la perte totale et de ses composantes 36
Figure 10. Sortie finale utilisable par le clinicien 37

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
   - Pipeline détaillé
5. Résultats et Finalisation

Acronymes — Domaine et modèles

Role : Donner les sigles du domaine avant les slides techniques | **Etape du projet :** Référence documentaire

Domaine médical et IA

IA : Intelligence Artificielle.

DL : Deep Learning, famille de modèles à plusieurs couches.

CXR : Chest X-Ray, radiographie thoracique.

SOTA : State Of The Art, meilleur niveau connu au moment de l'étude.

Modèles et approches

CNN : Convolutional Neural Network, réseau fondé sur les convolutions.

ViT : Vision Transformer, adaptation du Transformer aux images.

Swin : Shifted Window Transformer, Transformer hiérarchique à fenêtres décalées.

Grad-CAM : Gradient-weighted Class Activation Mapping, outil d'explicabilité visuelle.

Acronymes — Blocs techniques

Role : Définir les sigles techniques utilisés dans les architectures et l'évaluation **Etape du projet :** Référence documentaire

Architecture

BN : Batch Normalization, normalisation des activations sur un mini-batch.

ReLU : Rectified Linear Unit, activation $f(x) = \max(0, x)$.

GAP : Global Average Pooling, moyenne spatiale par canal.

FC : Fully Connected, couche dense finale de décision.

Efficacité et confiance

MBConv : Mobile Inverted Bottleneck Convolution, bloc compact d'EfficientNet.

SE : Squeeze-and-Excitation, mécanisme de ré-pondération des canaux.

FLOPs : Floating Point Operations, estimation du coût de calcul.

ECE : Expected Calibration Error, mesure de calibration des probabilités.

Notations mathématiques

Role : Définir les notations qui reviennent dans les équations et les schémas **Etape du projet :** Référence documentaire

Tailles et dimensions

H, W : Hauteur et largeur spatiales d'une image ou d'une carte de features.

C : Nombre de canaux.

L : Nombre de couches ou de blocs, selon le contexte.

k : Growth rate DenseNet, nombre de nouveaux canaux ajoutés par couche.

Variables de modélisation

ϕ : Facteur global de scaling dans EfficientNet.

X : Image d'entrée.

F : Tensor de features appris par le modèle.

$p(y|X)$: Probabilité prédite pour une classe y conditionnée par l'image X.

Terminologie d'architecture

Role : Définir les termes techniques utilisés sans alourdir les slides principales **Etape du projet :** Référence documentaire

CNN et représentations

Feature map : Carte d'activation produite par un bloc du réseau.

Backbone : Extracteur principal de représentations d'une architecture.

Bottleneck : Réduction intermédiaire des canaux pour baisser le coût.

Skip connection : Chemin de contournement transmettant une information plus tôt dans le réseau.

Transformers et fiabilité

Token : Unité d'entrée d'un Transformer, ici un patch projeté.

Embedding : Représentation vectorielle dense d'un objet discret ou local.

Calibration : Adéquation entre probabilité annoncée et fréquence réelle de succès.

Heatmap : Carte colorée montrant des zones activées ou importantes pour la décision.

Guide de lecture du document

Role : Préciser le rôle exact de chaque groupe de slides dans la fabrication du projet **Etape du projet :** Lecture guidée du rapport

Cadrage

Problématique / Méthodologie : Définir le besoin clinique, la question scientifique et l'organisation du travail.

Analyse SOTA : Comparer les approches existantes avant de choisir une direction.

Conception

Solution proposée : Définir l'architecture cible, sa logique et ses sorties.

Validation

Résultats : Mesurer la performance finale et lire les indicateurs.

Annexes : Documenter les notions techniques non développées dans le flux principal.

Principe de lecture

Chaque slide technique indique explicitement :

- son **role** dans le document,
- l'**etape du projet** à laquelle il appartient.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
   - Pipeline détaillé
5. Résultats et Finalisation

Problématique

Role : Poser le besoin clinique, la question de recherche et la contrainte d'explicabilité **Etape du projet :** Cadrage scientifique

Question Centrale de Recherche

Face à la complexité visuelle des pathologies pulmonaires et à la pénurie mondiale de radiologues experts, comment pouvons-nous concevoir un système automatisé basé sur le Deep Learning capable non seulement de détecter la pneumonie avec une précision clinique supérieure à l'interprétation humaine, mais aussi de fournir une justification visuelle explicable afin de garantir une intégration sécurisée et fiable dans le flux de travail médical d'urgence ?

Méthodologie : Approche Agile (Scrum)

Role : Montrer comment le projet est découpé en phases de travail et d'itération **Etape du projet :** Organisation / planification

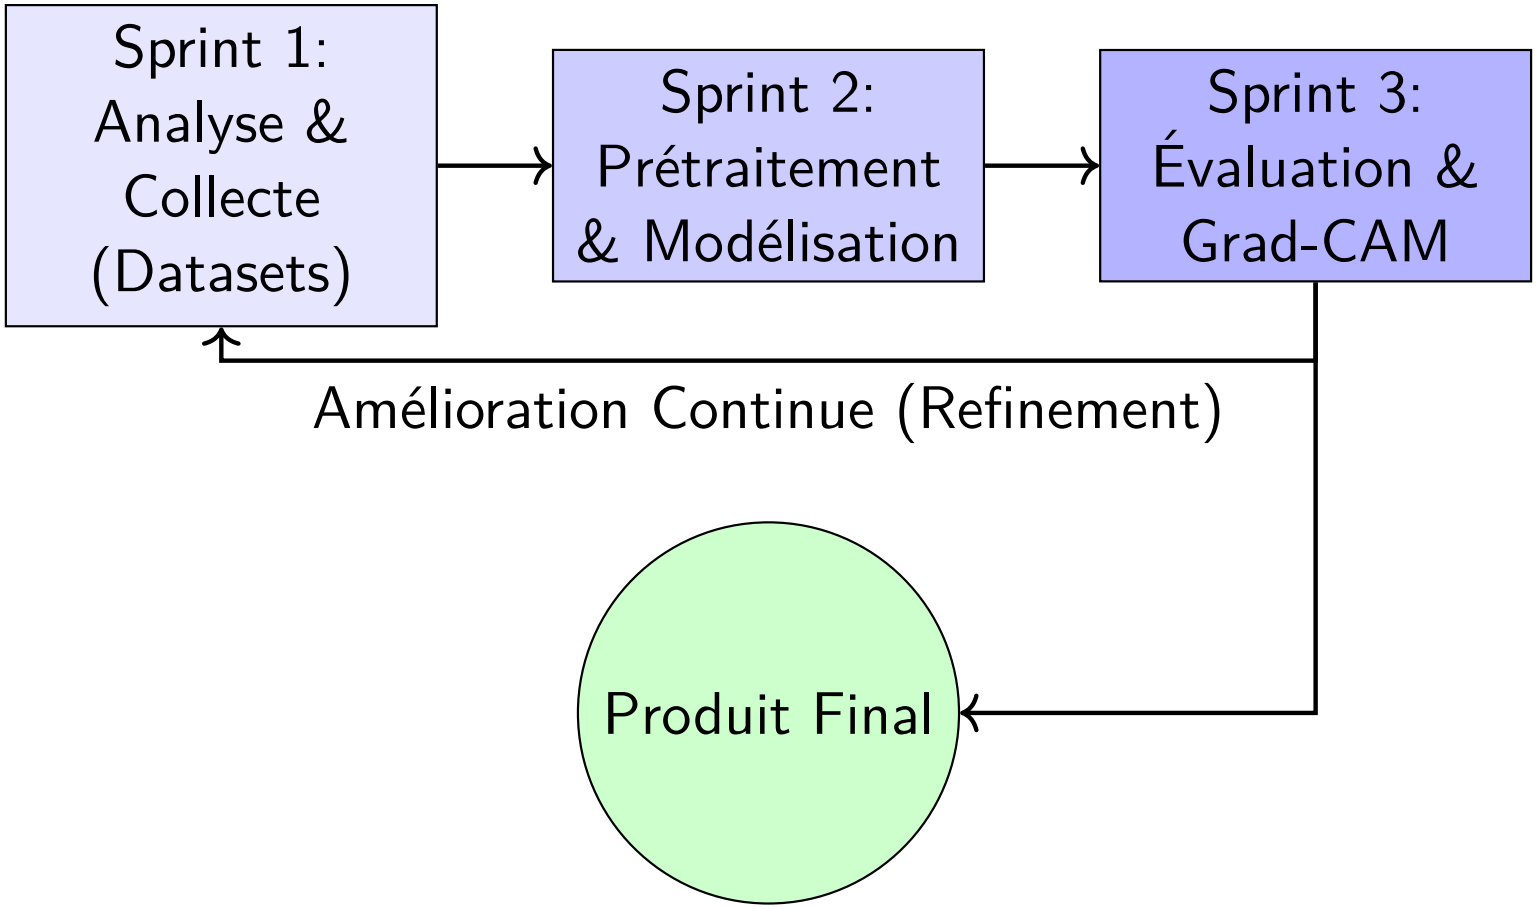

- **Flexibilité :** Adaptation aux contraintes des données médicales.
- **Itérations :** Optimisation progressive des hyperparamètres.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
   - Pipeline détaillé
5. Résultats et Finalisation

SOTA : Architecture DenseNet-121

Role : Présenter le modele CNN de référence utilisé comme base de comparaison **Etape du projet :** Analyse SOTA / comparaison

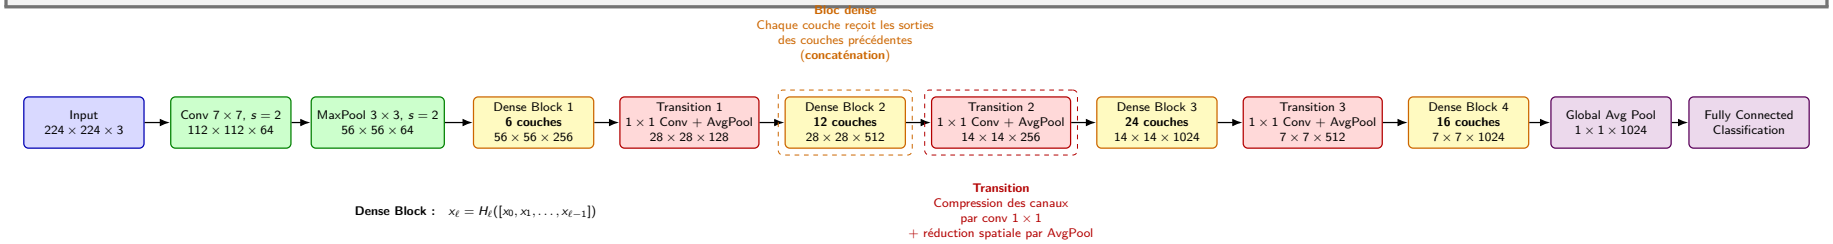

Dense Block
Concaténation de toutes les cartes précédentes :
$x_\ell = H_\ell([x_0, x_1, \ldots, x_{\ell-1}])$
Réutilisation des features + meilleur flux de gradient.
Croissance des canaux : $C_{\text{out}} = C_0 + L \cdot k$.
Exemple : $k = 32$, $L = 6 \Rightarrow C_{\text{out}} = C_0 + 192$.
Où C_0 = canaux initiaux, L = nb de couches, k = growth rate.

Transition
Entre blocs denses, compresse et réduit.
$X \in \mathbb{R}^{H \times W \times C}$
$\rightarrow \text{Conv}_{1\times1}(X) = Y \in \mathbb{R}^{H \times W \times C'}$
$Y_{h,w,c'} = \sum_c W_{c',c} X_{h,w,c} + b_{c'}$
$\rightarrow \text{AvgPool}(Y) = Z \in \mathbb{R}^{H/2 \times W/2 \times C'}$
$Z_{i,j,c'} = \frac{1}{4} \sum_{u,v \in \{0,1\}} Y_{2i+u,2j+v,c'}$
Compression, efficacité, préparation du bloc suivant.
Où H, W = hauteur/largeur, C = canaux, C' = canaux compressés.

Stem / Entrée
Entrée $224 \times 224 \times 3$.
Conv 7×7 ($s = 2$) puis MaxPool 3×3 ($s = 2$).
Extrait des bords/textures et réduit tôt la résolution.
Exemple : $224 \times 224 \rightarrow 112 \times 112 \rightarrow 56 \times 56$.
Où H, W = dimensions spatiales, s = stride.

Tête de classification
Global Avg Pooling : moyenne spatiale par canal.
$7 \times 7 \times 1024 \rightarrow 1 \times 1 \times 1024$.
$g_c = \frac{1}{HW} \sum_{h,w} F_{h,w,c}$, puis FC.
Exemple : $g \in \mathbb{R}^{1024} \rightarrow$ scores $\in \mathbb{R}^K$.
Où F = carte de features, g = vecteur global, K = nb de classes.

DenseNet-121 : Structure d'une couche dense

Role : Expliquer le calcul interne d'une couche dense pour comprendre le baseline choisi **Etape du projet :** Analyse SOTA / compréhension mécanistique

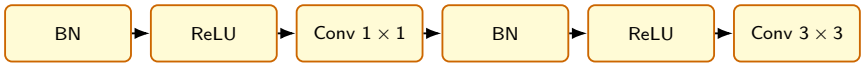

Séquence : BN $\rightarrow$ ReLU $\rightarrow$ Conv 1×1 $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ Conv 3×3

Transformation H_ℓ
H_ℓ est la transformation appliquée par la couche ℓ dans un bloc dense ; elle produit de **nouvelles** cartes de features.
Formule :
$H_\ell(x) = \mathrm{Conv}_{3\times3}\big(\mathrm{ReLU}(\mathrm{BN}(\mathrm{Conv}_{1\times1}(\mathrm{ReLU}(\mathrm{BN}(x))))))\big)$
Si $x = [x_0, x_1, \ldots, x_{\ell-1}]$, alors $x_\ell = H_\ell(x)$.
Interprétation : 1×1 = mélange/réduction des canaux (bottleneck),
3×3 = extraction spatiale locale, BN+ReLU = stabilité + non-linéarité.
Croissance : la couche ajoute k canaux :
$C_{\text{out}} = C_{\text{in}} + k$.
Après L couches : $C_{\text{out}} = C_0 + Lk$.
Où C_{in} = canaux d'entrée, C_0 = canaux initiaux, k = growth rate.

Phase 2 — EfficientNet : idée générale et scaling

Role : Comparer une stratégie d'optimisation du coût de calcul par scaling équilibré **Etape du projet :** Analyse SOTA / comparaison

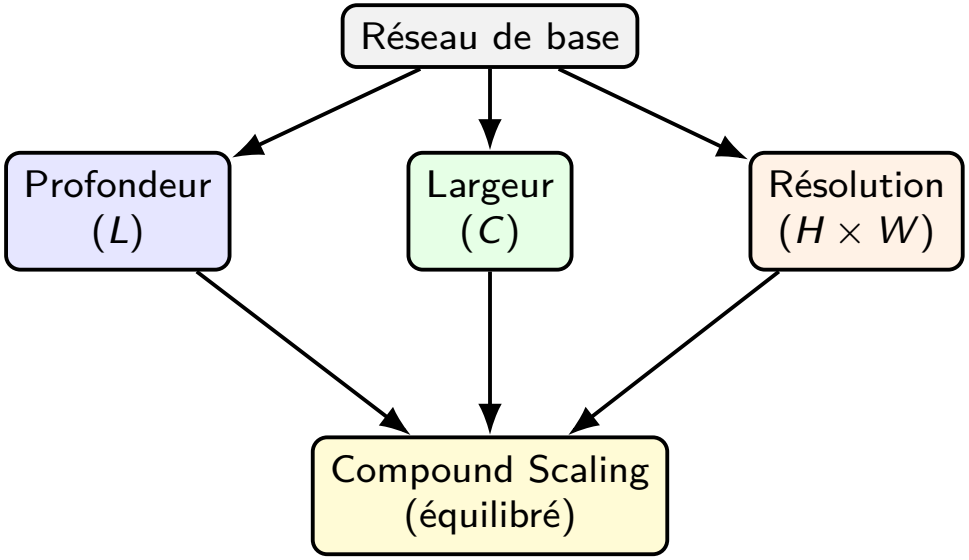

Idée centrale
EfficientNet est une famille de CNN conçue pour **mieux exploiter** un budget de calcul donné.
Le **scaling naïf** (uniquement profondeur, largeur ou résolution) crée un déséquilibre :
trop profond $\Rightarrow$ gradient fragile,
trop large $\Rightarrow$ surcoût mémoire,
trop haute résolution $\Rightarrow$ coût quadratique.

Compound Scaling
On augmente **ensemble** profondeur, largeur et résolution par un facteur global ϕ pour rester efficace.

$$d = \alpha^{\phi}, \quad w = \beta^{\phi}, \quad r = \gamma^{\phi},$$
$$\alpha\,\beta^2\,\gamma^2 \approx 2$$

ϕ contrôle l'échelle globale ; la contrainte équilibre coût et performance.

Phase 2 — MBConv : bloc clé d'EfficientNet

Role : Détailler le bloc opératoire central qui rend EfficientNet efficace **Etape du projet :** Analyse SOTA / modélisation d'un bloc

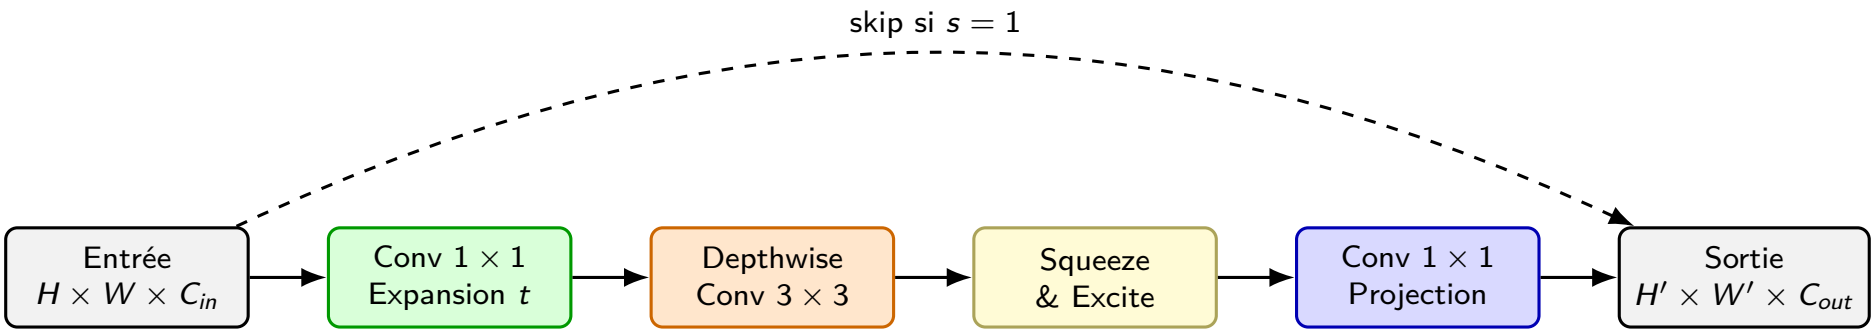

Depthwise Convolution
Chaque canal est filtré séparément :
$Y_{h,w,c} = \sum_{i,j} K_{i,j}^{(c)} X_{h+i,w+j,c}$
Coût paramétrique : $k^2 C$
au lieu de $k^2 CC'$ (conv standard).
Réduit fortement les paramètres et FLOPs.

MBConv en pratique
1) Expansion
$C_e = t \cdot C_{in}$,
2) Depthwise 3×3,
3) SE (ré-pondération canal),
4) Projection vers C_{out},
5) Skip si stride $s = 1$
et dimensions
compatibles.
Objectif :
expressivité élevée
avec coût réduit.

Phase 2 — EfficientNetV2 et impact médical

Role : Montrer l'évolution d'EfficientNet vers une version plus rapide à entraîner et à déployer **Etape du projet :** Analyse SOTA / comparaison

EfficientNetV2 : améliorations
Optimise l'entraînement (plus rapide et stable) via :
- **Fused-MBConv** sur les petits étages (meilleur débit GPU),
- règles de scaling adaptées,
- stratégies de régularisation plus efficaces.

Résultat : **meilleure précision** à coût d'entraînement réduit.

Intérêt en imagerie médicale
Meilleur compromis précision/temps :
- utile pour stations avec GPU limités,
- facilite l'expérimentation rapide,
- déploiement clinique plus réaliste.

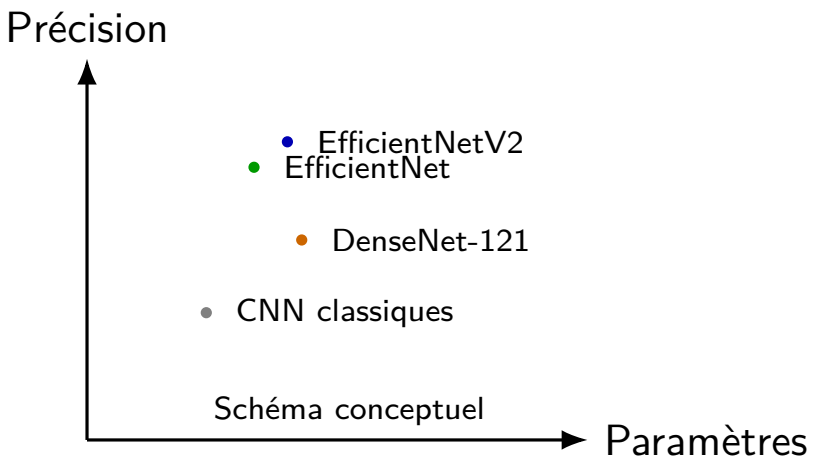

Phase 2 — EfficientNet : ce que fait le modèle

Role : Relier le mécanisme d'EfficientNet aux besoins pratiques de la détection sur CXR **Etape du projet :** Analyse SOTA / pertinence applicative

Mécanisme effectif

Le réseau apprend une fonction f_θ qui transforme X en **cartes hiérarchiques** (bords, textures, motifs complexes).

Les blocs MBConv alternent **mixage de canaux** (1×1), **filtrage spatial local** (depthwise) et **ré-pondération** (SE).

Après agrégation globale :

$$z = \mathrm{GAP}(F_L(X)), \quad p(y|X) = \sigma(w^\top z)$$

Le scaling compound règle **profondeur/largeur/résolution** pour préserver détail et contexte.

Aide en imagerie médicale

Capte des patterns **multi-échelles** (opacités diffuses, consolidations).

Bon compromis précision/coût $\Rightarrow$ utile en contexte GPU limité.

Permet d'exploiter des images haute résolution sans explosion de paramètres.

Limites et risques

Downsampling peut effacer des signes **très fins**.

Sensibilité aux biais (texte, position, appareil, contraste).

Pas de localisation directe : nécessite un outil d'explicabilité.

Phase 3 — ViT : patches et tokens

Role : Introduire la représentation en patches qui remplace la grille convolutive classique **Etape du projet :** Analyse SOTA / comparaison

Image → patches

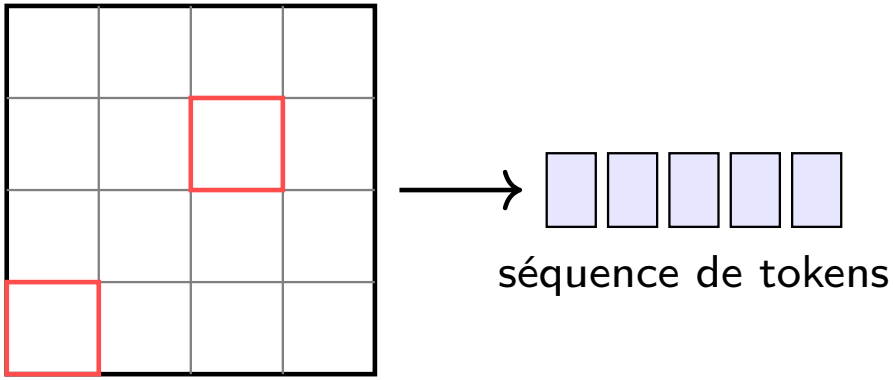

Tokenisation d'image
Image $X \in \mathbb{R}^{H \times W \times C}$ découpée en patches $P \times P$.
Nombre de tokens : $N = \frac{HW}{P^2}$.
Chaque patch est aplati et projeté :
$z_i = E\, x_i + e_i^{\text{pos}}, \quad z_i \in \mathbb{R}^D$.
On traite ensuite $(z_1, \ldots, z_N)$ comme une **séquence**.

Intuition : les patches jouent le rôle de "mots" visuels ; l'attention relie des régions éloignées.

Phase 3 — Auto-attention : mécanisme et coût

Role : Expliquer le calcul d'attention, son intérêt et son coût computationnel **Etape du projet :** Analyse SOTA / modélisation

Auto-attention

$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Q : requêtes, K : clés, V : valeurs.
Chaque token "regarde" tous les autres **(contexte global)**.

Limite de ViT

Complexité quadratique : $O(N^2)$ avec N tokens.
Pour grandes images médicales, N devient très élevé $\Rightarrow$ coût prohibitif.

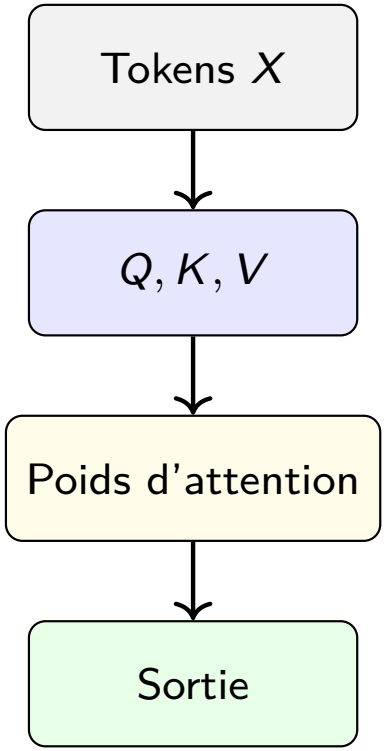

Phase 3 — Swin Transformer : fenêtres et décalage

Role : Montrer comment Swin conserve le contexte global tout en réduisant la complexité **Etape du projet :** Analyse SOTA / comparaison

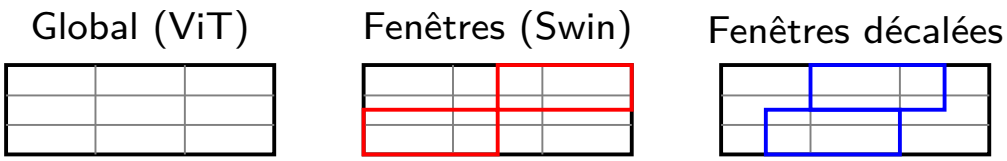

Attention par fenêtres
Swin limite l'attention à des fenêtres $M \times M$:
complexité
$O\left(\frac{HW}{M^2} \cdot M^4\right) = O(HW\,M^2)$,
au lieu de $O(N^2)$ global.
Le **décalage** des fenêtres connecte les régions voisines.

Intérêt médical
Capte des relations à longue distance tout en restant scalable.
Meilleure adaptation aux images haute résolution (radiographies).
Permet de relier des patterns subtils répartis dans l'image.

Phase 3 — ViT/Swin : ce que fait le modèle

Role : Relier Transformers et radiographie thoracique en termes de bénéfices et de limites **Etape du projet :** Analyse SOTA / pertinence applicative

Mécanisme effectif
Chaque patch devient un token ; l'attention calcule l'importance **entre régions**.

$$a_{ij} = \mathrm{softmax}\left(\frac{q_i k_j}{\sqrt{d}}\right), \quad \tilde{z}_i = \sum_j a_{ij} v_j$$

Le modèle combine ainsi **contexte global** et information locale.
Swin ajoute attention par **fenêtres** + **décalage**, puis **fusion de patches** (hiérarchie multi-échelle).

Aide en imagerie médicale
Relie des régions éloignées (symétrie pulmonaire, contexte global).
Utile pour motifs diffus et structures larges.
Swin reste efficace sur grandes images tout en gardant du détail.

Limites
Moins d'inductif bias que les CNN ⇒ besoin de pré-entraînement.
Patches trop grands ⇒ perte de lésions fines ; trop petits ⇒ coût élevé.
Attention peut suivre des corrélats non pathologiques.

Phase 4 — Grad-CAM : principe et formulation

Role : Définir l'outil d'explicabilité utilisé pour interpréter les prédictions **Etape du projet :** Analyse SOTA / évaluation interprétable

Idée

Grad-CAM met en évidence **où** le réseau "regarde" pour une classe donnée.
On utilise les gradients du score y^c par rapport aux cartes A^k.

Formules

Poids d'importance :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

Carte Grad-CAM :

$$L_{\text{Grad-CAM}}^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k\right)$$

Interprétation

A^k : carte de features de la dernière couche conv.
α_k^c : contribution de la carte k à la classe c.
ReLU conserve les contributions positives.
Le modèle donne **"quoi"**, Grad-CAM suggère **"où"**.

Phase 4 — Grad-CAM : schéma de génération

Role : Visualiser le pipeline complet de production d'une heatmap explicative **Etape du projet :** Analyse SOTA / évaluation interprétable

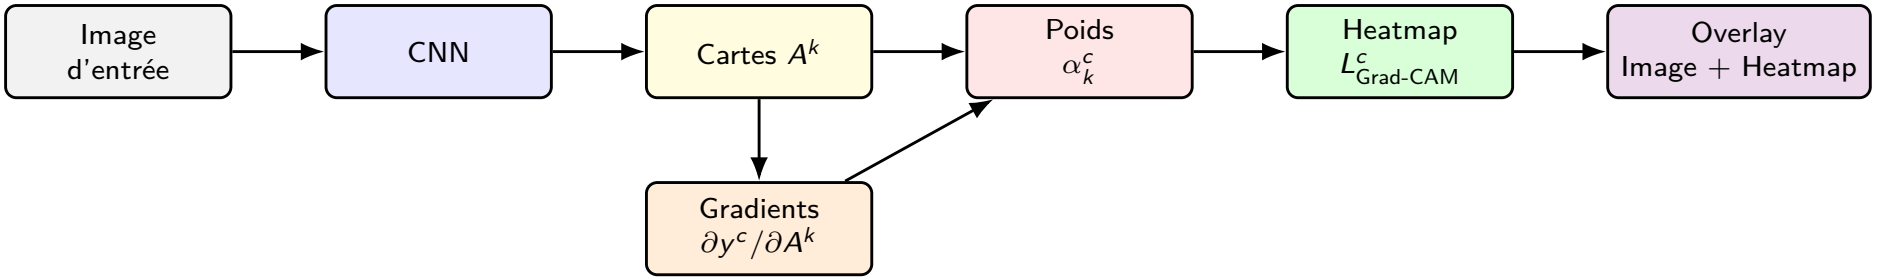

Lecture : l'overlay montre les régions activées associées à la classe prédite.

Phase 4 — Grad-CAM : ce que ça aide (et ce que ça n'aide pas)

Role : Préciser l'utilité clinique réelle de Grad-CAM et ses limites méthodologiques **Etape du projet :** Analyse SOTA / validation critique

Ce que Grad-CAM apporte

Explication **post-hoc** : montre quelles zones augmentent le score y^c.
Ne modifie pas la prédiction, mais **guide l'analyse** (triage, relecture).
Utile pour repérer des biais (texte, marqueurs, position).
Permet d'aligner le modèle avec l'expertise clinique.

Ce que Grad-CAM ne garantit pas

Carte **grossière** (résolution = stride de la dernière couche).
Importance $\neq$ causalité ; une heatmap "plausible" peut être trompeuse.
Sensibilité à la couche choisie, au prétraitement et au bruit.
Interprétabilité = aide, pas preuve diagnostique.

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
   - Pipeline détaillé
5. Résultats et Finalisation

Solution proposée — Étape 0 : vue d'ensemble

Role : Présenter la logique globale du modèle avant le détail des étapes **Etape du projet :** Conception de la solution

Principe et formule globale

MedFusionNet combine deux lectures d'une même radiographie :

- une branche **CNN** pour les indices locaux : contours, textures, petites opacités ;
- une branche **Swin** pour le contexte global : symétrie thoracique, bilatéralité, cohérence anatomique ;
- une **fusion guidée** qui pondère automatiquement les deux branches.

Chaîne mathématique.

$$\tilde{X} = T(X)$$

$$F_c = \Phi_c(\tilde{X}), \qquad F_s = \Phi_s(\tilde{X})$$

$$g = \sigma\Big(W_g[\mathrm{GAP}(F_c), \mathrm{GAP}(F_s)] + b_g\Big)$$

$$F = g \odot F_c + (1-g) \odot F_s$$

La sortie finale vérifie $\Psi(F) = (p, L^c, u)$: score p, heatmap L^c, incertitude u.

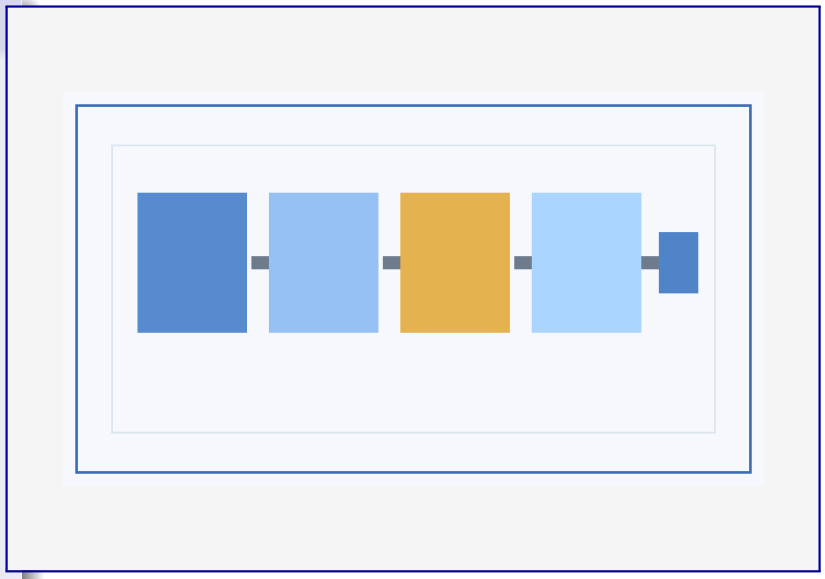

Figure 1: Vue d'ensemble du pipeline complet

Solution proposée — Étape 1 : échantillon d'entrée

Role : Définir la donnée d'entrée et ce qu'elle contient avant tout calcul | **Etape du projet :** Conception détaillée

Image et variabilité

Une radiographie thoracique est modélisée par :

$$X \in \mathbb{R}^{H \times W}$$

avec une étiquette binaire :

$$\begin{cases} y = 1 & \text{pneumonie} \\ y = 0 & \text{normal ou autre classe négative} \end{cases}$$

Pourquoi l'entrée est difficile. L'image brute contient à la fois le signal clinique et des facteurs parasites :

- variations d'intensité et de contraste selon l'appareil ;
- bruit, annotations, câbles et autres artefacts ;
- cadrage, résolution et structures normales parfois trompeuses.

Exemple : deux clichés de même classe peuvent avoir un contraste ou un centrage très différents ; le modèle doit ignorer cette variabilité non pathologique.

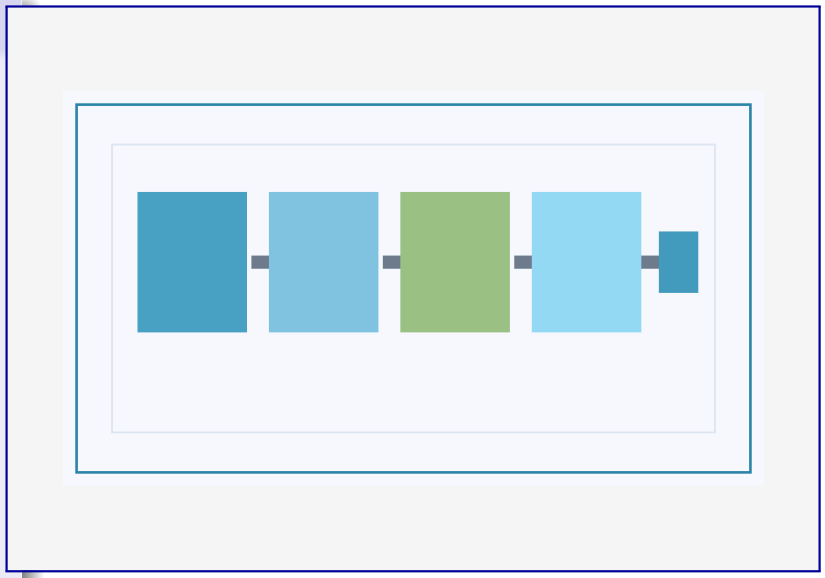

Figure 2: Échantillon brut provenant du dataset

Solution proposée — Étape 2 : prétraitement

Role : Standardiser l'image avant son entrée dans les deux branches du modèle **Etape du projet :** Développement / préparation des données

Transformation

Le prétraitement applique une chaîne de standardisation :

$$\tilde{X} = T(X) = A\Big(R(N(X))\Big)$$

où N normalise les intensités, R redimensionne et A peut améliorer localement le contraste.

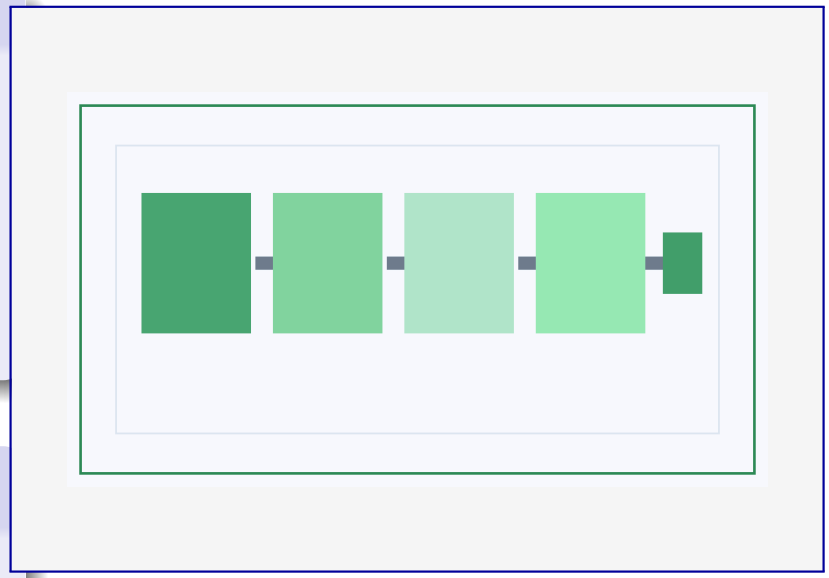

Figure 3: Image après normalisation et redimensionnement

Ce que la donnée devient

normalisation : $$X_{norm} = \frac{X - \mu}{\sigma}$$

redimensionnement : $$X \in \mathbb{R}^{H \times W} \longrightarrow \tilde{X} \in \mathbb{R}^{H_0 \times W_0}$$

Exemple : $1024 \times 1024 \rightarrow 384 \times 384$. Cette étape réduit le coût mémoire, homogénéise les entrées et diminue le risque que le modèle prenne une différence d'acquisition pour une pneumonie.

Solution proposée — Étape 3 : branche CNN locale

Role : Extraire les motifs fins et localisés par une lecture convolutive **Etape du projet :** Modélisation de la branche locale

Lecture locale par CNN

La branche locale produit :

$$F_c = \Phi_c(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_c}$$

Une convolution applique un filtre sur un voisinage restreint :

$$F^{(\ell)}_{i,j,c'} = \sum_{u,v,c} W^{(\ell)}_{u,v,c,c'} \, F^{(\ell-1)}_{i+u,j+v,c} + b^{(\ell)}_{c'}$$

Ce que la branche voit réellement.

- bords pleuraux, côtes, contours pulmonaires ;
- textures diffuses ou focales ;
- petites consolidations et opacités locales ;
- transitions fines entre tissu sain et tissu suspect.

Exemple : une opacité basale discrète peut être amplifiée par la comparaison locale entre intensités voisines.

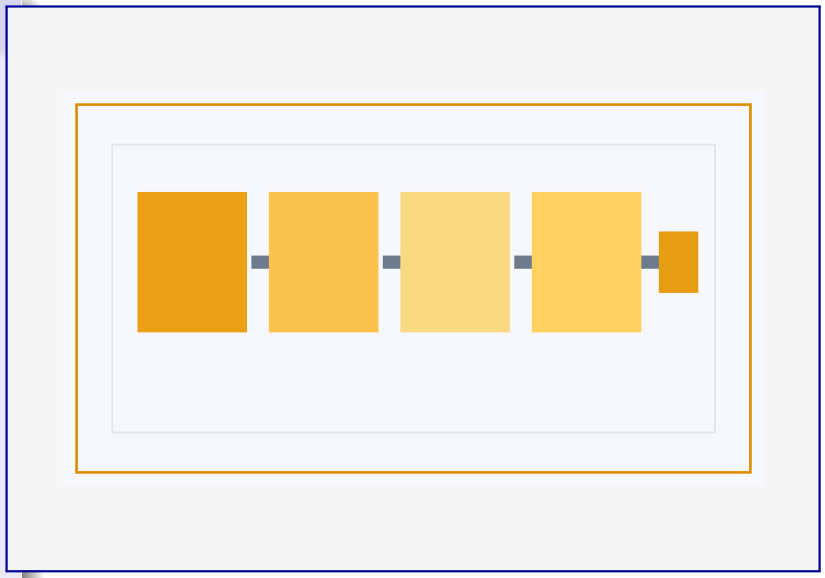

Figure 4: Représentation locale extraite par la branche CNN

Solution proposée — Étape 4 : branche Swin globale

Role : Extraire une représentation de contexte capable de relier des régions éloignées **Etape du projet :** Modélisation de la branche globale

Lecture globale par Swin

L'image prétraitée est découpée en patches puis projetée :

$$z_i = E\,x_i + e_i^{pos}$$

La branche globale calcule ensuite :

$$F_s = \Phi_s(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_s}$$

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Dans Swin, cette attention est calculée par fenêtres, puis les fenêtres sont décalées pour reconnecter les régions voisines. **Ce que la branche globale apporte.** Elle relie des zones éloignées : apex, bases, hémithorax droit/gauche, médiastin. Si une anomalie n'a de sens que par sa **distribution spatiale**, Swin la capture mieux qu'un CNN purement local.

Figure 5: Représentation globale extraite par la branche Swin

Solution proposée — Étape 5 : fusion guidée

Role : Combiner les indices locaux et globaux sans imposer un poids fixe à chaque branche **Etape du projet :** Conception du coeur de fusion

Porte de fusion et interprétation

On résume d'abord chaque branche par un vecteur global :

$$\bar{F}_c = \mathrm{GAP}(F_c), \qquad \bar{F}_s = \mathrm{GAP}(F_s)$$

Puis on apprend un coefficient de fusion :

$$g = \sigma\Big(W_g[\bar{F}_c, \bar{F}_s] + b_g\Big)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si $g \approx 1$, le modèle privilégie l'indice local ; si $g \approx 0$, il privilégie le contexte global. **Exemples. Exemple 1 :** foyer net et compact $\Rightarrow g \approx 0.8$.
Exemple 2 : atteinte diffuse ou bilatérale $\Rightarrow g \approx 0.3$.
La fusion n'est donc pas une moyenne fixe : elle s'adapte à la structure réelle de l'image.

Figure 6: Fusion adaptative entre la branche locale et la branche globale

Solution proposée — Étape 6 : classification

Role : Transformer la représentation fusionnée en probabilité de pneumonie | **Etape du projet :** Tête de décision

Score de classe

La représentation fusionnée est condensée en un vecteur :

$$z = \mathrm{GAP}(F)$$

puis convertie en probabilité :

$$p(y = 1|X) = \sigma(w^\top z + b)$$

Décision pratique

Avec un seuil τ :

$$\hat{y} = \begin{cases} 1 & \text{si } p(y = 1|X) \geq \tau \\ 0 & \text{sinon} \end{cases}$$

Exemple : si $p = 0.91$ et $\tau = 0.5$, la prédiction est positive avec une forte marge. Si $p = 0.54$, la décision reste positive mais devient fragile : elle doit être lue avec la heatmap et l'incertitude.

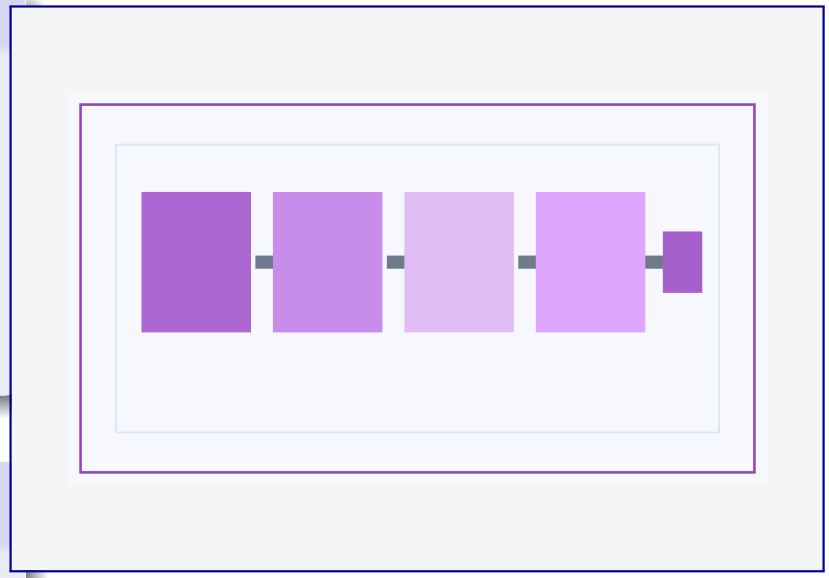

Figure 7: Passage de la représentation fusionnée au score de classe

Solution proposée — Étape 7 : localisation et incertitude

Role : Produire une explication spatiale et mesurer la fiabilité de la décision **Etape du projet :** Sorties interprétables

Localisation et incertitude

À partir des cartes finales A^k :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

$$L^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k \right)$$

La heatmap montre **où** le modèle a trouvé des indices pour la classe prédite. **Incertitude.** En répétant plusieurs passes avec dropout actif :

$$u = \mathrm{Var}_t(p_t)$$

Exemple : si $p_t = \{0.87, 0.88, 0.89\}$, la variance est faible ; si $p_t = \{0.42, 0.81, 0.57\}$, la décision est instable et doit être relue.

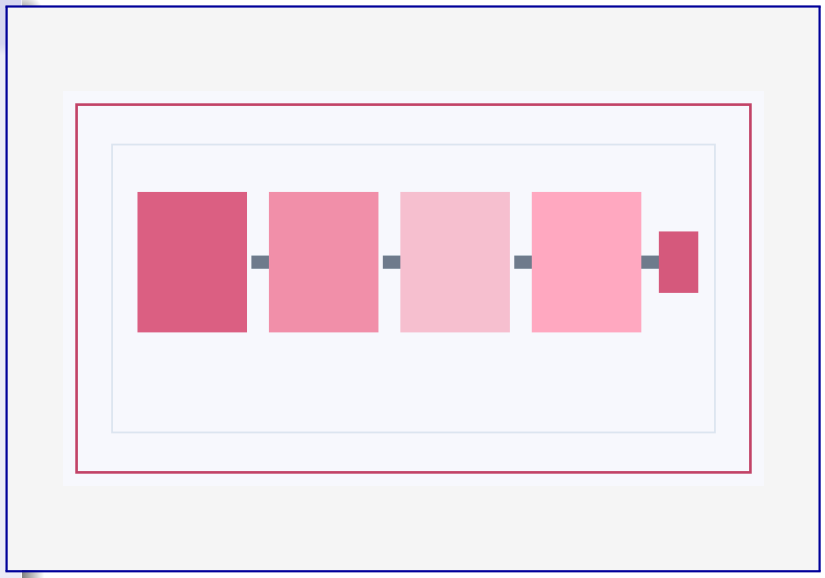

Figure 8: Heatmap explicative et estimation d'incertitude

Solution proposée — Étape 8 : apprentissage

Role : Définir exactement ce qui est optimisé pendant l'entraînement **Etape du projet :** Développement / entraînement

Fonction objectif

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{loc} + \lambda_2 \mathcal{L}_{cons} + \lambda_3 \mathcal{L}_{cal}$$

Sens de chaque terme

$\mathcal{L}_{cls}$: apprendre la bonne classe.

$\mathcal{L}_{loc}$: contraindre la heatmap à rester cliniquement plausible.

$\mathcal{L}_{cons}$: garder une prédiction stable sous augmentation.

$\mathcal{L}_{cal}$: mieux aligner confiance prédite et fréquence réelle d'erreur.

Exemple : sur un dataset déséquilibré, $\mathcal{L}_{cls}$ peut être une Focal Loss afin de mieux traiter les cas rares ou difficiles.

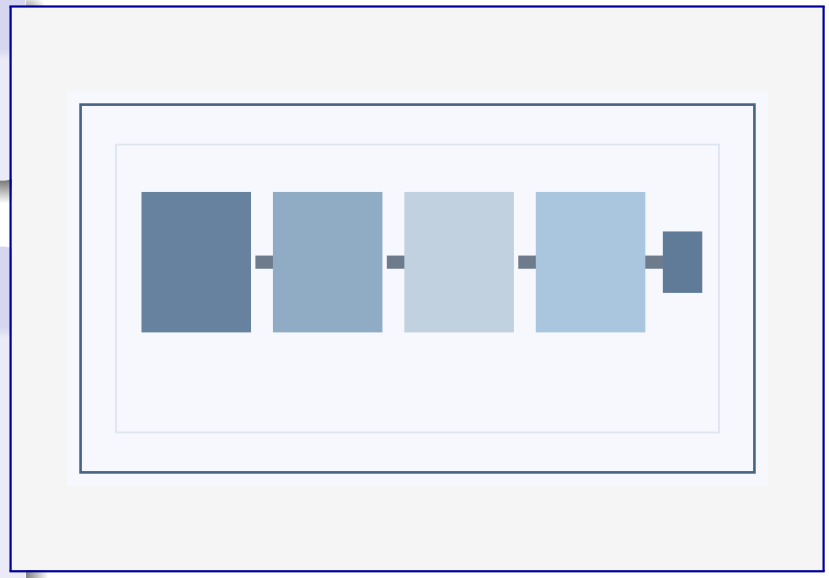

Figure 9: Schéma de la perte totale et de ses composantes

Solution proposée — Étape 9 : sortie clinique

Role : Montrer comment les sorties du modèle deviennent une aide concrète pour le workflow médical **Etape du projet :** Validation métier / déploiement

Sortie exploitable pour le clinicien

Pour une image X, le modèle renvoie :

$$\big(p(y=1|X),\ L^c,\ u\big)$$

soit un score de pneumonie, une heatmap explicative et une estimation d'incertitude.

Comment cela aide le clinicien.

- score élevé + faible incertitude : cas à prioriser ;
- score modéré + incertitude élevée : revue humaine prioritaire ;
- score faible + faible incertitude : cas probablement normal.

Limite : une heatmap plausible reste un support de lecture, pas une preuve diagnostique.

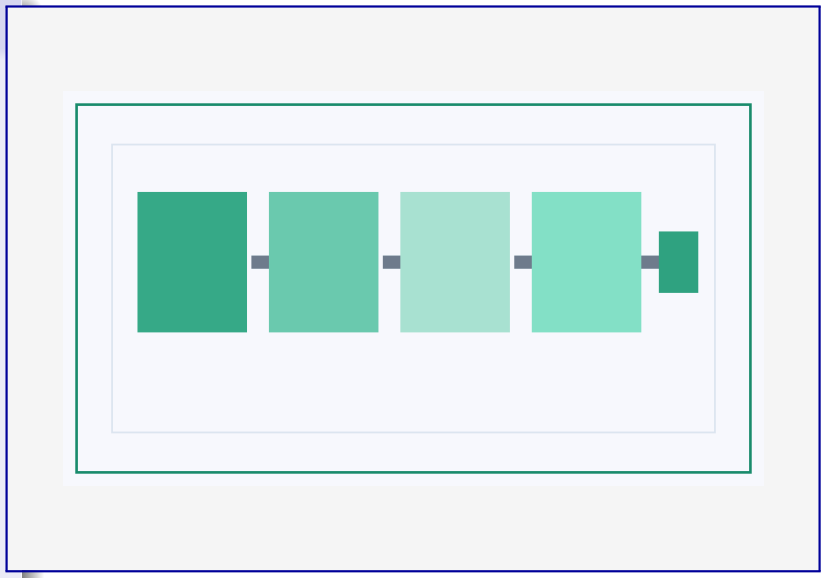

Figure 10: Sortie finale utilisable par le clinicien

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit | **Etape du projet :** Navigation / structuration

1. Acronymes et terminologie
   - Glossaire initial
2. Problématique et Méthodologie
3. Analyse SOTA
   - Phase 1 — DenseNet / CheXNet
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité
4. Solution proposée
   - Architecture et conception
   - Pipeline détaillé
5. Résultats et Finalisation

Résultats obtenus

Role : Présenter les indicateurs de performance et leur interprétation métier **Etape du projet :** Évaluation finale

Métriques de Performance

- **Précision (Accuracy) :** $\approx 92\%$
- **Sensibilité (Recall) :** 94%
- **AUC-ROC :** 0.96

- Réduction significative des faux négatifs.
- Génération de **Grad-CAM** fonctionnelle pour valider les zones d'intérêt.

Mots clés

Role : Synthétiser les thèmes techniques majeurs couverts par le document **Etape du projet :** Clôture documentaire

Intelligence Artificielle

Deep Learning

Vision par Ordinateur

Radiographie Thoracique (CXR)

Pneumonie

CNN / Transformers

Transfer Learning

Interprétabilité (Grad-CAM)

Table des Matières

Role : Repérer la section courante et le type de contenu qui suit	**Etape du projet :** Navigation / structuration

6 Annexes
- Références techniques

Annexe A — Convolution, stride et pooling

Role : Définir les opérations de base des CNN utilisées dans les architectures étudiées **Etape du projet :** Annexe technique

Definitions

Convolution $k \times k$: Filtre local glissant sur l'image ou sur une carte de features.

Stride s : Pas de déplacement du filtre ; quand s augmente, la résolution baisse plus vite.

Padding : Bordure ajoutée pour contrôler la taille de sortie.

MaxPool : Conserve la plus forte activation dans une fenêtre locale.

AvgPool : Remplace une fenêtre locale par sa moyenne.

Formules utiles

$$Y_{i,j,c'} = \sum_{u,v,c} W_{u,v,c,c'} X_{i+u,j+v,c} + b_{c'}$$

$$H_{out} = \left\lfloor \frac{H + 2p - k}{s} \right\rfloor + 1$$

Intuition

Les convolutions extraient des motifs locaux. Le pooling résume l'information et réduit la taille spatiale pour rendre le calcul plus efficace.

Annexe B — BN, ReLU, bottleneck et connexions

Role : Clarifier les briques de stabilisation et d'efficacité citées dans DenseNet et EfficientNet **Etape du projet :** Annexe technique

Stabilisation

BN : Normalise les activations d'un mini-batch pour stabiliser et accélérer l'entraînement.

ReLU : Garde les valeurs positives et annule les négatives, ce qui introduit une non-linéarité simple.

Skip connection : Réinjecte une information plus tôt dans le réseau pour faciliter le gradient.

Efficacité

Bottleneck : Réduit les canaux avant une opération coûteuse, puis projette de nouveau si besoin.

Growth rate k : Nombre de nouveaux canaux ajoutés par chaque couche dense.

SE : Mécanisme qui ré-pondère les canaux selon leur importance.

Fused-MBConv : Version simplifiée de MBConv, souvent plus rapide à entraîner sur GPU dans les premiers étages.

Annexe C — DenseNet et MBConv

Role : Reprendre proprement les blocs spécifiques les plus utilisés dans l'analyse SOTA **Etape du projet :** Annexe technique

Bloc dense

DenseNet concatène les sorties précédentes au lieu de simplement les additionner.

$$x_\ell = H_\ell([x_0, \ldots, x_{\ell-1}])$$

Cela favorise la réutilisation des features et un meilleur flux de gradient.

MBConv

MBConv combine :

- une expansion 1×1,
- une convolution depthwise,
- un module SE,
- une projection finale 1×1.

L'objectif est d'obtenir une bonne expressivité à coût réduit.

Annexe D — Vocabulaire Transformer

Role : Définir les notions de patchs, tokens et embeddings utilisées dans ViT et Swin **Etape du projet :** Annexe technique

Definitions

Patch : Sous-image locale de taille $P \times P$.

Token : Vecteur obtenu après projection d'un patch.

Embedding : Représentation vectorielle dense envoyée dans le Transformer.

Encodage positionnel : Information ajoutée pour conserver l'ordre spatial des patches.

Formule de tokenisation

$$N = \frac{HW}{P^2}, \qquad z_i = E\,x_i + e_i^{pos}$$

Intuition

Le Transformer traite l'image comme une séquence de morceaux visuels, de la même façon qu'un modèle de langage traite une phrase comme une séquence de mots.

Annexe E — Attention et Swin

Role : Détailler le calcul d'attention et la logique des fenêtres décalées de Swin **Etape du projet :** Annexe technique

Attention

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Q : Ce que le token courant cherche.

K : Ce que les autres tokens proposent pour être reliés à lui.

V : L'information qui sera effectivement transmise.

Pourquoi Swin

Fenêtre : Sous-ensemble local de tokens traité ensemble.

Fenêtres décalées : Décalage d'une couche à la suivante pour reconnecter des zones voisines.

Bénéfice : Réduire le coût du contexte global tout en conservant des interactions spatiales utiles.

Complexité

L'attention globale est quadratique en nombre de tokens. Swin réduit ce coût en limitant l'attention à des fenêtres locales.

Annexe F — Entraînement complémentaire

Role : Définir les notions d'entraînement mentionnées sans détail dans la solution proposée **Etape du projet :** Annexe technique

Concepts de base

Transfer learning : Réutiliser un modèle pré-entraîné puis l'adapter à la radiographie thoracique.

Augmentation : Modifier l'image pendant l'entraînement pour rendre le modèle plus robuste.

Pseudo-masque : Zone approximative utilisée comme supervision faible quand on n'a pas d'annotation pixel exacte.

Logit : Score brut avant application de la sigmoïde ou du softmax.

Pourquoi c'est utile

Ces mécanismes servent à :

- mieux généraliser,
- réduire la dépendance à un seul centre hospitalier,
- exploiter des annotations incomplètes,
- stabiliser l'apprentissage quand les données sont déséquilibrées.

Annexe G — Pertes et calibration

Role : Définir les fonctions objectif et la notion de confiance calibrée | **Etape du projet :** Annexe technique

Fonctions de perte

BCE : Binary Cross-Entropy, perte standard de classification binaire.

Focal loss : Version de BCE qui met davantage l'accent sur les exemples difficiles ou rares.

$\mathcal{L}_{cons}$: Impose des sorties proches pour deux vues augmentées d'une même image.

$\mathcal{L}_{loc}$: Contraint la carte explicative à rester cohérente avec une zone plausible.

Calibration

Calibration : Une probabilité 0.8 devrait correspondre à environ 80% de prédictions correctes.

Temperature scaling : Correction post-hoc des logits par un scalaire de température.

ECE : Mesure l'écart entre confiance moyenne et précision réelle.

$$\mathrm{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{n} \left|\mathrm{acc}(B_m) - \mathrm{conf}(B_m)\right|$$

$$\mathcal{L}_{BCE} = -(y \log p + (1-y)\log(1-p))$$

Annexe H — Fusion, explicabilité et incertitude

Role : Documenter les sorties avancées de la solution proposée	**Etape du projet :** Annexe technique

Fusion et gating

Le gating apprend le poids relatif des branches locale et globale.

$$g = \sigma(W_g[\mathrm{GAP}(F_c), \mathrm{GAP}(F_s)])$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si g est grand, la branche CNN domine ; sinon la branche Swin domine.

Explicabilité et confiance

Grad-CAM : Carte visuelle des zones qui contribuent positivement au score choisi.

MC-Dropout : Plusieurs passes avec dropout actif à l'inférence pour estimer l'incertitude.

Variance prédictive : Plus elle est grande, moins la décision est fiable.

$$u = \mathrm{Var}_t(p_t)$$

Annexe I — Metriques d'evaluation

Role : Définir précisément les mesures de performance et leur lecture clinique **Etape du projet :** Annexe technique

Definitions

Accuracy : Proportion totale de prédictions correctes.

Recall / Sensibilité : Capacité à retrouver les cas positifs.

Spécificité : Capacité à rejeter les cas négatifs.

AUC-ROC : Qualité de séparation entre classes quand on fait varier le seuil.

Faux positif : Cas sain déclaré malade.

Faux négatif : Cas malade déclaré sain.

Formules

$$\text{Recall} = \frac{TP}{TP+FN}, \qquad \text{Specificite} = \frac{TN}{TN+FP}$$

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Lecture en contexte médical

En dépistage de pneumonie, réduire les faux négatifs est souvent prioritaire : manquer un cas pathologique est généralement plus grave que sur-appeler un cas douteux.