Présentation PFA: Détection de pneumonie sur radiographie

Conception, Modélisation et Développement.

HANFAOUI Karim[1] KAFIF. Imane[2]

[1]EMSI, 4ème Année IADO G2 - Karim.Hanfaoui@emsi-edu.ma
[2]EMSI, 4ème Année IADO G2 - Imane.Kafif@emsi-edu.ma

EMSI Les Orangers, Mars 2026

Table des Matières

1. Problématique et Méthodologie
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité

2. Résultats et Finalisation

Table des Matières

1. Problématique et Méthodologie
   - Phase 2 — Optimisation et efficacité
   - Phase 3 — Vision Transformers et contexte global
   - Phase 4 — Confiance et explicabilité

2. Résultats et Finalisation

Problématique

Question Centrale de Recherche

Face à la complexité visuelle des pathologies pulmonaires et à la pénurie mondiale de radiologues experts, comment pouvons-nous concevoir un système automatisé basé sur le Deep Learning capable non seulement de détecter la pneumonie avec une précision clinique supérieure à l'interprétation humaine, mais aussi de fournir une justification visuelle explicable afin de garantir une intégration sécurisée et fiable dans le flux de travail médical d'urgence ?

Méthodologie : Approche Agile (Scrum)

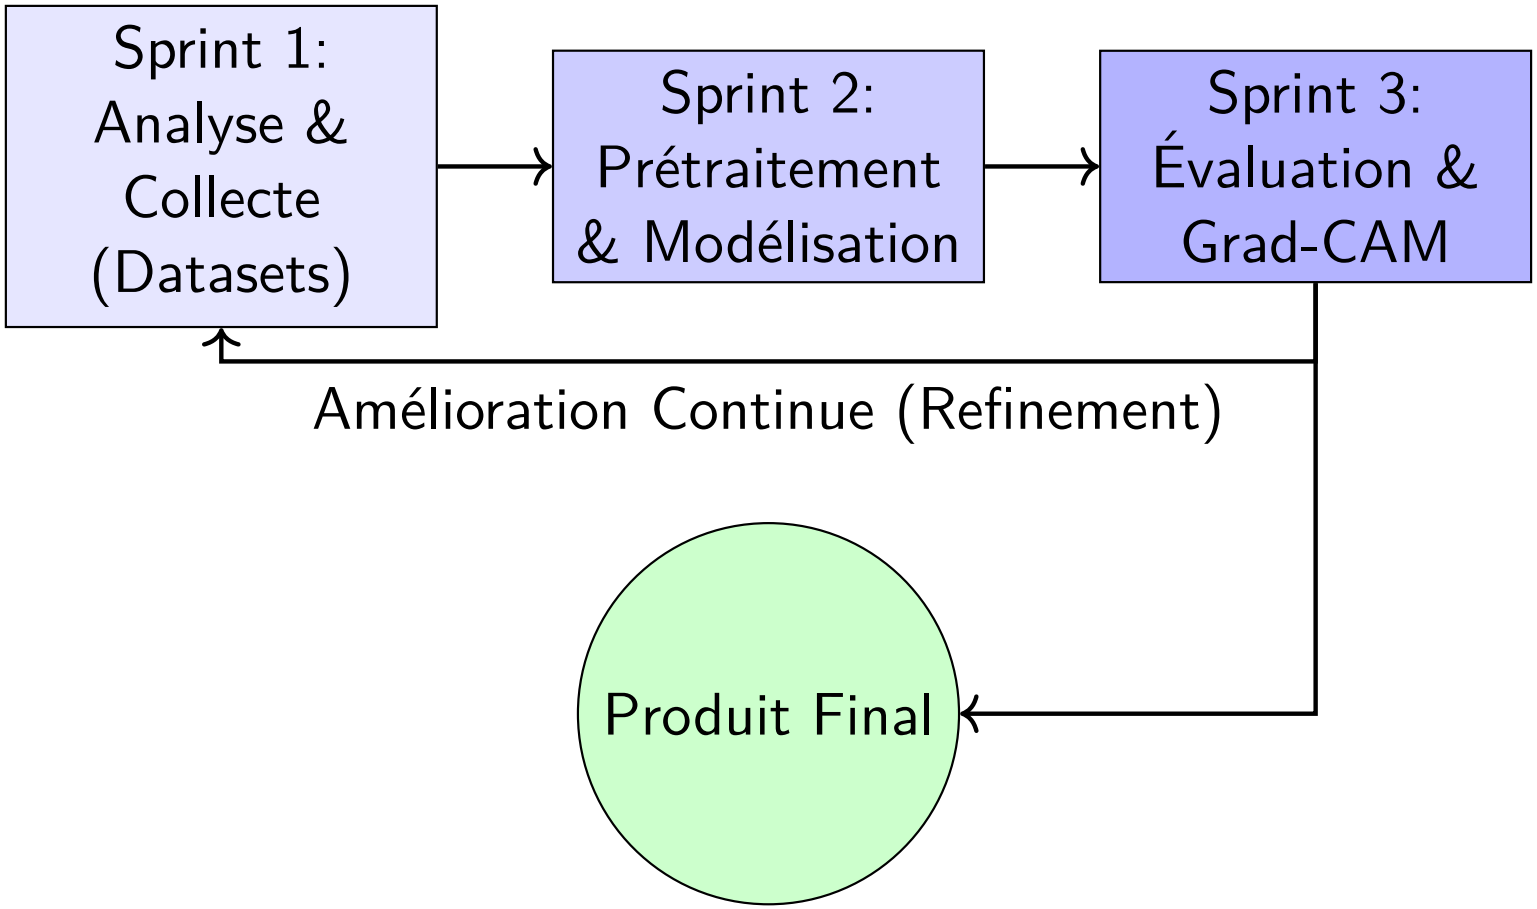

- **Flexibilité :** Adaptation aux contraintes des données médicales.
- **Itérations :** Optimisation progressive des hyperparamètres.

SOTA : Architecture DenseNet-121

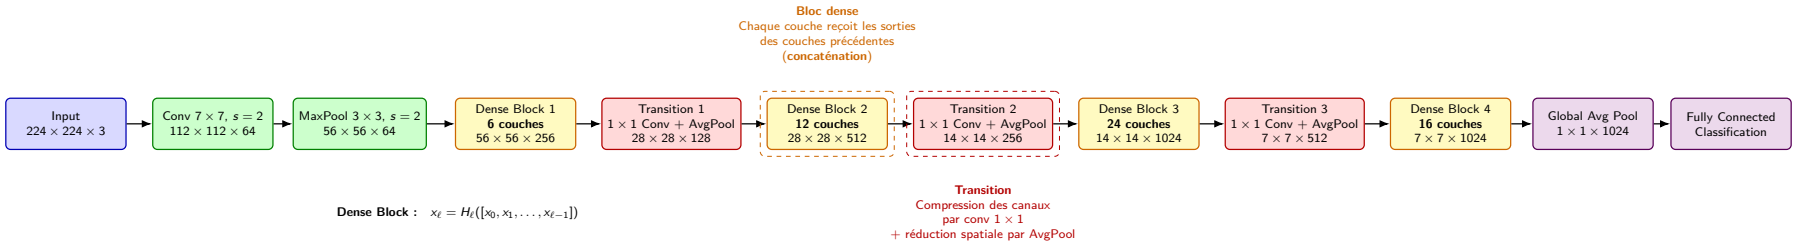

Dense Block
Concaténation de toutes les cartes précédentes :
$x_\ell = H_\ell([x_0, x_1, \ldots, x_{\ell-1}])$
Réutilisation des features + meilleur flux de gradient.
Croissance des canaux : $C_{\text{out}} = C_0 + L \cdot k$.
Exemple : $k = 32$, $L = 6 \Rightarrow C_{\text{out}} = C_0 + 192$.
Où C_0 = canaux initiaux, L = nb de couches, k = growth rate.

Transition
Entre blocs denses, compresse et réduit.
$X \in \mathbb{R}^{H \times W \times C}$
$\rightarrow \mathrm{Conv}_{1\times1}(X) = Y \in \mathbb{R}^{H \times W \times C'}$
$Y_{h,w,c'} = \sum_c W_{c',c} X_{h,w,c} + b_{c'}$
$\rightarrow \mathrm{AvgPool}(Y) = Z \in \mathbb{R}^{H/2 \times W/2 \times C'}$
$Z_{i,j,c'} = \frac{1}{4} \sum_{u,v \in \{0,1\}} Y_{2i+u,2j+v,c'}$
Compression, efficacité, préparation du bloc suivant.
Où H, W = hauteur/largeur, C = canaux, C' = canaux compressés.

Stem / Entrée
Entrée $224 \times 224 \times 3$.
Conv 7×7 ($s = 2$) puis MaxPool 3×3 ($s = 2$).
Extrait des bords/textures et réduit tôt la résolution.
Exemple : $224 \times 224 \rightarrow 112 \times 112 \rightarrow 56 \times 56$.
Où H, W = dimensions spatiales, s = stride.

Tête de classification
Global Avg Pooling : moyenne spatiale par canal.
$7 \times 7 \times 1024 \rightarrow 1 \times 1 \times 1024$.
$g_c = \frac{1}{HW} \sum_{h,w} F_{h,w,c}$, puis FC.
Exemple : $g \in \mathbb{R}^{1024} \rightarrow$ scores $\in \mathbb{R}^K$.
Où F = carte de features, g = vecteur global, K = nb de classes.

DenseNet-121 : Structure d'une couche dense

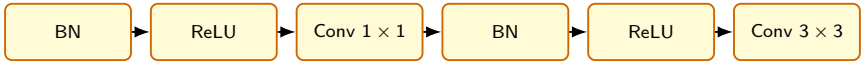

Séquence : BN $\rightarrow$ ReLU $\rightarrow$ Conv 1×1 $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ Conv 3×3

Transformation H_ℓ
H_ℓ est la transformation appliquée par la couche ℓ dans un bloc dense ; elle produit de **nouvelles** cartes de features.
Formule :
$H_\ell(x) = \mathrm{Conv}_{3\times3}\big(\mathrm{ReLU}(\mathrm{BN}(\mathrm{Conv}_{1\times1}(\mathrm{ReLU}(\mathrm{BN}(x))))))\big)$
Si $x = [x_0, x_1, \ldots, x_{\ell-1}]$, alors $x_\ell = H_\ell(x)$.
Interprétation : 1×1 = mélange/réduction des canaux (bottleneck),
3×3 = extraction spatiale locale, BN+ReLU = stabilité + non-linéarité.
Croissance : la couche ajoute k canaux :
$C_{\text{out}} = C_{\text{in}} + k$.
Après L couches : $C_{\text{out}} = C_0 + Lk$.
Où C_{in} = canaux d'entrée, C_0 = canaux initiaux, k = growth rate.

Phase 2 — EfficientNet : idée générale et scaling

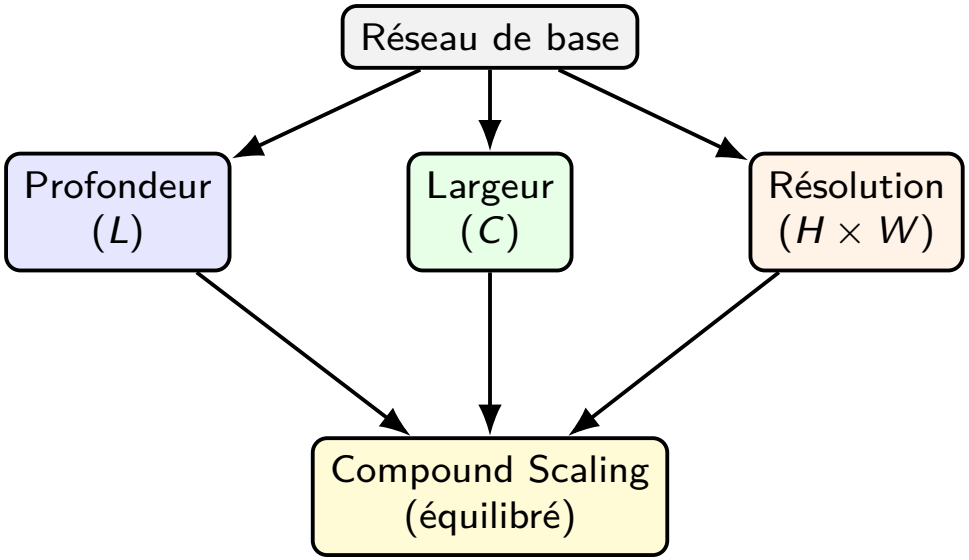

Idée centrale
EfficientNet est une famille de CNN conçue pour **mieux exploiter** un budget de calcul donné.
Le **scaling naïf** (uniquement profondeur, largeur ou résolution) crée un déséquilibre :
trop profond $\Rightarrow$ gradient fragile,
trop large $\Rightarrow$ surcoût mémoire,
trop haute résolution $\Rightarrow$ coût quadratique.

Compound Scaling
On augmente **ensemble** profondeur, largeur et résolution par un facteur global ϕ pour rester efficace.

$$d = \alpha^{\phi}, \quad w = \beta^{\phi}, \quad r = \gamma^{\phi},$$
$$\alpha\,\beta^2\,\gamma^2 \approx 2$$

ϕ contrôle l'échelle globale ; la contrainte équilibre coût et performance.

Phase 2 — MBConv : bloc clé d'EfficientNet

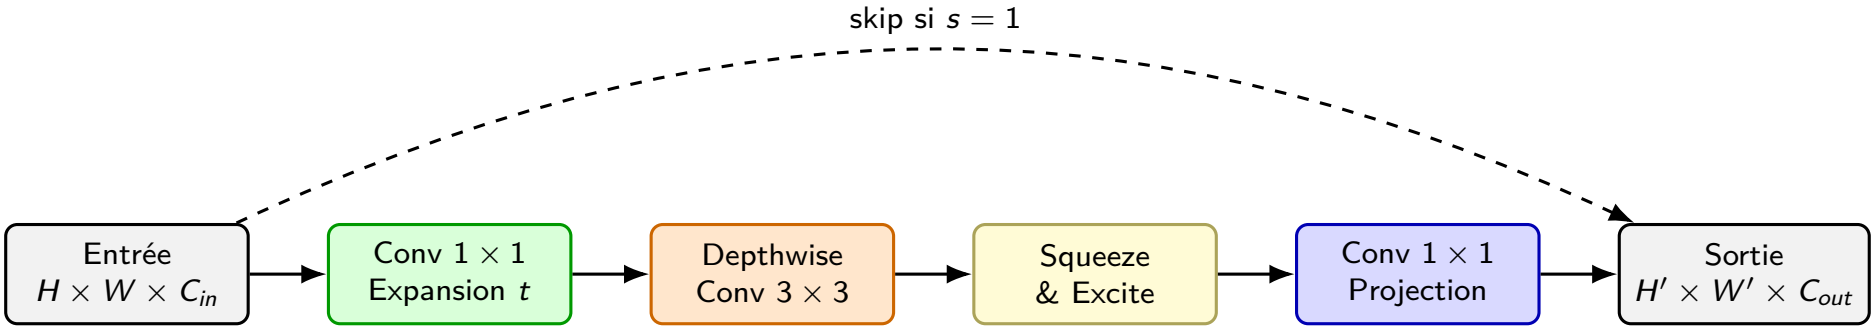

Depthwise Convolution

Chaque canal est filtré séparément :

$$Y_{h,w,c} = \sum_{i,j} K_{i,j}^{(c)} X_{h+i,w+j,c}$$

Coût paramétrique : $k^2 C$
au lieu de $k^2 CC'$ (conv standard).
Réduit fortement les paramètres et FLOPs.

MBConv en pratique

1) Expansion
$C_e = t \cdot C_{in}$,
2) Depthwise 3×3,
3) SE (ré-pondération canal),
4) Projection vers C_{out},
5) Skip si stride $s = 1$
et dimensions
compatibles.
Objectif :
expressivité élevée
avec coût réduit.

Phase 2 — EfficientNetV2 et impact médical

EfficientNetV2 : améliorations
Optimise l'entraînement (plus rapide et stable) via :
- **Fused-MBConv** sur les petits étages (meilleur débit GPU),
- règles de scaling adaptées,
- stratégies de régularisation plus efficaces.

Résultat : **meilleure précision** à coût d'entraînement réduit.

Intérêt en imagerie médicale
Meilleur compromis précision/temps :
- utile pour stations avec GPU limités,
- facilite l'expérimentation rapide,
- déploiement clinique plus réaliste.

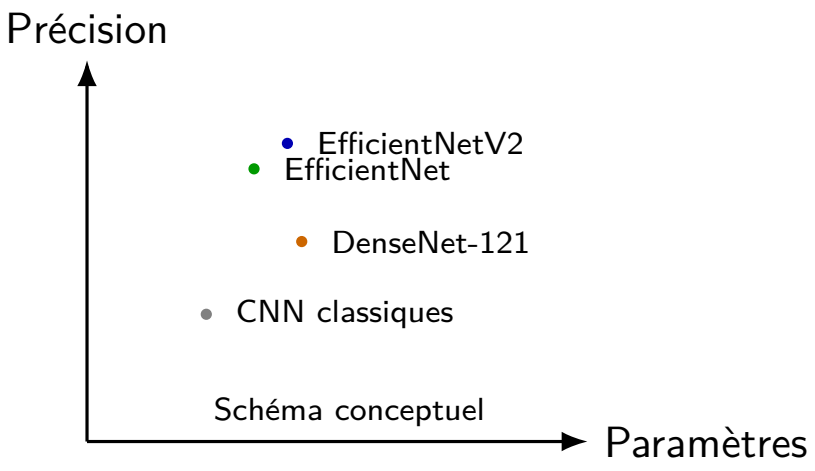

Phase 2 — EfficientNet : ce que fait le modèle

Mécanisme effectif
Le réseau apprend une fonction f_θ qui transforme X en **cartes hiérarchiques** (bords, textures, motifs complexes).
Les blocs MBConv alternent **mixage de canaux** (1×1), **filtrage spatial local** (depthwise) et **ré-pondération** (SE).
Après agrégation globale :

$$z = \mathrm{GAP}(F_L(X)), \quad p(y|X) = \sigma(w^\top z)$$

Le scaling compound règle **profondeur/largeur/résolution** pour préserver détail et contexte.

Aide en imagerie médicale
Capte des patterns **multi-échelles** (opacités diffuses, consolidations).
Bon compromis précision/coût $\Rightarrow$ utile en contexte GPU limité.
Permet d'exploiter des images haute résolution sans explosion de paramètres.

Limites et risques
Downsampling peut effacer des signes **très fins**.
Sensibilité aux biais (texte, position, appareil, contraste).
Pas de localisation directe : nécessite un outil d'explicabilité.

Phase 3 — ViT : patches et tokens

Image → patches

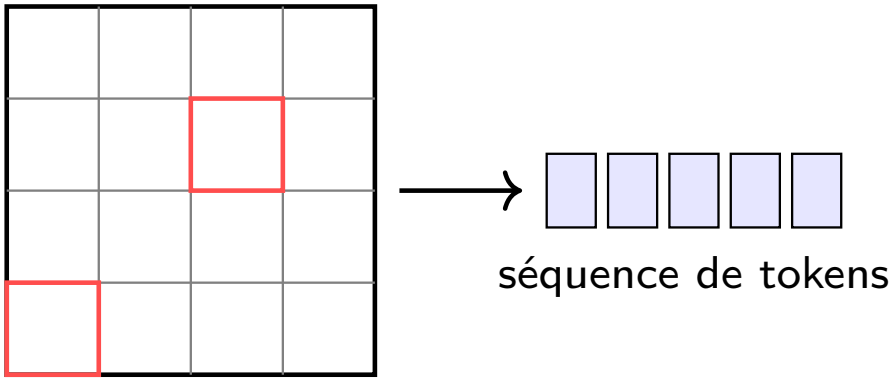

Tokenisation d'image
Image $X \in \mathbb{R}^{H \times W \times C}$ découpée en patches $P \times P$.
Nombre de tokens : $N = \frac{HW}{P^2}$.
Chaque patch est aplati et projeté :
$z_i = E\, x_i + e_i^{\text{pos}}, \quad z_i \in \mathbb{R}^D$.
On traite ensuite $(z_1, \ldots, z_N)$ comme une **séquence**.

Intuition : les patches jouent le rôle de "mots" visuels ; l'attention relie des régions éloignées.

Phase 3 — Auto-attention : mécanisme et coût

Auto-attention

$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Q : requêtes, K : clés, V : valeurs.
Chaque token "regarde" tous les autres **(contexte global)**.

Limite de ViT

Complexité quadratique : $O(N^2)$ avec N tokens.
Pour grandes images médicales, N devient très élevé $\Rightarrow$ coût prohibitif.

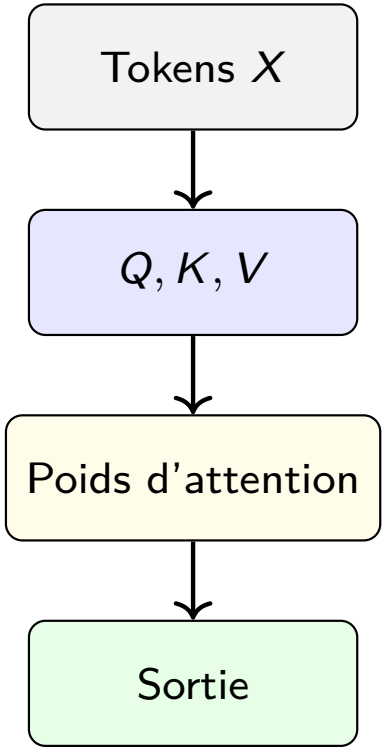

Phase 3 — Swin Transformer : fenêtres et décalage

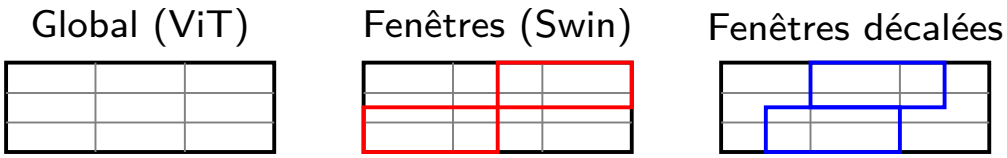

Attention par fenêtres
Swin limite l'attention à des fenêtres $M \times M$:
complexité
$O\left(\frac{HW}{M^2} \cdot M^4\right) = O(HW\,M^2)$,
au lieu de $O(N^2)$ global.
Le **décalage** des fenêtres connecte les régions voisines.

Intérêt médical
Capte des relations à longue distance tout en restant scalable.
Meilleure adaptation aux images haute résolution (radiographies).
Permet de relier des patterns subtils répartis dans l'image.

Phase 3 — ViT/Swin : ce que fait le modèle

Mécanisme effectif
Chaque patch devient un token ; l'attention calcule l'importance **entre régions**.

$$a_{ij} = \mathrm{softmax}\left(\frac{q_i k_j}{\sqrt{d}}\right), \quad \tilde{z}_i = \sum_j a_{ij} v_j$$

Le modèle combine ainsi **contexte global** et information locale.
Swin ajoute attention par **fenêtres** + **décalage**, puis **fusion de patches** (hiérarchie multi-échelle).

Aide en imagerie médicale
Relie des régions éloignées (symétrie pulmonaire, contexte global).
Utile pour motifs diffus et structures larges.
Swin reste efficace sur grandes images tout en gardant du détail.

Limites
Moins d'inductif bias que les CNN ⇒ besoin de pré-entraînement.
Patches trop grands ⇒ perte de lésions fines ; trop petits ⇒ coût élevé.
Attention peut suivre des corrélats non pathologiques.

Phase 4 — Grad-CAM : principe et formulation

Idée
Grad-CAM met en évidence **où** le réseau "regarde" pour une classe donnée.
On utilise les gradients du score y^c par rapport aux cartes A^k.

Formules
Poids d'importance :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

Carte Grad-CAM :

$$L_{\text{Grad-CAM}}^c = \mathrm{ReLU}\left(\sum_k \alpha_k^c A^k\right)$$

Interprétation
A^k : carte de features de la dernière couche conv.
α_k^c : contribution de la carte k à la classe c.
ReLU conserve les contributions positives.
Le modèle donne **"quoi"**, Grad-CAM suggère **"où"**.

Phase 4 — Grad-CAM : schéma de génération

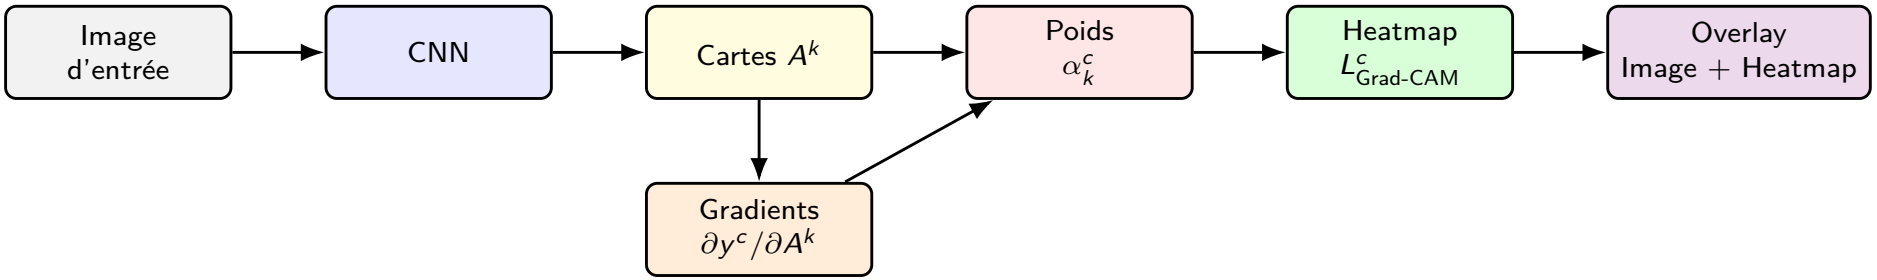

Lecture : l'overlay montre les régions activées associées à la classe prédite.

Phase 4 — Grad-CAM : ce que ça aide (et ce que ça n'aide pas)

Ce que Grad-CAM apporte

Explication **post-hoc** : montre quelles zones augmentent le score y^c.
Ne modifie pas la prédiction, mais **guide l'analyse** (triage, relecture).
Utile pour repérer des biais (texte, marqueurs, position).
Permet d'aligner le modèle avec l'expertise clinique.

Ce que Grad-CAM ne garantit pas

Carte **grossière** (résolution = stride de la dernière couche).
Importance $\neq$ causalité ; une heatmap "plausible" peut être trompeuse.
Sensibilité à la couche choisie, au prétraitement et au bruit.
Interprétabilité = aide, pas preuve diagnostique.

Table des Matières

1 Problématique et Méthodologie
- Phase 2 — Optimisation et efficacité
- Phase 3 — Vision Transformers et contexte global
- Phase 4 — Confiance et explicabilité

2 Résultats et Finalisation

Résultats obtenus

Métriques de Performance

- **Précision (Accuracy) :** $\approx 92\%$
- **Sensibilité (Recall) :** 94%
- **AUC-ROC :** 0.96

- Réduction significative des faux négatifs.
- Génération de **Grad-CAM** fonctionnelle pour valider les zones d'intérêt.

Mots clés

Intelligence Artificielle

Deep Learning

Vision par Ordinateur

Radiographie Thoracique (CXR)

Pneumonie

CNN / Transformers

Transfer Learning

Interprétabilité (Grad-CAM)