



Présentation PFA: Détection de pneumonie sur radiographie

Conception, Modélisation et Développement.

HANFAOUI Karim¹ KAFIF. Imane²

¹EMSI, 4ème Année IADO G2 -
Karim.Hanfaoui@emsi-edu.ma

²EMSI, 4ème Année IADO G2 -
Imane.Kafif@emsi-edu.ma

EMSI Les Orangers, Mars 2026

Table des Matières

Role : Présenter la structure complète du rapport et l'ordre des étapes

Etape du projet : Navigation / cadrage global

1 Problématique et Méthodologie

2 Faisabilité Entrepreneuriale

- Étude de marché et stratégie
- Faisabilité financière et juridique
- Phase 4 — Confiance et explicabilité

3 Solution proposée

- Architecture et conception
- Pipeline détaillé
- Implémentation et Outils techniques

4 Résultats et Finalisation

Role : Poser le besoin clinique, la question de recherche et la contrainte d'explicabilité scientifique

Etape du projet : Cadrage


Question Centrale de Recherche

Face à la complexité visuelle des pathologies pulmonaires et à la pénurie mondiale de radiologues experts, comment pouvons-nous concevoir un système automatisé basé sur le Deep Learning capable non seulement de détecter la pneumonie avec une précision clinique supérieure à l'interprétation humaine, mais aussi de fournir une justification visuelle explicable afin de garantir une intégration sécurisée et fiable dans le flux de travail médical d'urgence ?

Méthodologie : Approche Agile (Scrum)

Role : Montrer comment le projet est découpé en phases de travail et d'itération
planification

Etape du projet : Organisation /



- **Flexibilité :** Adaptation aux contraintes des données médicales.
- **Itérations :** Optimisation progressive des hyperparamètres.

Gestion de Projet — Tableau des Tâches (PFA)

Role : Détailler les tâches, leur charge et le type exact de liaison temporelle **Etape du projet** : Organisation / planification

Le tableau ci-dessous affine la planification en ajoutant les décalages et les relations PERT.

ID	Nom de la Tâche	Durée	Antécédent(s) + liaison
A	Cadrage et problématique clinique	3 j	—
B	Analyse SOTA CNN (DenseNet / CheXNet)	4 j	A (0FD)
C	Analyse SOTA Swin Transformer / ViT	4 j	A (0FD)
D	Étude d'explicabilité XAI et lecture Grad-CAM	2 j	B (1DD), C (0FF)
E	Prétraitement $T(X)$, resize et normalisation	5 j	A (0FD)
F	Développement de la branche locale CNN	6 j	B (0FD), E (0FD)
G	Développement de la branche globale Swin	7 j	C (0FD), E (0FD)
H	Intégration du module de gated fusion	5 j	F (0FD), G (0FD)
I	Sortie clinique Ψ : score + incertitude	4 j	H (0FD)
J	Configuration GPU / Colab / environnement	2 j	A (1DD)
K	Entraînement, calibration et optimisation	10 j	I (0FD), J (0FD)
L	Évaluation finale, benchmark et métriques	3 j	K (0FD)
M	Finalisation rapport, slides et démonstration	5 j	L (0FD), D (0FD)

Lecture de la notation

Exemple : 0FD signifie *Fin-Début sans décalage*, 1DD signifie *Début-Début avec 1 jour de décalage*. La notation générale est : [décalage] + [type de liaison].

Gestion de Projet — Tableau des Marges

Role : Quantifier la flexibilité de chaque tâche à travers la marge libre et la marge totale **Etape du projet :** Organisation / planification

ID	A	B	C	D	E	F	G	H	I	J	K	L	M
ML	0	1	0	30	0	1	0	0	0	21	0	0	0
MT	0	2	1	30	0	1	0	0	0	21	0	0	0

ML = marge libre ; **MT** = marge totale. Les tâches critiques vérifient **ML = MT = 0**, tandis que **D** et **J** concentrent l'essentiel de la souplesse du planning.

Chemin critique

A → E → G → H → I → K → L → M

Durée totale estimée : 42 jours

Méthodologie — Schéma du Réseau de PERT

Rôle : Visualiser le réseau PERT avec les dates au plus tôt/tard et le chemin critique **Etape du projet :** Organisation / planification





Figure 1: Réseau PERT de MedFusionNet avec chemin critique et dates au plus tôt / au plus tard.

Gestion de Projet — Diagramme de Gantt

Role : Projeter le planning sur un calendrier opérationnel tout en respectant les liaisons DD, FD et FF **Etape du projet :** Organisation / planification



Partie II

Faisabilité Entrepreneuriale et Commerciale

Démontrer la viabilité économique, le potentiel de marché et la transformation de la solution technique **MedFusionNet** en un projet d'entreprise viable.

Contexte et Identification du Problème

Role : Poser le besoin terrain, l'origine de l'idée et l'avantage concurrentiel de la solution entrepreneurial

Etape du projet : Cadrage

Le Problème

- **Complexité visuelle** des pathologies pulmonaires sur CXR.
- **Pénurie mondiale** de radiologues (OMS : 1/100 000 hab. en Afrique).
- **Temps d'attente** critiques aux urgences.
- IA SOTA actuelles = **boîtes noires** opaques, freinant l'adoption clinique.

Origine & Solution

- Observation terrain en **milieu hospitalier**.
- **MedFusionNet** : avantage concurrentiel unique :
 - Double lecture **locale/globale** (CNN + Swin).
 - **Explicabilité** Grad-CAM intégrée.
 - **Incertitude** (MC-Dropout) pour sécuriser le diagnostic.

Proposition de valeur

Là où les concurrents fournissent un score opaque, MedFusionNet livre un **triplet** (p, L^c, u) : probabilité, carte explicative et niveau de confiance.

Étude de Faisabilité Commerciale

Role : Synthétiser l'environnement externe et les outils stratégiques SWOT / PESTEL / Porter
Analyse de marché

Etape du projet :

Demande & Cibles

- **Hôpitaux publics** : optimiser le triage et réduire les erreurs.
- **Cliniques privées** : accélérer les flux et se différencier.
- **Centres d'urgence** : aide à la décision h24.

Analyse PESTEL

- **P/E** : Soutien e-santé ; marché mondial >45Mds\$.
- **S/T** : Adoption médicale ; GPU cloud & SOTA matures.
- **E/L** : Green IT ; Loi 09-08 / RGPD (données patients).

Synthèse SWOT

- **F** : Technologie unique, explicable et quantifiée.
- **W** : Statut startup, volume de données cliniques initial.
- **O** : Digitalisation et réformes de la santé au Maroc.
- **M** : Réglementation stricte, acteurs mondiaux.

Forces de Porter

- **Entrants** : Barrière élevée (expertise IA + médicale).
- **Clients** : Pouvoir fort ⇒ Modèle SaaS flexible.
- **Substituts** : Rares (pas d'outil explicable local).

Marketing Stratégique et Marketing Mix

Role : Définir le positionnement STP et le mix marketing 4P pour la commercialisation marketing

Etape du projet : Stratégie

Segmentation & Positionnement (STP)

- **Segment principal** : Services d'urgence et centres de radiologie à fort flux (>50 CXR/jour).
- **Segment secondaire** : Plateformes de téléradiologie.
- **Ciblage** : B2B, établissements de santé au Maroc puis Afrique francophone.
- **Positionnement** : Solution IA **innovante**, hautement **fiable** (incertitude quantifiée) et **transparente** (explicable par Grad-CAM).

Marketing Mix — 4P

- **Produit** : API MedFusionNet + Interface Web intuitive (Streamlit / Gradio). Sortie : (p, L^c, u) .
- **Prix** : Stratégie de pénétration puis abonnement SaaS par volume de scans (3 paliers).
- **Place** : Déploiement Cloud sécurisé (AWS/GCP) ou conteneurisé sur serveur local via Docker.
- **Promotion** : Salons technologiques médicaux (GITEX Africa), publications scientifiques, partenariats pilotes avec des CHU.

Avantage clé

MedFusionNet se différencie par la **triple sortie explicable** (p, L^c, u) là où les concurrents ne fournissent qu'un score binaire opaque.

Étude de Faisabilité Technique

Role : Valider la viabilité opérationnelle : ressources matérielles et profils humains requis technique

Etape du projet : Faisabilité

Besoins Matériels

- **Calcul :** Serveurs GPU (NVIDIA A100 ou T4) pour l'entraînement et l'inférence temps réel.
- **Cloud :** Infrastructure sécurisée (AWS / GCP / Azure) avec chiffrement des données médicales.
- **Stockage :** Compatibilité PACS/DICOM pour l'intégration hospitalière native.
- **Réseau :** Connexion sécurisée (VPN / TLS) pour la transmission des images.

Profils Requis

- **Ingénieur IA / Deep Learning :** Maintenance et amélioration du modèle hybride.
- **Développeur Full-Stack :** FastAPI / Streamlit, interface utilisateur et API REST.
- **Expert DevOps :** Docker, CI/CD, monitoring et déploiement continu.
- **Consultant Radiologue :** Validation clinique, annotation experte et conformité médicale.

Stack technologique validée

L'ensemble du pipeline (PyTorch, Flask, Docker) a été **prototypé et testé** durant le PFA, réduisant significativement le risque technique.

Étude Financière — Budget et Prévisions

Role : Chiffrer l'investissement initial et projeter les revenus sur 12 mois

Etape du projet : Faisabilité financière

Investissement Initial

Poste d'investissement	Montant (MAD)
Développement logiciel (6 mois)	180 000
Infrastructure Cloud / GPU (an 1)	60 000
Licences outils IA & données	25 000
Marketing de lancement	35 000
Création juridique (SARL)	8 000
Fonds de roulement initial	42 000
Total Investissement	350 000

Prévisions de Ventes (mois 7-12)

Segment	Clients	CA/mois
Cliniques (SaaS)	5	30 000
Hôpitaux (licence)	2	40 000
Pilotes payants	3	15 000
Total mensuel	10	85 000

- CA annuel projeté (an 1) :
~510 000 MAD
- Objectif an 2 : 20 clients, CA > 1.2M MAD

Modèle économique

Revenus récurrents par **abonnement SaaS** (cliniques) et **licences annuelles** (hôpitaux), assurant une visibilité financière à moyen terme.

Étude Financière — Indicateurs de Rentabilité

Role : Calculer les seuils de rentabilité et le BFR pour valider la viabilité économique **Etape du projet :** Analyse financière

Charges mensuelles estimées

Charges fixes (CF)	MAD/mois
Salaires (3 ETP)	36 000
Cloud / serveurs GPU	5 000
Locaux / divers	4 000
Total CF	45 000

Charges variables (CV)

- $\approx 0,50$ MAD / scan d'API Cloud.
- Pour 10 000 scans/mois $\Rightarrow$ **5 000 MAD.**

Indicateurs clés

- **Marge brute (MB) :**
 $MB = CA - CV = 85k - 5k = 80\,000$ MAD
- **Taux de MCV (TMCV) :**
 $TMCV = \frac{MB}{CA} = \frac{80\,000}{85\,000} \approx 94,1\%$
- **Seuil de rentabilité (SR) :**
 $SR = \frac{CF}{TMCV} = \frac{45\,000}{0,941} \approx 47\,822$ MAD/mois
- **BFR maîtrisé :** Paiement SaaS d'avance $\Rightarrow$ BFR proche de zéro.

Conclusion financière

Avec un CA cible de 85 000 MAD et un SR à $\sim 48\,000$ MAD, le projet atteint son **équilibre dès le 8^e mois** d'activité commerciale.

Cadre Juridique et Stratégie de Développement

Role : Définir la forme juridique et tracer les axes d'évolution du projet perspectives

Etape du projet : Aspects juridiques /

Forme Juridique (SARL) & Conformité

- **Choix** : Structure stable, capital social libre.
- **Avantages** : Protection du patrimoine des associés et souplesse adaptée à une startup tech au Maroc.
- **Conformité** : Respect strict de la **Loi 09-08** (anonymisation, hébergement sécurisé, consentement).

Perspectives de Développement

- **Court terme** : Déploiement pilote dans 2-3 CHU partenaires au Maroc.
- **Moyen terme** : Extension multi-pathologies (tumeurs, tuberculose) & Certification Dispositif Médical (**CE / FDA**).
- **Long terme** : Intégration PACS/RIS (**DICOM**), expansion en Afrique francophone, levée de fonds.

Vision

De projet de recherche à **startup e-health** certifiée : MedFusionNet vise à devenir une référence du diagnostic IA au Maroc et en Afrique.

Solution proposée — Étape 0 : vue d'ensemble

Role : Présenter la logique globale du modèle avant le détail des étapes

Etape du projet : Conception de la solution

Principe et formule globale

MedFusionNet combine deux lectures d'une même radiographie :

- une branche **CNN** pour les indices locaux : contours, textures, petites opacités ;
- une branche **Swin** pour le contexte global : symétrie thoracique, bilatéralité, cohérence anatomique ;
- une **fusion guidée** qui pondère automatiquement les deux branches.

Chaîne mathématique.

$$\tilde{X} = T(X)$$

$$F_c = \Phi_c(\tilde{X}), \quad F_s = \Phi_s(\tilde{X})$$

$$g = \sigma(W_g[\text{GAP}(F_c), \text{GAP}(F_s)] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

La sortie finale vérifie $\Psi(F) = (p, L^c, u)$: score p , heatmap L^c , incertitude u .




Figure 2: Vue d'ensemble du pipeline complet

Solution proposée — Étape 1 : échantillon d'entrée

Role : Définir la donnée d'entrée et ce qu'elle contient avant tout calcul

Etape du projet : Conception détaillée

Image et variabilité

Une radiographie thoracique est modélisée par :

$$X \in \mathbb{R}^{H \times W}$$

avec une étiquette binaire :

$$\begin{cases} y = 1 & \text{pneumonie} \\ y = 0 & \text{normal ou autre classe négative} \end{cases}$$

Pourquoi l'entrée est difficile. L'image brute contient à la fois le signal clinique et des facteurs parasites :

- variations d'intensité et de contraste selon l'appareil ;
- bruit, annotations, câbles et autres artefacts ;
- cadrage, résolution et structures normales parfois trompeuses.

Exemple : deux clichés de même classe peuvent avoir un contraste ou un centrage très différents ; le modèle doit ignorer cette variabilité non pathologique.




Figure 3: Échantillon brut provenant du dataset

Solution proposée — Étape 2 : prétraitement

Role : Standardiser l'image avant son entrée dans les deux branches du modèle
préparation des données

Etape du projet : Développement /

Transformation

Le prétraitement applique une chaîne de standardisation :

$$\tilde{X} = T(X) = A(R(N(X)))$$

où N normalise les intensités, R redimensionne et A peut améliorer localement le contraste.

Ce que la donnée devient

normalisation :
$$X_{norm} = \frac{X - \mu}{\sigma}$$

redimensionnement :
$$X \in \mathbb{R}^{H \times W} \rightarrow \tilde{X} \in \mathbb{R}^{H_0 \times W_0}$$

Exemple : $1024 \times 1024 \rightarrow 384 \times 384$. Cette étape réduit le coût mémoire, homogénéise les entrées et diminue le risque que le modèle prenne une différence d'acquisition pour une pneumonie.




Figure 4: Image après normalisation et redimensionnement

Solution proposée — Étape 3 : branche CNN locale

Role : Extraire les motifs fins et localisés par une lecture convolutive **Etape du projet :** Modélisation de la branche locale

Lecture locale par CNN

La branche locale produit :

$$F_c = \Phi_c(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_c}$$

Une convolution applique un filtre sur un voisinage restreint :



$$F_{i,j,c'}^{(\ell)} = \sum_{u,v,c} W_{u,v,c,c'}^{(\ell)} F_{i+u,j+v,c}^{(\ell-1)} + b_{c'}^{(\ell)}$$

Ce que la branche voit réellement.

- bords pleuraux, côtes, contours pulmonaires ;
- textures diffuses ou focales ;
- petites consolidations et opacités locales ;
- transitions fines entre tissu sain et tissu suspect.

Exemple : une opacité basale discrète peut être amplifiée par la comparaison locale entre intensités voisines.

Image / Feature Map



Couche suivante

Champ récepteur local ($k \times k$)

Figure 5: Représentation locale extraite par la branche CNN

Solution proposée — Étape 4 : branche Swin globale

Role : Extraire une représentation de contexte capable de relier des régions éloignées **Etape du projet :** Modélisation de la branche globale

Lecture globale par Swin

L'image prétraitée est découpée en patches puis projetée :

$$z_i = E x_i + e_i^{pos}$$

La branche globale calcule ensuite :


$$F_s = \Phi_s(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_s}$$

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Dans Swin, cette attention est calculée par fenêtres, puis les fenêtres sont décalées pour reconnecter les régions voisines. **Ce que la branche globale apporte.** Elle relie des zones éloignées : apex, bases, hémithorax droit/gauche, médiastin. Si une anomalie n'a de sens que par sa **distribution spatiale**, Swin la capture mieux qu'un CNN purement local.

**Attention Globale
(Longue distance)**



Patches d'image

Figure 6: Représentation globale extraite par la branche Swin

Solution proposée — Étape 5 : fusion guidée

Role : Combiner les indices locaux et globaux sans imposer un poids fixe à chaque branche **Etape du projet :** Conception du coeur de fusion

Porte de fusion et interprétation

On résume d'abord chaque branche par un vecteur global :

$$\bar{F}_c = \text{GAP}(F_c), \quad \bar{F}_s = \text{GAP}(F_s)$$

Puis on apprend un coefficient de fusion :

$$g = \sigma(W_g[\bar{F}_c, \bar{F}_s] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si $g \approx 1$, le modèle privilégie l'indice local ; si $g \approx 0$, il privilégie le contexte global. **Exemples. Exemple 1** : foyer net et compact $\Rightarrow g \approx 0.8$.

Exemple 2 : atteinte diffuse ou bilatérale $\Rightarrow g \approx 0.3$.

La fusion n'est donc pas une moyenne fixe : elle s'adapte à la structure réelle de l'image.




Figure 7: Fusion adaptative entre la branche locale et la branche globale

Solution proposée — Étape 6 : classification

Role : Transformer la représentation fusionnée en probabilité de pneumonie

Etape du projet : Tête de décision

Score de classe

La représentation fusionnée est condensée en un vecteur :

$$z = \text{GAP}(F)$$

puis convertie en probabilité :

$$p(y = 1|X) = \sigma(w^\top z + b)$$

Décision pratique

Avec un seuil τ :

$$\hat{y} = \begin{cases} 1 & \text{si } p(y = 1|X) \geq \tau \\ 0 & \text{sinon} \end{cases}$$

Exemple : si $p = 0.91$ et $\tau = 0.5$, la prédiction est positive avec une forte marge. Si $p = 0.54$, la décision reste positive mais devient fragile : elle doit être lue avec la heatmap et l'incertitude.




Figure 8: Passage de la représentation fusionnée au score de classe

Solution proposée — Étape 7 : localisation et incertitude

Role : Produire une explication spatiale et mesurer la fiabilité de la décision

Etape du projet : Sorties interprétables

Localisation et incertitude

À partir des cartes finales A^k :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

$$L^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right)$$

La heatmap montre **où** le modèle a trouvé des indices pour la classe prédite. **Incertainité**. En répétant plusieurs passes avec dropout actif :

$$u = \text{Var}_t(p_t)$$

Exemple : si $p_t = \{0.87, 0.88, 0.89\}$, la variance est faible ; si $p_t = \{0.42, 0.81, 0.57\}$, la décision est instable et doit être relue.





Figure 9: Heatmap explicative et estimation d'incertitude

Grad-CAM : schéma de génération

Role : Visualiser le pipeline complet de production d'une heatmap explicative
évaluation interprétable

Etape du projet : Analyse SOTA /



Lecture : l'overlay montre les régions activées associées à la classe prédite.

Solution proposée — Étape 8 : apprentissage

Role : Définir exactement ce qui est optimisé pendant l'entraînement **Etape du projet :** Développement / entraînement

Fonction objectif

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{loc} + \lambda_2 \mathcal{L}_{cons} + \lambda_3 \mathcal{L}_{cal}$$

Sens de chaque terme

$\mathcal{L}_{cls}$: apprendre la bonne classe.

$\mathcal{L}_{loc}$: contraindre la heatmap à rester cliniquement plausible.

$\mathcal{L}_{cons}$: garder une prédiction stable sous augmentation.

$\mathcal{L}_{cal}$: mieux aligner confiance prédite et fréquence réelle d'erreur.

Exemple : sur un dataset déséquilibré, $\mathcal{L}_{cls}$ peut être une Focal Loss afin de mieux traiter les cas rares ou difficiles.




Figure 10: Schéma de la perte totale et de ses composantes

Solution proposée — Étape 9 : sortie clinique

Role : Montrer comment les sorties du modèle deviennent une aide concrète pour le workflow médical **Etape du projet :** Validation métier / déploiement

Sortie exploitable pour le clinicien

Pour une image X , le modèle renvoie :

$$(p(y = 1|X), L^c, u)$$

soit un score de pneumonie, une heatmap explicative et une estimation d'incertitude.

Comment cela aide le clinicien.

- score élevé + faible incertitude : cas à prioriser ;
- score modéré + incertitude élevée : revue humaine prioritaire ;
- score faible + faible incertitude : cas probablement normal.

Limite : une heatmap plausible reste un support de lecture, pas une preuve diagnostique.




Figure 11: Sortie finale utilisable par le clinicien

Implémentation — Dataset Chest X-Ray

Role : Justifier la sélection et les caractéristiques des données d'apprentissage **Etape du projet :** Préparation des données

Spécifications & Accès aux données

Dataset Kaggle de Paul Mooney (5 856 images).

- **Classes :** *NORMAL* vs *PNEUMONIA*.
- **Défi :** Déséquilibre fort (plus de cas malades).
- **Choix :** Utilisation de la *Focal Loss* pour corriger le biais de majorité et focaliser sur les cas difficiles.



Lien Kaggle :
(Scanner pour accéder
au dataset)




Figure 12: Répartition et flux des données d'imagerie

Implémentation — Les Modules de Code (API)

Role : Documenter les scripts métiers Python principaux et leurs relations

Etape du projet : Architecture Logicielle

Cœur Algorithmique

preprocessing.py & dataset.py : Pipeline de normalisation (CLAHE) et orchestration PyTorch *DataLoaders* fournissant des batchs au GPU en parallèle.

model.py & losses.py : Définition déclarative de la double branche (CNN + Swin + Gate) et des équations de la fonction *Objective* (Focal Loss, ...).

inference.py : API finale (MedFusionInference) destinée au clinicien : génère le score, calcule l'incertitude via MC-Dropout en 20 passes rapides, puis tisse la masque explicative (Heatmap).




Figure 13: Interaction logique entre les fichiers source principaux

Implémentation — API REST locale

Role : Montrer comment le moteur d'inférence a été exposé à des clients externes sans casser l'interface web
projet : Architecture Logicielle

Etape du

Composants d'exposition

api.py : Blueprint Flask sous `/api/v1` exposant `/health`, `/predict`, `/predict/gradcam` et `/benchmark`.


app.py : Enregistre le Blueprint sans toucher aux routes HTML déjà utilisées par l'interface Flask.

service.py : Conserve `model_store` : le chargement du checkpoint reste **lazy** et partagé.

client.py : CLI local pour tester l'API, afficher les métriques et exporter les images Grad-CAM.

Intérêt pratique

- même moteur d'inférence pour le navigateur, curl et les scripts externes ;
- point d'intégration propre pour une future interface plus riche ;
- smoke tests simples via `/api/v1/health` et le client CLI.



Implémentation — Workflow d'une requête API

Rôle : Expliquer le cycle complet d'une requête, la validation de l'image et la structure des réponses JSON

projet : Déploiement local / intégration

Etape du

Cycle de traitement

- 1 Entrée : multipart/form-data ou octets image bruts.
- 2 Validation : extension autorisée, ouverture PIL conversion RGB.
- 3 Traitement : `engine.predict(...)` ou `run_benchmark(max_images)`.
- 4 Sortie : réponse **JSON** avec probabilités, métadonnées et temps d'inférence.

Routes exposées

- GET `/api/v1/health`
- POST `/api/v1/predict`
- POST `/api/v1/predict/gradcam`
- GET `/api/v1/benchmark?max_images=20`

Choix d'implémentation

- `/predict` : score simple, sans heatmap.
- `/predict/gradcam` : overlay et heatmap en PNG Base64.
- `/benchmark` : métriques seulement, graphes exclus.

Exemples d'appel

```
curl /api/v1/health
```

```
curl -X POST /api/v1/predict  
-F "image=@radio.jpeg"
```

```
python client.py predict image.jpeg  
--gradcam --save overlay.png
```

Implémentation — Exécution et Hyperparamètres

Role : Justifier les variables d'ajustement du code lors de l'apprentissage **Etape du projet :** Lancement de l'Entraînement

Lancement via `train.py`

L'exécution de l'entraînement a été finement calibrée sur l'environnement Colab :

- `--epochs 50` : Temps de chauffe suffisant pour stabiliser le réseau Transformer.
- `--batch_size 16` : Contrainte optimale GPU allégeant la VRAM tout en maintenant le batch normalization fonctionnel.
- `--lr 1e-4` & **AdamW** : Taux d'apprentissage modéré afin d'éviter l'oubli catastrophique du pré-entraînement CNN.




Figure 14: Flux d'exécution de l'entraînement et enregistrements

Résultats obtenus — synthèse quantitative

Rôle : Donner les performances finales du modèle sur le jeu de test et les interpréter **Etape du projet :** Évaluation finale

Protocole d'évaluation

- **Jeu de test final :** 624 radiographies.
- **Répartition :** 234 cas NORMAL et 390 cas PNEUMONIA.
- **Checkpoint évalué :**
Model_19Apr26.pth.

Indicateurs globaux

- **Accuracy :** 92.79%
- **AUC-ROC :** 0.976
- **Average Precision :** 0.984
- **Erreurs totales :** 45 images sur 624 seulement

Classe PNEUMONIA

- **Recall / Sensibilité :** 96.92%
- **Precision :** 91.97%
- **F1-score :** 94.38%

Classe NORMAL

- **Recall / Spécificité :** 85.90%
- **Precision :** 94.37%
- **F1-score :** 89.93%

Résultats obtenus — matrice de confusion et lecture métier

Rôle : Expliquer précisément où le modèle se trompe et pourquoi ces erreurs comptent
détaillée des sorties

Etape du projet : Analyse

Matrice de confusion

Vrai / Prédit	NORMAL	PNEUMONIA
NORMAL	201	33
PNEUMONIA	12	378

Bilan chiffré

- **Vrais positifs :** 378
- **Vrais négatifs :** 201
- **Faux positifs :** 33
- **Faux négatifs :** 12

Interprétation





- Sur **390** cas de pneumonie, le système en détecte **378**.
- Le taux de cas pneumonie manqués est de $12 / 390 = 3.08\%$.
- Sur **234** images normales, **33** sont surclassées à tort en pneumonie.
- Le modèle est donc **volontairement plus sensible que spécifique** : il déclenche plus facilement une alerte plutôt que de laisser passer une pneumonie.
- En contexte de triage, ce compromis reste **cohérent médicalement**.

Résultats obtenus — benchmark visuel sur le jeu de test

Role : Montrer visuellement la qualité de séparation du modèle à l'échelle du test complet **Etape du projet :** Benchmark final

Benchmark final — Test set (624 images)

Accuracy 92.79% | AUC 0.976 | AP 0.984 | Recall pneumo 96.92%



TN=201 FP=33 FN=12 TP=378

Ce que montrent les courbes

- **ROC** : courbe très proche du coin supérieur gauche.
- **PR** : AP = **0.984**, donc très bon classement des cas pneumonie.
- Les scores sont **bien séparés** ; peu d'ambiguïté autour du seuil 0.5.

Résultats obtenus — comportement durant l'entraînement

Role : Lire les courbes d'apprentissage et signaler les limites de validation

Etape du projet : Analyse du run conservé



Lecture des courbes


- La **train loss** baisse régulièrement : le modèle apprend effectivement.
- La **val loss** oscille davantage : la validation est plus instable.
- Les métriques montent vite, mais la validation ne contient que **16 images**.
- La conclusion finale doit donc s'appuyer sur le **test set à 624 images**.

Résultats obtenus — validation qualitative par Grad-CAM

Role : Montrer comment l'explicabilité visuelle aide à valider le comportement du modèle
Interprétabilité

Etape du projet :

GradCAM — What MedFusionNet sees in each X-ray



Ce que l'on observe

- Les activations se concentrent surtout sur les **champs pulmonaires** et sur des zones cohérentes avec des opacités.
- Le modèle ne semble pas décider uniquement à partir des bords ou du fond de l'image.
- Grad-CAM aide à expliquer **où** le réseau regarde, mais reste un **outil qualitatif**.

Finalisation du projet

Rôle : Résumer les livrables concrets du projet et la suite logique **Etape du projet :** Clôture / mise en production locale

Livrables finalisés

- **Modèle final entraîné** et checkpoint exporté.
- **Runtime Python** modulaire avec CLI et API locale.
- **Interface web Flask** pour charger une image, lancer l'inférence et voir le Grad-CAM.
- **Benchmark local** avec ROC, PR, matrice de confusion et distribution des scores.

Conclusion technique

- Le système est **fonctionnel de bout en bout**.
- Les performances sont **suffisamment fortes** pour démontrer la viabilité de l'approche hybride Swin + DenseNet.
- Le compromis retenu favorise la **détection des cas positifs**, ce qui est cohérent avec l'objectif médical.

Améliorations futures

- augmenter la taille du jeu de validation
- renforcer la spécificité
- tester sur un dataset externe et améliorer la calibration