



Présentation PFA: Détection de pneumonie sur radiographie

Conception, Modélisation et Développement.

HANFAOUI Karim¹ KAFIF. Imane²

¹EMSI, 4ème Année IADO G2 -
Karim.Hanfaoui@emsi-edu.ma

²EMSI, 4ème Année IADO G2 -
Imane.Kafif@emsi-edu.ma

EMSI Les Orangers, Mars 2026

Table des Matières

Role : Présenter la structure complète du rapport et l'ordre des étapes

Etape du projet : Navigation / cadrage global

- 1 **Problématique et Méthodologie**
 - Entrepreneuriat et valorisation
 - Phase 4 — Confiance et explicabilité
- 2 **Solution proposée**
 - Architecture et conception
 - Pipeline détaillé
 - Implémentation et Outils techniques
- 3 **Résultats et Finalisation**

Role : Poser le besoin clinique, la question de recherche et la contrainte d'explicabilité scientifique

Etape du projet : Cadrage


Question Centrale de Recherche

Face à la complexité visuelle des pathologies pulmonaires et à la pénurie mondiale de radiologues experts, comment pouvons-nous concevoir un système automatisé basé sur le Deep Learning capable non seulement de détecter la pneumonie avec une précision clinique supérieure à l'interprétation humaine, mais aussi de fournir une justification visuelle explicable afin de garantir une intégration sécurisée et fiable dans le flux de travail médical d'urgence ?

Méthodologie : Approche Agile (Scrum)

Role : Montrer comment le projet est découpé en phases de travail et d'itération
planification

Etape du projet : Organisation /



- **Flexibilité :** Adaptation aux contraintes des données médicales.
- **Itérations :** Optimisation progressive des hyperparamètres.

Gestion de Projet — Tableau des Tâches (PFA)

Role : Détailler les tâches, leur charge et le type exact de liaison temporelle **Etape du projet :** Organisation / planification

Le tableau ci-dessous affine la planification en ajoutant les décalages et les relations PERT.

ID	Nom de la Tâche	Durée	Antécédent(s) + liaison
A	Cadrage et problématique clinique	3 j	—
B	Analyse SOTA CNN (DenseNet / CheXNet)	4 j	A (0FD)
C	Analyse SOTA Swin Transformer / ViT	4 j	A (0FD)
D	Étude d'explicabilité XAI et lecture Grad-CAM	2 j	B (1DD), C (0FF)
E	Prétraitement $T(X)$, resize et normalisation	5 j	A (0FD)
F	Développement de la branche locale CNN	6 j	B (0FD), E (0FD)
G	Développement de la branche globale Swin	7 j	C (0FD), E (0FD)
H	Intégration du module de gated fusion	5 j	F (0FD), G (0FD)
I	Sortie clinique Ψ : score + incertitude	4 j	H (0FD)
J	Configuration GPU / Colab / environnement	2 j	A (1DD)
K	Entraînement, calibration et optimisation	10 j	I (0FD), J (0FD)
L	Évaluation finale, benchmark et métriques	3 j	K (0FD)
M	Finalisation rapport, slides et démonstration	5 j	L (0FD), D (0FD)

Lecture de la notation

Exemple : 0FD signifie *Fin-Début sans décalage*, 1DD signifie *Début-Début avec 1 jour de décalage*. La notation générale est : [décalage] + [type de liaison].

Gestion de Projet — Typologie des Dépendances PERT

Role : Préciser les quatre types de relations temporelles utilisés dans un ordonnancement PERT
Organisation / planification

Etape du projet :

FD — Fin à Début

La tâche successeur démarre après la fin de la tâche précédente.

Exemple projet : $A \rightarrow B = 0FD$.

FF — Fin à Fin

La fin de la tâche successeur est contrainte par la fin d'une autre tâche.

Exemple projet : $C \rightarrow D = 0FF$.

DD — Début à Début

La tâche successeur peut commencer après le début du précédent, avec un éventuel décalage.

Exemple projet : $A \rightarrow J = 1DD$.

DF — Début à Fin

Relation plus rare : la fin d'une tâche dépend du début d'une autre.

Exemple de notation : 2DF. Elle est documentée dans la méthode, mais non structurante ici.

Lecture managériale

Dans MedFusionNet, la planification repose surtout sur des relations **FD** pour sécuriser les jalons de validation, avec des liaisons **DD** et **FF** pour modéliser les travaux menés en parallèle sans perdre la cohérence globale.

Méthodologie — Analyse du Réseau de PERT

Role : Interpréter les dates, les marges et les zones critiques du planning **Etape du projet :** Organisation / planification

Principes de lecture

- Le réseau PERT calcule des dates au plus tôt et au plus tard pour chaque activité.
- L'écart entre ces deux positions donne la flexibilité réelle de la tâche.
- Une activité sans marge devient immédiatement sensible à tout retard.
- Les relations **FD**, **DD** et **FF** modifient directement les dates admissibles.

Lecture des dépendances

- **B** et **C** sont lancées en parallèle après **A**.
- **J** démarre en **1DD** pour préparer l'infrastructure sans attendre la fin complète du cadrage.
- **D** démarre tôt, mais se ferme en même temps que **C** via la contrainte **OFF**.

Méthodologie — Lecture du Chemin Critique

Role : Mettre en avant les tâches à marge nulle et les points de pilotage du projet
planification

Etape du projet : Organisation /

Interprétation projet

- **H** concentre la convergence des deux branches **F** et **G**.
- **K** attend simultanément la sortie clinique **I** et l'environnement **J**.
- **D** et **J** restent importantes, mais elles ne pilotent pas la date finale.

Lecture managériale

- Les nœuds critiques pilotent directement la livraison finale.
- Les tâches quasi critiques, comme **C** et **F**, doivent rester sous surveillance.
- Les activités très flexibles, comme **D** et **J**, absorbent les aléas sans casser le planning.

Conséquence managériale

Priorité de pilotage : toute dérive sur une tâche à marge nulle décale immédiatement la démonstration finale.

Chemin critique

A → E → G → H → I → K → L → M

Durée totale estimée : 42 jours

Gestion de Projet — Interprétation Opérationnelle

Role : Transformer le planning théorique en lecture de pilotage concrète pour le projet **Etape du projet** : Organisation / planification

Hypothèses de conduite

- Le cadrage **A** alimente rapidement l'état de l'art et le prétraitement pour éviter un démarrage séquentiel trop long.
- Les branches **F** et **G** sont parallélisées afin de réduire la durée totale avant l'étape de fusion.
- L'environnement **J** démarre tôt et l'entraînement **K** reste le lot le plus long, car il concentre essais, calibration et choix du meilleur checkpoint.

Lecture de risque

- Le verrou principal est la séquence **E-G-H-I-K**, car elle relie directement données, architecture et validation du modèle.
- Un retard sur **D** ou **J** reste absorbable grâce aux marges, alors qu'un retard sur **H** ou **K** décale toute la démonstration.
- Les tâches à faible marge, comme **C** et **F**, restent à surveiller, tandis que **L** et **M** sécurisent la transformation du travail technique en livrables académiques.

Message clé

Le planning montre que la réussite du PFA dépend moins du nombre de tâches que de la bonne maîtrise des quelques étapes critiques qui structurent tout le projet.

Gestion de Projet — Tableau des Marges

Role : Quantifier la flexibilité de chaque tâche à travers la marge libre et la marge totale **Etape du projet :** Organisation / planification

ID	A	B	C	D	E	F	G	H	I	J	K	L	M
ML	0	1	0	30	0	1	0	0	0	21	0	0	0
MT	0	2	1	30	0	1	0	0	0	21	0	0	0

ML = marge libre ; **MT** = marge totale. Les tâches critiques vérifient **ML = MT = 0**, tandis que **D** et **J** concentrent l'essentiel de la souplesse du planning.

Méthodologie — Schéma du Réseau de PERT

Role : Visualiser le réseau PERT avec les décalages, les convergences et le chemin critique
Organisation / planification

Etape du projet :





Figure 1: Réseau PERT de MedFusionNet avec liaisons temporelles annotées et chemin critique mis en évidence.

Gestion de Projet — Diagramme de Gantt

Rôle : Projeter le planning sur un calendrier opérationnel tout en respectant les liaisons DD, FD et FF **Etape du projet :** Organisation / planification



Entrepreneuriat — Vision de valorisation

Role : Introduire simplement comment une idee technique peut devenir un projet entrepreneurial
Ouverture business / entrepreneuriat

Etape du projet :

Le point de depart

- Les hopitaux et centres d'imagerie doivent traiter beaucoup d'examens en peu de temps.
- Une radiographie thoracique peut etre difficile a interpreter rapidement.
- Un outil d'aide peut donc avoir une vraie utilite pratique.

Notre idee

- signaler les cas suspects,
- aider a prioriser les urgences,
- montrer une explication visuelle.

Ce que l'on vend

- une aide au triage,
- une aide a la lecture,
- un service utile pour les structures medicales.

Idee cle

On ne vend pas un “medecin automatique”, mais une **solution d'assistance** qui aide les professionnels a travailler plus vite et plus sereinement.

Entrepreneuriat — A qui vendre le projet ?

Role : Identifier les clients potentiels avec un vocabulaire simple **Etape du projet** : Etude de marche / premiers concepts

Clients potentiels

- hopitaux publics et privés,
- cliniques,
- centres de radiologie,
- plateformes de teleradiologie.

Leur besoin

- gagner du temps,
- mieux organiser les priorites,
- reduire le risque d'oubli,
- utiliser un outil simple.

Comment presenter le projet ?

Comme une **aide au triage**, une **seconde lecture** et un **outil explicable** pour la radiographie thoracique.

Positionnement

Le projet se vend en **B2B** : a des etablissements de sante, et non directement au grand public.

Entrepreneuriat — Comment vendre concrètement le projet ?

Role : Montrer simplement les etapes commerciales possibles **Etape du projet :** Demarche commerciale / entrepreneuriat debutant

Etapes simples

- 1 **Presenter le probleme** du client
- 2 **Montrer une demonstration** du systeme
- 3 **Proposer un petit pilote**
- 4 **Recueillir les retours**
- 5 **Transformer le test en offre**



A retenir

Pour un premier cours d'entrepreneuriat, il suffit deja de montrer **qui peut acheter, comment tester** et **comment vendre**.

Entrepreneuriat — Budget simple et modalites de vente

Role : Donner une vision accessible du budget et des revenus possibles
modele simple

Etape du projet : Faisabilite economique /

Poste	Estimation
Hebergement / cloud / GPU	30 000 MAD
Developpement / amelioration	50 000 MAD
Tests / pilote / documentation	25 000 MAD
Communication / déplacement	20 000 MAD
Total simplifie	125 000 MAD

Modes de vente

- pilote payant,
- abonnement mensuel,
- licence annuelle.

Exemple simple

- Pilote : 10 000 a 20 000 MAD
- Abonnement : 3 000 a 6 000 MAD / mois


Lecture entrepreneuriale

Pour notre niveau, l'essentiel est de montrer qu'il existe un **marche possible**, un **mode de vente simple** et un **budget de depart raisonnable**.

Phase 4 — Grad-CAM : schéma de génération

Role : Visualiser le pipeline complet de production d'une heatmap explicative
évaluation interprétable

Etape du projet : Analyse SOTA /



Lecture : l'overlay montre les régions activées associées à la classe prédite.

Solution proposée — Étape 0 : vue d'ensemble

Role : Présenter la logique globale du modèle avant le détail des étapes

Etape du projet : Conception de la solution

Principe et formule globale

MedFusionNet combine deux lectures d'une même radiographie :

- une branche **CNN** pour les indices locaux : contours, textures, petites opacités ;
- une branche **Swin** pour le contexte global : symétrie thoracique, bilatéralité, cohérence anatomique ;
- une **fusion guidée** qui pondère automatiquement les deux branches.

Chaîne mathématique.

$$\tilde{X} = T(X)$$

$$F_c = \Phi_c(\tilde{X}), \quad F_s = \Phi_s(\tilde{X})$$

$$g = \sigma(W_g[\text{GAP}(F_c), \text{GAP}(F_s)] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

La sortie finale vérifie $\Psi(F) = (p, L^c, u)$: score p , heatmap L^c , incertitude u .




Figure 2: Vue d'ensemble du pipeline complet

Solution proposée — Étape 1 : échantillon d'entrée

Role : Définir la donnée d'entrée et ce qu'elle contient avant tout calcul

Etape du projet : Conception détaillée

Image et variabilité

Une radiographie thoracique est modélisée par :

$$X \in \mathbb{R}^{H \times W}$$

avec une étiquette binaire :

$$\begin{cases} y = 1 & \text{pneumonie} \\ y = 0 & \text{normal ou autre classe négative} \end{cases}$$

Pourquoi l'entrée est difficile. L'image brute contient à la fois le signal clinique et des facteurs parasites :

- variations d'intensité et de contraste selon l'appareil ;
- bruit, annotations, câbles et autres artefacts ;
- cadrage, résolution et structures normales parfois trompeuses.

Exemple : deux clichés de même classe peuvent avoir un contraste ou un centrage très différents ; le modèle doit ignorer cette variabilité non pathologique.




Figure 3: Échantillon brut provenant du dataset

Solution proposée — Étape 2 : prétraitement

Role : Standardiser l'image avant son entrée dans les deux branches du modèle
préparation des données

Etape du projet : Développement /

Transformation

Le prétraitement applique une chaîne de standardisation :

$$\tilde{X} = T(X) = A(R(N(X)))$$

où N normalise les intensités, R redimensionne et A peut améliorer localement le contraste.

Ce que la donnée devient

normalisation :
$$X_{norm} = \frac{X - \mu}{\sigma}$$

redimensionnement :
$$X \in \mathbb{R}^{H \times W} \longrightarrow \tilde{X} \in \mathbb{R}^{H_0 \times W_0}$$

Exemple : $1024 \times 1024 \rightarrow 384 \times 384$. Cette étape réduit le coût mémoire, homogénéise les entrées et diminue le risque que le modèle prenne une différence d'acquisition pour une pneumonie.




Figure 4: Image après normalisation et redimensionnement

Solution proposée — Étape 3 : branche CNN locale

Role : Extraire les motifs fins et localisés par une lecture convolutive **Etape du projet :** Modélisation de la branche locale

Lecture locale par CNN

La branche locale produit :

$$F_c = \Phi_c(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_c}$$

Une convolution applique un filtre sur un voisinage restreint :



$$F_{i,j,c'}^{(\ell)} = \sum_{u,v,c} W_{u,v,c,c'}^{(\ell)} F_{i+u,j+v,c}^{(\ell-1)} + b_{c'}^{(\ell)}$$

Ce que la branche voit réellement.

- bords pleuraux, côtes, contours pulmonaires ;
- textures diffuses ou focales ;
- petites consolidations et opacités locales ;
- transitions fines entre tissu sain et tissu suspect.

Exemple : une opacité basale discrète peut être amplifiée par la comparaison locale entre intensités voisines.

Image / Feature Map



Couche suivante

Champ récepteur local ($k \times k$)

Figure 5: Représentation locale extraite par la branche CNN

Solution proposée — Étape 4 : branche Swin globale

Role : Extraire une représentation de contexte capable de relier des régions éloignées **Etape du projet :** Modélisation de la branche globale

Lecture globale par Swin

L'image prétraitée est découpée en patches puis projetée :

$$z_i = E x_i + e_i^{pos}$$

La branche globale calcule ensuite :


$$F_s = \Phi_s(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_s}$$

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Dans Swin, cette attention est calculée par fenêtres, puis les fenêtres sont décalées pour reconnecter les régions voisines. **Ce que la branche globale apporte.** Elle relie des zones éloignées : apex, bases, hémithorax droit/gauche, médiastin. Si une anomalie n'a de sens que par sa **distribution spatiale**, Swin la capture mieux qu'un CNN purement local.

**Attention Globale
(Longue distance)**



Patches d'image

Figure 6: Représentation globale extraite par la branche Swin

Solution proposée — Étape 5 : fusion guidée

Role : Combiner les indices locaux et globaux sans imposer un poids fixe à chaque branche **Etape du projet :** Conception du coeur de fusion

Porte de fusion et interprétation

On résume d'abord chaque branche par un vecteur global :

$$\bar{F}_c = \text{GAP}(F_c), \quad \bar{F}_s = \text{GAP}(F_s)$$

Puis on apprend un coefficient de fusion :

$$g = \sigma(W_g[\bar{F}_c, \bar{F}_s] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si $g \approx 1$, le modèle privilégie l'indice local ; si $g \approx 0$, il privilégie le contexte global. **Exemples. Exemple 1** : foyer net et compact $\Rightarrow g \approx 0.8$.

Exemple 2 : atteinte diffuse ou bilatérale $\Rightarrow g \approx 0.3$.

La fusion n'est donc pas une moyenne fixe : elle s'adapte à la structure réelle de l'image.




Figure 7: Fusion adaptative entre la branche locale et la branche globale

Solution proposée — Étape 6 : classification

Role : Transformer la représentation fusionnée en probabilité de pneumonie

Etape du projet : Tête de décision

Score de classe

La représentation fusionnée est condensée en un vecteur :

$$z = \text{GAP}(F)$$

puis convertie en probabilité :

$$p(y = 1|X) = \sigma(w^\top z + b)$$

Décision pratique

Avec un seuil τ :

$$\hat{y} = \begin{cases} 1 & \text{si } p(y = 1|X) \geq \tau \\ 0 & \text{sinon} \end{cases}$$

Exemple : si $p = 0.91$ et $\tau = 0.5$, la prédiction est positive avec une forte marge. Si $p = 0.54$, la décision reste positive mais devient fragile : elle doit être lue avec la heatmap et l'incertitude.




Figure 8: Passage de la représentation fusionnée au score de classe

Solution proposée — Étape 7 : localisation et incertitude

Role : Produire une explication spatiale et mesurer la fiabilité de la décision

Etape du projet : Sorties interprétables

Localisation et incertitude

À partir des cartes finales A^k :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

$$L^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right)$$

La heatmap montre **où** le modèle a trouvé des indices pour la classe prédite. **Incertainité**. En répétant plusieurs passes avec dropout actif :

$$u = \text{Var}_t(p_t)$$

Exemple : si $p_t = \{0.87, 0.88, 0.89\}$, la variance est faible ; si $p_t = \{0.42, 0.81, 0.57\}$, la décision est instable et doit être relue.




Figure 9: Heatmap explicative et estimation d'incertitude

Solution proposée — Étape 8 : apprentissage

Role : Définir exactement ce qui est optimisé pendant l'entraînement **Etape du projet :** Développement / entraînement

Fonction objectif

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{loc} + \lambda_2 \mathcal{L}_{cons} + \lambda_3 \mathcal{L}_{cal}$$

Sens de chaque terme

$\mathcal{L}_{cls}$: apprendre la bonne classe.

$\mathcal{L}_{loc}$: contraindre la heatmap à rester cliniquement plausible.

$\mathcal{L}_{cons}$: garder une prédiction stable sous augmentation.

$\mathcal{L}_{cal}$: mieux aligner confiance prédite et fréquence réelle d'erreur.

Exemple : sur un dataset déséquilibré, $\mathcal{L}_{cls}$ peut être une Focal Loss afin de mieux traiter les cas rares ou difficiles.




Figure 10: Schéma de la perte totale et de ses composantes

Solution proposée — Étape 9 : sortie clinique

Role : Montrer comment les sorties du modèle deviennent une aide concrète pour le workflow médical **Etape du projet :** Validation métier / déploiement

Sortie exploitable pour le clinicien

Pour une image X , le modèle renvoie :

$$(p(y = 1|X), L^c, u)$$

soit un score de pneumonie, une heatmap explicative et une estimation d'incertitude.

Comment cela aide le clinicien.

- score élevé + faible incertitude : cas à prioriser ;
- score modéré + incertitude élevée : revue humaine prioritaire ;
- score faible + faible incertitude : cas probablement normal.

Limite : une heatmap plausible reste un support de lecture, pas une preuve diagnostique.




Figure 11: Sortie finale utilisable par le clinicien

Implémentation — Dataset Chest X-Ray

Role : Justifier la sélection et les caractéristiques des données d'apprentissage **Etape du projet :** Préparation des données

Spécifications & Accès aux données

Dataset Kaggle de Paul Mooney (5 856 images).

- **Classes :** *NORMAL* vs *PNEUMONIA*.
- **Défi :** Déséquilibre fort (plus de cas malades).
- **Choix :** Utilisation de la *Focal Loss* pour corriger le biais de majorité et focaliser sur les cas difficiles.



Lien Kaggle :
(Scanner pour accéder
au dataset)




Figure 12: Répartition et flux des données d'imagerie

Implémentation — Les Modules de Code (API)

Role : Documenter les scripts métiers Python principaux et leurs relations

Etape du projet : Architecture Logicielle

Cœur Algorithmique

preprocessing.py & dataset.py : Pipeline de normalisation (CLAHE) et orchestration PyTorch *DataLoaders* fournissant des batchs au GPU en parallèle.

model.py & losses.py : Définition déclarative de la double branche (CNN + Swin + Gate) et des équations de la fonction *Objective* (Focal Loss, ...).

inference.py : API finale (MedFusionInference) destinée au clinicien : génère le score, calcule l'incertitude via MC-Dropout en 20 passes rapides, puis tisse la masque explicative (Heatmap).




Figure 13: Interaction logique entre les fichiers source principaux

Implémentation — API REST locale

Role : Montrer comment le moteur d'inférence a été exposé à des clients externes sans casser l'interface web
projet : Architecture Logicielle

Etape du


Composants d'exposition

api.py : Blueprint Flask sous `/api/v1` exposant `/health`, `/predict`, `/predict/gradcam` et `/benchmark`.

app.py : Enregistre le Blueprint sans toucher aux routes HTML déjà utilisées par l'interface Flask.

service.py : Conserve `model_store` : le chargement du checkpoint reste **lazy** et partagé.

client.py : CLI local pour tester l'API, afficher les métriques et exporter les images Grad-CAM.



Intérêt pratique

- même moteur d'inférence pour le navigateur, `curl` et les scripts externes ;
- point d'intégration propre pour une future interface plus riche ;
- smoke tests simples via `/api/v1/health` et le client CLI.

Implémentation — Workflow d'une requête API

Rôle : Expliquer le cycle complet d'une requête, la validation de l'image et la structure des réponses JSON
projet : Déploiement local / intégration

Etape du

Cycle de traitement

- 1 Entrée : multipart/form-data ou octets image bruts.
- 2 Validation : extension autorisée, ouverture PIL conversion RGB.
- 3 Traitement : `engine.predict(...)` ou `run_benchmark(max_images)`.
- 4 Sortie : réponse **JSON** avec probabilités, métadonnées et temps d'inférence.

Routes exposées

- GET `/api/v1/health`
- POST `/api/v1/predict`
- POST `/api/v1/predict/gradcam`
- GET `/api/v1/benchmark?max_images=20`

Choix d'implémentation

- `/predict` : score simple, sans heatmap.
- `/predict/gradcam` : overlay et heatmap en PNG Base64.
- `/benchmark` : métriques seulement, graphes exclus.

Exemples d'appel

```
curl /api/v1/health
```

```
curl -X POST /api/v1/predict  
-F "image=@radio.jpeg"
```

```
python client.py predict image.jpeg  
--gradcam --save overlay.png
```

Implémentation — Exécution et Hyperparamètres

Role : Justifier les variables d'ajustement du code lors de l'apprentissage **Etape du projet :** Lancement de l'Entraînement

Lancement via `train.py`

L'exécution de l'entraînement a été finement calibrée sur l'environnement Colab :

- `--epochs 50` : Temps de chauffe suffisant pour stabiliser le réseau Transformer.
- `--batch_size 16` : Contrainte optimale GPU allégeant la VRAM tout en maintenant le batch normalization fonctionnel.
- `--lr 1e-4` & **AdamW** : Taux d'apprentissage modéré afin d'éviter l'oubli catastrophique du pré-entraînement CNN.




Figure 14: Flux d'exécution de l'entraînement et enregistrements

Résultats obtenus — synthèse quantitative

Rôle : Donner les performances finales du modèle sur le jeu de test et les interpréter **Etape du projet :** Évaluation finale

Protocole d'évaluation

- **Jeu de test final :** 624 radiographies.
- **Répartition :** 234 cas NORMAL et 390 cas PNEUMONIA.
- **Checkpoint évalué :**
Model_19Apr26.pth.

Indicateurs globaux

- **Accuracy :** 92.79%
- **AUC-ROC :** 0.976
- **Average Precision :** 0.984
- **Erreurs totales :** 45 images sur 624 seulement

Classe PNEUMONIA

- **Recall / Sensibilité :** 96.92%
- **Precision :** 91.97%
- **F1-score :** 94.38%

Classe NORMAL

- **Recall / Spécificité :** 85.90%
- **Precision :** 94.37%
- **F1-score :** 89.93%

Résultats obtenus — matrice de confusion et lecture métier

Rôle : Expliquer précisément où le modèle se trompe et pourquoi ces erreurs comptent
détaillée des sorties

Etape du projet : Analyse

Matrice de confusion

Vrai / Prédit	NORMAL	PNEUMONIA
NORMAL	201	33
PNEUMONIA	12	378

Bilan chiffré

- **Vrais positifs :** 378
- **Vrais négatifs :** 201
- **Faux positifs :** 33
- **Faux négatifs :** 12

Interprétation





- Sur **390** cas de pneumonie, le système en détecte **378**.
- Le taux de cas pneumonie manqués est de $12 / 390 = 3.08\%$.
- Sur **234** images normales, **33** sont surclassées à tort en pneumonie.
- Le modèle est donc **volontairement plus sensible que spécifique** : il déclenche plus facilement une alerte plutôt que de laisser passer une pneumonie.
- En contexte de triage, ce compromis reste **cohérent médicalement**.

Résultats obtenus — benchmark visuel sur le jeu de test

Role : Montrer visuellement la qualité de séparation du modèle à l'échelle du test complet **Etape du projet :** Benchmark final

Benchmark final — Test set (624 images)

Accuracy 92.79% | AUC 0.976 | AP 0.984 | Recall pneumo 96.92%



TN=201 FP=33 FN=12 TP=378

Ce que montrent les courbes

- **ROC** : courbe très proche du coin supérieur gauche.
- **PR** : **AP = 0.984**, donc très bon classement des cas pneumonie.
- Les scores sont **bien séparés** ; peu d'ambiguïté autour du seuil 0.5.

Résultats obtenus — comportement durant l'entraînement

Role : Lire les courbes d'apprentissage et signaler les limites de validation

Etape du projet : Analyse du run conservé



Lecture des courbes


- La **train loss** baisse régulièrement : le modèle apprend effectivement.
- La **val loss** oscille davantage : la validation est plus instable.
- Les métriques montent vite, mais la validation ne contient que **16 images**.
- La conclusion finale doit donc s'appuyer sur le **test set à 624 images**.

Résultats obtenus — validation qualitative par Grad-CAM

Role : Montrer comment l'explicabilité visuelle aide à valider le comportement du modèle
Interprétabilité

Etape du projet :

GradCAM — What MedFusionNet sees in each X-ray



Ce que l'on observe

- Les activations se concentrent surtout sur les **champs pulmonaires** et sur des zones cohérentes avec des opacités.
- Le modèle ne semble pas décider uniquement à partir des bords ou du fond de l'image.
- Grad-CAM aide à expliquer **où** le réseau regarde, mais reste un **outil qualitatif**.

Finalisation du projet

Rôle : Résumer les livrables concrets du projet et la suite logique **Etape du projet :** Clôture / mise en production locale

Livrables finalisés

- **Modèle final entraîné** et checkpoint exporté.
- **Runtime Python** modulaire avec CLI et API locale.
- **Interface web Flask** pour charger une image, lancer l'inférence et voir le Grad-CAM.
- **Benchmark local** avec ROC, PR, matrice de confusion et distribution des scores.

Conclusion technique

- Le système est **fonctionnel de bout en bout**.
- Les performances sont **suffisamment fortes** pour démontrer la viabilité de l'approche hybride Swin + DenseNet.
- Le compromis retenu favorise la **détection des cas positifs**, ce qui est cohérent avec l'objectif médical.

Améliorations futures

- augmenter la taille du jeu de validation
- renforcer la spécificité
- tester sur un dataset externe et améliorer la calibration