

Mémoire du projet de fin d'année

Pour la validation du module PFA Semestre S1

Filière : 4IADO G2

Période : année universitaire 2025–2026

Thème : Intelligence artificielle appliquée à l'imagerie médicale

Détection de la pneumonie sur radiographie thoracique via MedFusionNet

Réalisé par :

M. HANFAOUI Karim

Mme. KAFIF Imane

Maître pédagogique :

Pr. Mdarbi Fatimaezzahra

Soutenu le [à compléter], Devant le jury composé de :

M. X Y : EMSI - Président(e)

M. X Y : EMSI - Examinateur(trice)

M. X Y : EMSI - Rapporteur

Promotion : 2025/2026

Remerciements

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet de détection de la pneumonie sur radiographie thoracique.

Je remercie tout particulièrement **Pr. Mdarbi Fatimaezzahra** pour son encadrement, ses conseils avisés et son soutien tout au long de cette aventure.

Je souhaite également remercier **l'EMSI Les Orangers** pour l'accompagnement pédagogique, l'environnement de travail et les ressources mises à disposition durant ce projet.

Enfin, une pensée sincère à nos familles et à nos proches pour leur soutien moral et leurs encouragements constants.

Karim Hanfaoui et Imane Kafif
Avril 2026

Table des matières

Remerciements	i
Résumé	vi
Abstract	vii
Liste des acronymes	viii
Introduction générale	1
Contexte	1
Problématique	1
Objectifs	1
Méthodologie	1
Plan du document	1
1 Contexte du projet	2
Terminologie et conventions de lecture	2
Contexte général, étude du besoin et méthodologie	4
Étude de l'existant	8
Phase 1 — DenseNet / CheXNet	8
Phase 2 — Optimisation et efficacité	9
Phase 3 — Vision Transformers et contexte global	11
Phase 4 — Confiance et explicabilité	13
Objectifs du projet	14
2 Conception fonctionnelle et modélisation	15
Diagrammes fonctionnels et structure logique	15
Données, nettoyage et protocole d'apprentissage	16
Architecture et conception	16
Pipeline détaillé	17
3 Conception technique et réalisation	23
Technologies, architecture et mise en œuvre	23

Tests, résultats et validation	26
Valorisation entrepreneuriale	30
Annexes	32
Références techniques	32

Liste des tableaux

1.1	Planification détaillée des tâches du projet et dépendances PERT	5
1.2	Marges libres et marges totales calculées sur le planning du projet	7
3.1	Matrice de confusion finale sur le jeu de test	27
3.2	Budget simplifié de lancement de la solution MedFusionNet	31

Table des figures

1.1	Réseau PERT de MedFusionNet avec liaisons temporelles annotées et chemin critique mis en évidence.	7
2.1	Diagramme de cas d'utilisation simplifié du système	15
2.2	Vue logique simplifiée des classes et composants du projet	16
2.3	Vue d'ensemble du pipeline complet	17
2.4	Échantillon brut provenant du dataset	17
2.5	Image après normalisation et redimensionnement	18
2.6	Représentation locale extraite par la branche CNN	18
2.7	Représentation globale extraite par la branche Swin	19
2.8	Fusion adaptative entre la branche locale et la branche globale	19
2.9	Passage de la représentation fusionnée au score de classe	20
2.10	Heatmap explicative et estimation d'incertitude	20
2.11	Schéma de la perte totale et de ses composantes	21
2.12	Sortie finale utilisable par le clinicien	21
3.1	Répartition et flux des données d'imagerie	23
3.2	Pile Technologique du système MedFusionNet	24
3.3	Arborescence du répertoire de travail (Git)	24
3.4	Interaction logique entre les fichiers source principaux	25
3.5	Flux d'exécution de l'entraînement et enregistrements	26

Résumé

Ce mémoire présente **MedFusionNet**, un système d'aide à la détection binaire de la pneumonie sur radiographie thoracique. La problématique traitée est celle de l'identification rapide et fiable de signes pathologiques dans un contexte où l'interprétation humaine peut être rendue difficile par la charge de travail, la variabilité des images et la subtilité de certains foyers pulmonaires. L'objectif du projet est de proposer une solution à la fois performante, explicable et exploitable dans un environnement local.

La méthodologie suivie combine une étude de l'existant, une conduite de projet de type agile et une conception progressive d'une architecture hybride. Le modèle retenu associe une branche **DenseNet**, chargée de capter les motifs radiographiques locaux, à une branche **Swin Transformer**, destinée à intégrer le contexte global de l'image. Ces deux représentations sont fusionnées par un mécanisme de **gated fusion**. L'ensemble est complété par un module **Grad-CAM** pour l'explicabilité, puis intégré dans une chaîne logicielle comprenant entraînement, inférence locale, API et interface web.

Les résultats obtenus sur le jeu de test final montrent une **accuracy de 92.79%**, une **AUC-ROC de 0.976** et une bonne capacité de détection des cas positifs, avec une sensibilité élevée. Le rapport couvre ainsi le contexte du projet, la modélisation, la réalisation technique, l'évaluation expérimentale et la valorisation du système.

Mots-clés : pneumonie, radiographie thoracique, Deep Learning, DenseNet, Swin Transformer, Grad-CAM, fusion multimodèle.

Abstract

This report presents **MedFusionNet**, a decision-support system for binary pneumonia detection from chest X-ray images. The project addresses the difficulty of obtaining fast and reliable interpretation in a setting where radiographs may contain subtle findings, acquisition variability, and clinically ambiguous patterns. The main objective is to design a solution that is accurate, explainable, and usable beyond a simple experimental notebook.

The adopted methodology combines state-of-the-art review, agile project management, and progressive model design. The final architecture is a hybrid network that merges a **DenseNet** branch for local texture and opacity analysis with a **Swin Transformer** branch for global anatomical context. Both feature streams are combined through a **gated fusion** mechanism that adapts their relative contribution for each image. The system is further extended with **Grad-CAM** to provide visual explanations, and packaged into a full software pipeline including training scripts, local inference, a REST API, and a web demonstration interface.

Experimental evaluation on the final test set shows strong performance, with **92.79% accuracy**, **0.976 AUC-ROC**, and high sensitivity to pneumonia cases. The report therefore covers the project context, the modelling choices, the technical implementation, the test protocol, the obtained results, and the practical value of the proposed system.

Keywords : pneumonia, chest X-ray, deep learning, DenseNet, Swin Transformer, Grad-CAM, hybrid fusion.

Liste des acronymes

Acronyme	Définition
IA	Intelligence Artificielle.
DL	Deep Learning.
CXR	Chest X-Ray, radiographie thoracique.
SOTA	State Of The Art, meilleur niveau de performance connu au moment de l'étude.
CNN	Convolutional Neural Network.
ViT	Vision Transformer.
Swin	Shifted Window Transformer.
Grad-CAM	Gradient-weighted Class Activation Mapping.
BN	Batch Normalization.
ReLU	Rectified Linear Unit.
GAP	Global Average Pooling.
FC	Fully Connected.
MBConv	Mobile Inverted Bottleneck Convolution.
SE	Squeeze-and-Excitation.
FLOPs	Floating Point Operations.
ECE	Expected Calibration Error.

Introduction générale

Contexte

La détection assistée de la pneumonie constitue un cas d’usage pertinent pour l’intelligence artificielle appliquée à l’imagerie médicale. La radiographie thoracique est un examen de première ligne, rapide et peu coûteux, mais son interprétation peut être difficile lorsque les signes sont diffus, subtils ou masqués par des artefacts d’acquisition.

Problématique

Le problème traité par ce projet est donc le suivant : *comment concevoir un système capable de détecter la pneumonie avec un bon niveau de fiabilité tout en fournissant des indices explicables sur les zones qui ont guidé la décision ?* La difficulté n’est pas seulement de classer une image, mais aussi de produire un comportement compatible avec une logique de triage clinique.

Objectifs

Les objectifs du projet sont de :

- concevoir un modèle de classification binaire **NORMAL** / **PNEUMONIA** ;
- exploiter à la fois les motifs locaux et le contexte global de l’image ;
- intégrer un mécanisme d’explicabilité visuelle avec Grad-CAM ;
- rendre le système exploitable via scripts d’entraînement, inférence locale, API et interface web.

Méthodologie

La démarche adoptée combine une étude bibliographique des approches SOTA, une conduite de projet inspirée d’une logique agile, une phase de conception d’architecture hybride, puis une phase de réalisation et d’évaluation expérimentale. Cette méthodologie permet de relier les choix théoriques aux contraintes concrètes de données, de calcul et de validation.

Plan du document

Le rapport est structuré en quatre grandes parties : le contexte du projet et l’étude de l’existant, la conception fonctionnelle et la modélisation, la conception technique et la réalisation, puis la conclusion avec les perspectives et la valorisation possible du projet.

Chapitre 1

Contexte du projet

Terminologie et conventions de lecture

Acronymes — Domaine et modèles

Rôle : Donner les sigles du domaine avant les slides techniques **Étape du projet :** Référence documentaire

Domaine médical et IA	Modèles et approches
IA : Intelligence Artificielle. DL : Deep Learning, famille de modèles à plusieurs couches. CXR : Chest X-Ray, radiographie thoracique. SOTA : State Of The Art, meilleur niveau connu au moment de l'étude.	CNN : Convolutional Neural Network, réseau fondé sur les convolutions. ViT : Vision Transformer, adaptation du Transformer aux images. Swin : Shifted Window Transformer, Transformer hiérarchique à fenêtres décalées. Grad-CAM : Gradient-weighted Class Activation Mapping, outil d'explicabilité visuelle.

Acronymes — Blocs techniques

Rôle : Définir les sigles techniques utilisés dans les architectures et l'évaluation **Étape du projet :** Référence documentaire

Architecture	Efficacité et confiance
BN : Batch Normalization, normalisation des activations sur un mini-batch. ReLU : Rectified Linear Unit, activation $f(x) = \max(0, x)$. GAP : Global Average Pooling, moyenne spatiale par canal. FC : Fully Connected, couche dense finale de décision.	MBConv : Mobile Inverted Bottleneck Convolution, bloc compact d'EfficientNet. SE : Squeeze-and-Excitation, mécanisme de ré pondération des canaux. FLOPs : Floating Point Operations, estimation du coût de calcul. ECE : Expected Calibration Error, mesure de calibration des probabilités.

Notations mathématiques

Rôle : Définir les notations qui reviennent dans les équations et les schémas **Étape du projet :** Référence documentaire

Tailles et dimensions	Variables de modélisation
H, W : Hauteur et largeur spatiales d'une image ou d'une carte de features. C : Nombre de canaux. L : Nombre de couches ou de blocs, selon le contexte. k : Growth rate DenseNet, nombre de nouveaux canaux ajoutés par couche.	ϕ : Facteur global de scaling dans EfficientNet. X : Image d'entrée. F : Tensor de features appris par le modèle. $p(y X)$: Probabilité prédite pour une classe y conditionnée par l'image X .

Terminologie d'architecture

Rôle : Définir les termes techniques utilisés sans alourdir les slides principales **Étape du projet :** Référence documentaire

CNN et représentations	Transformers et fiabilité
Feature map : Carte d'activation produite par un bloc du réseau. Backbone : Extracteur principal de représentations d'une architecture. Bottleneck : Réduction intermédiaire des canaux pour baisser le coût. Skip connection : Chemin de contournement transmettant une information plus tôt dans le réseau.	Token : Unité d'entrée d'un Transformer, ici un patch projeté. Embedding : Représentation vectorielle dense d'un objet discret ou local. Calibration : Adéquation entre probabilité annoncée et fréquence réelle de succès. Heatmap : Carte colorée montrant des zones activées ou importantes pour la décision.

Guide de lecture du document

Rôle : Préciser le rôle exact de chaque groupe de slides dans la fabrication du projet **Étape du projet :** Lecture guidée du rapport

Cadrage	Validation
Problématique / Méthodologie : Définir le besoin clinique, la question scientifique et l'organisation du travail. Analyse SOTA : Comparer les approches existantes avant de choisir une direction.	Résultats : Mesurer la performance finale et lire les indicateurs. Annexes : Documenter les notions techniques non développées dans le flux principal.
Conception	Principe de lecture
Solution proposée : Définir l'architecture cible, sa logique et ses sorties.	Chaque slide technique indique explicitement : — son role dans le document, — l' etape du projet à laquelle il appartient.

Contexte général, étude du besoin et méthodologie

Problématique


Rôle : Poser le besoin clinique, la question de recherche et la contrainte d'explicabilité **Étape du projet** : Cadrage scientifique

Question Centrale de Recherche

Face à la complexité visuelle des pathologies pulmonaires et à la pénurie mondiale de radiologues experts, comment pouvons-nous concevoir un système automatisé basé sur le Deep Learning capable non seulement de détecter la pneumonie avec une précision clinique supérieure à l'interprétation humaine, mais aussi de fournir une justification visuelle explicable afin de garantir une intégration sécurisée et fiable dans le flux de travail médical d'urgence ?

Méthodologie : Approche Agile (Scrum)

Rôle : Montrer comment le projet est découpé en phases de travail et d'itération **Étape du projet** : Organisation / planification



— **Flexibilité** : Adaptation aux contraintes des données médicales.

— **Itérations** : Optimisation progressive des hyperparamètres.

Gestion de Projet — Tableau des Tâches (PFA)

Rôle : Détailler les tâches, leur charge et le type exact de liaison temporelle **Étape du projet** : Organisation / planification

Le tableau ci-dessous affine la planification en ajoutant les décalages et les relations

PERT.	ID	Nom de la Tâche	Durée	Antécédent(s) + liaison
	A	Cadrage et problématique clinique	3 j	—
	B	Analyse SOTA CNN (DenseNet / CheXNet)	4 j	A (0FD)
	C	Analyse SOTA Swin Transformer / ViT	4 j	A (0FD)
	D	Étude d'explicabilité XAI et lecture Grad-CAM	2 j	B (1DD), C (0FF)
	E	Prétraitement $T(X)$, resize et normalisation	5 j	A (0FD)
	F	Développement de la branche locale CNN	6 j	B (0FD), E (0FD)
	G	Développement de la branche globale Swin	7 j	C (0FD), E (0FD)
	H	Intégration du module de gated fusion	5 j	F (0FD), G (0FD)
	I	Sortie clinique Ψ : score + incertitude	4 j	H (0FD)
	J	Configuration GPU / Colab / environnement	2 j	A (1DD)
	K	Entraînement, calibration et optimisation	10 j	I (0FD), J (0FD)
	L	Évaluation finale, benchmark et métriques	3 j	K (0FD)
	M	Finalisation rapport, slides et démonstration	5 j	L (0FD), D (0FD)

Table 1.1. Planification détaillée des tâches du projet et dépendances PERT

Lecture de la notation

Exemple : 0FD signifie *Fin-Début sans décalage*, 1DD signifie *Début-Début avec 1 jour de décalage*. La notation générale est : [décalage] + [type de liaison].

Gestion de Projet — Typologie des Dépendances PERT

Rôle : Préciser les quatre types de relations temporelles utilisés dans un ordonnancement PERT **Étape du projet** : Organisation / planification

FD — Fin à Début	FF — Fin à Fin
La tâche successeure démarre après la fin de la tâche précédente. Exemple projet : $A \rightarrow B = 0FD$.	La fin de la tâche successeure est contrainte par la fin d'une autre tâche. Exemple projet : $C \rightarrow D = 0FF$.
DD — Début à Début	DF — Début à Fin
La tâche successeure peut commencer après le début du précédent, avec un éventuel décalage. Exemple projet : $A \rightarrow J = 1DD$.	Relation plus rare : la fin d'une tâche dépend du début d'une autre. Exemple de notation : 2DF. Elle est documentée dans la méthode, mais non structurante ici.

Lecture managériale

Dans MedFusionNet, la planification repose surtout sur des relations **FD** pour sécuriser les jalons de validation, avec des liaisons **DD** et **FF** pour modéliser les travaux menés en parallèle sans perdre la cohérence globale.

Méthodologie — Analyse du Réseau de PERT

Rôle : Interpréter les dates, les marges et les zones critiques du planning **Étape du projet :** Organisation / planification

Principes de lecture	Lecture des dépendances
— Le réseau PERT calcule des dates au plus tôt et au plus tard pour chaque activité. — L'écart entre ces deux positions donne la flexibilité réelle de la tâche. — Une activité sans marge devient immédiatement sensible à tout retard. — Les relations FD, DD et FF modifient directement les dates admissibles.	— B et C sont lancées en parallèle après A. — J démarre en 1DD pour préparer l'infrastructure sans attendre la fin complète du cadrage. — D démarre tôt, mais se ferme en même temps que C via la contrainte OFF.

Méthodologie — Lecture du Chemin Critique

Rôle : Mettre en avant les tâches à marge nulle et les points de pilotage du projet **Étape du projet :** Organisation / planification

Interprétation projet	Lecture managériale
— H concentre la convergence des deux branches F et G. — K attend simultanément la sortie clinique I et l'environnement J. — D et J restent importantes, mais elles ne pilotent pas la date finale.	— Les nœuds critiques pilotent directement la livraison finale. — Les tâches quasi critiques, comme C et F, doivent rester sous surveillance. — Les activités très flexibles, comme D et J, absorbent les aléas sans casser le planning.

Conséquence managériale

Priorité de pilotage : toute dérive sur une tâche à marge nulle décale immédiatement la démonstration finale.

Chemin critique
A → E → G → H → I → K → L → M Durée totale estimée : 42 jours

Gestion de Projet — Interprétation Opérationnelle

Rôle : Transformer le planning théorique en lecture de pilotage concrète pour le projet **Étape du projet :** Organisation / planification

Hypothèses de conduite	Lecture de risque
— Le cadrage A alimente rapidement l'état de l'art et le prétraitement pour éviter un démarrage séquentiel trop long. — Les branches F et G sont parallélisées afin de réduire la durée totale avant l'étape de fusion. — L'environnement J démarre tôt et l'entraînement K reste le lot le plus long, car il concentre essais, calibration et choix du meilleur checkpoint.	— Le verrou principal est la séquence E-G-H-I-K, car elle relie directement données, architecture et validation du modèle. — Un retard sur D ou J reste absorbable grâce aux marges, alors qu'un retard sur H ou K décale toute la démonstration. — Les tâches à faible marge, comme C et F, restent à surveiller, tandis que L et M sécurisent la transformation du travail technique en livrables académiques.

Message clé
Le planning montre que la réussite du PFA dépend moins du nombre de tâches que de la bonne maîtrise des quelques étapes critiques qui structurent tout le projet.

Gestion de Projet — Tableau des Marges

Rôle : Quantifier la flexibilité de chaque tâche à travers la marge libre et la marge totale Étape du projet : Organisation / planification

ID	A	B	C	D	E	F	G	H	I	J	K	L	M
ML	0	1	0	30	0	1	0	0	0	21	0	0	0
MT	0	2	1	30	0	1	0	0	0	21	0	0	0

Table 1.2. Marges libres et marges totales calculées sur le planning du projet

ML = marge libre ; MT = marge totale. Les tâches critiques vérifient ML = MT = 0, tandis que D et J concentrent l'essentiel de la souplesse du planning.

Méthodologie — Schéma du Réseau de PERT

Rôle : Visualiser le réseau PERT avec les décalages, les convergences et le chemin critique Étape du projet : Organisation / planification
--





Figure 1.1. Réseau PERT de MedFusionNet avec liaisons temporelles annotées et chemin critique mis en évidence.

Gestion de Projet — Diagramme de Gantt

Rôle : Projeter le planning sur un calendrier opérationnel tout en respectant les liaisons DD, FD et FF
Étape du projet : Organisation / planification




Étude de l'existant

Phase 1 — DenseNet / CheXNet

SOTA : Architecture DenseNet-121

Rôle : Présenter le modèle CNN de référence utilisé comme base de comparaison
Étape du projet : Analyse SOTA / comparaison



Dense Block
 Concaténation de toutes les cartes précédentes :
 $x_\ell = H_\ell([x_0, x_1, \dots, x_{\ell-1}])$
 Réutilisation des features + meilleur flux de gradient.
 Croissance des canaux : $C_{out} = C_0 + L \cdot k$.
 Exemple : $k = 32, L = 6 \Rightarrow C_{out} = C_0 + 192$.
 Où C_0 = canaux initiaux, L = nb de couches, k = growth rate.

Transition
 Entre blocs denses, compresse et réduit.
 $X \in \mathbb{R}^{H \times W \times C}$
 $\rightarrow \text{Conv}_{1 \times 1}(X) = Y \in \mathbb{R}^{H \times W \times C'}$
 $Y_{h,w,c'} = \sum_c W_{c',c} X_{h,w,c} + b_{c'}$
 $\rightarrow \text{AvgPool}(Y) = Z \in \mathbb{R}^{H/2 \times W/2 \times C'}$
 $Z_{i,j,c'} = \frac{1}{4} \sum_{u,v \in \{0,1\}} Y_{2i+u, 2j+v, c'}$
 Compression, efficacité, préparation du bloc suivant.
 Où H, W = hauteur/largeur, C = canaux, C' = canaux compressés.

Stem / Entrée


Entrée $224 \times 224 \times 3$.
 Conv 7×7 ($s = 2$) puis MaxPool 3×3 ($s = 2$).
 Extrait des bords/textures et réduit tôt la résolution.
 Exemple : $224 \times 224 \rightarrow 112 \times 112 \rightarrow 56 \times 56$.
 Où H, W = dimensions spatiales, s = stride.

Tête de classification

Global Avg Pooling : moyenne spatiale par canal.
 $7 \times 7 \times 1024 \rightarrow 1 \times 1 \times 1024$.
 $g_c = \frac{1}{HW} \sum_{h,w} F_{h,w,c}$, puis FC.
 Exemple : $g \in \mathbb{R}^{1024} \rightarrow \text{scores} \in \mathbb{R}^K$.
 Où F = carte de features, g = vecteur global, K = nb de classes.

DenseNet-121 : Structure d'une couche dense

Rôle : Expliquer le calcul interne d'une couche dense pour comprendre le baseline choisi **Étape du projet :** Analyse SOTA / compréhension mécanistique



Séquence : BN $\rightarrow$ ReLU $\rightarrow$ Conv 1×1
 $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ Conv 3×3

Transformation H_ℓ

H_ℓ est la transformation appliquée par la couche ℓ dans un bloc dense; elle produit de **nouvelles** cartes de features.

Formule :

$$H_\ell(x) = \text{Conv}_{3 \times 3} \left(\text{ReLU}(\text{BN}(\text{Conv}_{1 \times 1}(\text{ReLU}(\text{BN}(x)))))) \right)$$

Si $x = [x_0, x_1, \dots, x_{\ell-1}]$, alors $x_\ell = H_\ell(x)$.

Interprétation : 1×1 = mélange/réduction des canaux (bottleneck),

3×3 = extraction spatiale locale, BN+ReLU = stabilité + non-linéarité.


Croissance : la couche ajoute k canaux : $C_{\text{out}} = C_{\text{in}} + k$.

Après L couches : $C_{\text{out}} = C_0 + Lk$.

Où C_{in} = canaux d'entrée, C_0 = canaux initiaux, k = growth rate.

Phase 2 — Optimisation et efficacité**Phase 2 — EfficientNet : idée générale et scaling**

Rôle : Comparer une stratégie d'optimisation du coût de calcul par scaling équilibré **Étape du projet :** Analyse SOTA / comparaison

**Idée centrale**

EfficientNet est une famille de CNN conçue pour **mieux exploiter** un budget de calcul donné.

Le **scaling naïf** (uniquement profondeur, largeur ou résolution) crée un déséquilibre :

trop profond $\Rightarrow$ gradient fragile,

trop large $\Rightarrow$ surcoût mémoire,

trop haute résolution $\Rightarrow$ coût quadratique.

Compound Scaling

On augmente **ensemble** profondeur, largeur et résolution par un facteur global ϕ pour rester efficace.


$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi,$$

$$\alpha \beta^2 \gamma^2 \approx 2$$

ϕ contrôle l'échelle globale ; la contrainte équilibre coût et performance.

Phase 2 — MBConv : bloc clé d'EfficientNet

Rôle : Détailler le bloc opératoire central qui rend EfficientNet efficace **Étape du projet :** Analyse SOTA / modélisation d'un bloc



Depthwise Convolution

Chaque canal est filtré séparément :

$$Y_{h,w,c} = \sum_{i,j} K_{i,j}^{(c)} X_{h+i,w+j,c}$$

Coût paramétrique : $k^2 C$

au lieu de $k^2 C C'$ (conv standard).

Réduit fortement les paramètres et FLOPs.

MBConv en pratique

- 1) Expansion
 $C_e = t \cdot C_{in}$,
 - 2) Depthwise 3×3 ,
 - 3) SE (ré-pondération canal),
 - 4) Projection vers C_{out} ,
 - 5) Skip si stride $s = 1$
- et dimensions compatibles.
Objectif :
expressivité élevée
avec coût réduit.

Phase 2 — EfficientNetV2 et impact médical

Rôle : Montrer l'évolution d'EfficientNet vers une version plus rapide à entraîner et à déployer **Étape du projet :** Analyse SOTA / comparaison

EfficientNetV2 : améliorations

Optimise l'entraînement (plus rapide et stable) via :

- **Fused-MBConv** sur les petits étages (meilleur débit GPU),
- règles de scaling adaptées,
- stratégies de régularisation plus efficaces.

Résultat : **meilleure précision** à coût d'entraînement réduit.

Intérêt en imagerie médicale

- Meilleur compromis précision/temps :
- utile pour stations avec GPU limités,
 - facilite l'expérimentation rapide,
 - déploiement clinique plus réaliste.

Précision

- EfficientNetV2
- EfficientNet
- DenseNet-121
- CNN classiques

Schéma conceptuel

Paramètres

Phase 2 — EfficientNet : ce que fait le modèle

Rôle : Relier le mécanisme d'EfficientNet aux besoins pratiques de la détection sur CXR **Étape du projet :** Analyse SOTA / pertinence applicative

Mécanisme effectif

Le réseau apprend une fonction f_θ qui transforme X en **cartes hiérarchiques** (bords, textures, motifs complexes).
Les blocs MBConv alternent **mixage de canaux** (1×1), **filtrage spatial local** (depthwise) et **ré-pondération** (SE).
Après agrégation globale :
 $z = \text{GAP}(F_L(X)), \quad p(y|X) = \sigma(w^\top z)$
Le scaling compound règle **profondeur/largeur/résolution** pour préserver détail et contexte.

Aide en imagerie médicale

Capte des patterns **multi-échelles** (opacités diffuses, consolidations).
Bon compromis précision/coût $\Rightarrow$ utile en contexte GPU limité.
Permet d'exploiter des images haute résolution sans explosion de paramètres.

Limites et risques


Downsampling peut effacer des signes **très fins**.
Sensibilité aux biais (texte, position, appareil, contraste).
Pas de localisation directe : nécessite un outil d'explicabilité.

Phase 3 — Vision Transformers et contexte global

Phase 3 — ViT : patches et tokens

Rôle : Introduire la représentation en patches qui remplace la grille convolutive classique **Étape du projet :** Analyse SOTA / comparaison

Image $\rightarrow$ patches



Tokenisation d'image

Image $X \in \mathbb{R}^{H \times W \times C}$ découpée en patches $P \times P$.
Nombre de tokens : $N = \frac{HW}{P^2}$.
Chaque patch est aplati et projeté :
 $z_i = E x_i + e_i^{\text{pos}}, \quad z_i \in \mathbb{R}^D$.
On traite ensuite $(z_1, \dots, z_N)$ comme une **séquence**.

Intuition : les patches jouent le rôle de “mots” visuels ; l'attention relie des régions éloignées.

Phase 3 — Auto-attention : mécanisme et coût

Rôle : Expliquer le calcul d'attention, son intérêt et son coût computationnel SOTA / modélisation

Étape du projet : Analyse

Auto-attention

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$


Q : requêtes, K : clés, V : valeurs.

Chaque token “regarde” tous les autres (**contexte global**).

Limite de ViT

Complexité quadratique : $O(N^2)$ avec N tokens.


Pour grandes images médicales, N devient très élevé $\Rightarrow$ coût prohibitif.




Phase 3 — Swin Transformer : fenêtres et décalage

Rôle : Montrer comment Swin conserve le contexte global tout en réduisant la complexité **Étape du projet :** Analyse SOTA / comparaison


Global (ViT)



Fenêtres (Swin)



Fenêtres décalées



Attention par fenêtres

Swin limite l'attention à des fenêtres $M \times M$:

$$\text{complexité } O\left(\frac{HW}{M^2} \cdot M^4\right) = O(HW M^2),$$

au lieu de $O(N^2)$ global.

Le **décalage** des fenêtres connecte les régions voisines.

Intérêt médical

Capte des relations à longue distance tout en restant scalable.

Meilleure adaptation aux images haute résolution (radiographies).

Permet de relier des patterns subtils répartis dans l'image.

Phase 3 — ViT/Swin : ce que fait le modèle

Rôle : Relier Transformers et radiographie thoracique en termes de bénéfices et de limites **Étape du projet :** Analyse SOTA / pertinence applicative

Mécanisme effectif

Chaque patch devient un token ; l'attention calcule l'importance **entre régions**.

$$a_{ij} = \text{softmax}\left(\frac{q_i k_j}{\sqrt{d}}\right), \quad \tilde{z}_i = \sum_j a_{ij} v_j$$

Le modèle combine ainsi **contexte global** et information locale. Swin ajoute attention par **fenêtres + décalage**, puis **fusion de patches** (hiérarchie multi-échelle).

Aide en imagerie médicale

Relie des régions éloignées (symétrie pulmonaire, contexte global).

Utile pour motifs diffus et structures larges.

Swin reste efficace sur grandes images tout en gardant du détail.

Limites

Moins d'inductif bias que les CNN $\Rightarrow$ besoin de pré-entraînement.

Patches trop grands $\Rightarrow$ perte de lésions fines ; trop petits $\Rightarrow$ coût élevé.

Attention peut suivre des corrélats non pathologiques.

Phase 4 — Confiance et explicabilité

Phase 4 — Grad-CAM : principe et formulation

Rôle : Définir l'outil d'explicabilité utilisé pour interpréter les prédictions **Étape du projet** : Analyse SOTA / évaluation interprétable

Idée

Grad-CAM met en évidence **où** le réseau “regarde” pour une classe donnée.

On utilise les gradients du score y^c par rapport aux cartes A^k .

Formules

Poids d'importance :

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$$

Carte Grad-CAM :

$$L_{\text{Grad-CAM}}^c = \text{ReLU}\left(\sum_k \alpha_k^c A^k\right)$$

Interprétation

A^k : carte de features de la dernière couche conv.


α_k^c : contribution de la carte k à la classe c .

ReLU conserve les contributions positives.

Le modèle donne “**quoi**”, Grad-CAM suggère “**où**”.

Phase 4 — Grad-CAM : schéma de génération

Rôle : Visualiser le pipeline complet de production d'une heatmap explicative **Étape du projet** : Analyse SOTA / évaluation interprétable



Lecture : l'overlay montre les régions activées associées à la classe prédite.

Phase 4 — Grad-CAM : ce que ça aide (et ce que ça n'aide pas)

Rôle : Préciser l'utilité clinique réelle de Grad-CAM et ses limites méthodologiques
Analyse SOTA / validation critique

Étape du projet :

Ce que Grad-CAM apporte

Explication **post-hoc** : montre quelles zones augmentent le score y^c .
Ne modifie pas la prédiction, mais **guide l'analyse** (triage, relecture).
Utile pour repérer des biais (texte, marqueurs, position).
Permet d'aligner le modèle avec l'expertise clinique.

Ce que Grad-CAM ne garantit pas

Carte **grossière** (résolution = stride de la dernière couche).
Importance $\neq$ causalité ; une heatmap "plausible" peut être trompeuse.
Sensibilité à la couche choisie, au prétraitement et au bruit.
Interprétabilité = aide, pas preuve diagnostique.

Objectifs du projet

Objectifs du projet

Rôle : Synthétiser les objectifs fonctionnels, scientifiques et logiciels avant la conception détaillée
projet : Cadrage du projet

Objectifs fonctionnels	Objectifs techniques
— détecter la pneumonie sur radiographie thoracique ; — fournir une probabilité exploitable pour le triage ; — visualiser les zones les plus contributives via Grad-CAM.	— construire un pipeline complet d'entraînement et d'inférence ; — exposer le modèle via scripts, API et interface web ; — conserver une solution reproductible et documentée.
Objectifs scientifiques	Critère de réussite
— comparer les familles CNN et Transformers ; — justifier une architecture hybride ; — relier performance et interprétabilité.	Le projet est considéré comme réussi si le modèle atteint une bonne sensibilité aux cas PNEUMONIA, reste lisible par ses sorties explicatives, et peut être utilisé localement dans une démonstration complète.

Chapitre 2

Conception fonctionnelle et modélisation

Diagrammes fonctionnels et structure logique

Conception fonctionnelle — Diagramme de cas d'utilisation





Figure 2.1. Diagramme de cas d'utilisation simplifié du système

Conception fonctionnelle — Diagramme de classes logiques






Figure 2.2. Vue logique simplifiée des classes et composants du projet

Données, nettoyage et protocole d'apprentissage

Conception des données — Dataset et nettoyage

Rôle : Présenter le corpus de données et la logique de préparation avant l'entraînement **Étape du projet :** Conception fonctionnelle / données

Présentation du dataset	Formulation
Le corpus retenu est le dataset Kaggle <i>Chest X-Ray Pneumonia</i> de Paul Mooney, organisé en deux classes : NORMAL et PNEUMONIA. Il fournit un cadre de travail adapté à une première évaluation comparative des architectures profondes sur radiographies thoraciques.	En notant X l'image brute, la transformation appliquée s'écrit : $\tilde{X} = T(X) = A(R(N(X)))$ où : — N normalise les intensités, — R redimensionne l'image, — A améliore éventuellement le contraste.
Nettoyage et homogénéisation	Pourquoi cette étape est critique
Avant l'apprentissage, les images sont : — redimensionnées à une taille cible commune ; — normalisées pour stabiliser les intensités ; — éventuellement améliorées localement pour le contraste ; — converties en tenseurs compatibles avec le pipeline PyTorch.	Un modèle médical ne doit pas apprendre les artefacts de capture ou les écarts de contraste ; il doit apprendre les indices pathologiques. La préparation des données réduit ce risque.

Architecture et conception

Solution proposée — Étape 0 : vue d'ensemble

Rôle : Présenter la logique globale du modèle avant le détail des étapes **Étape du projet :** Conception de la solution

Principe et formule globale

MedFusionNet combine deux lectures d'une même radiographie :

- une branche **CNN** pour les indices locaux : contours, textures, petites opacités ;
- une branche **Swin** pour le contexte global : symétrie thoracique, bilatéralité, cohérence anatomique ;
- une **fusion guidée** qui pondère automatiquement les deux branches.

Chaîne mathématique.

$$\tilde{X} = T(X)$$

$$F_c = \Phi_c(\tilde{X}), \quad F_s = \Phi_s(\tilde{X})$$

$$g = \sigma(W_g[\text{GAP}(F_c), \text{GAP}(F_s)] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

La sortie finale vérifie $\Psi(F) = (p, L^c, u)$: score p , heatmap L^c , incertitude u .




Figure 2.3. Vue d'ensemble du pipeline complet

Pipeline détaillé

Solution proposée — Étape 1 : échantillon d'entrée

Rôle : Définir la donnée d'entrée et ce qu'elle contient avant tout calcul

Étape du projet : Conception détaillée

Image et variabilité

Une radiographie thoracique est modélisée par :

$$X \in \mathbb{R}^{H \times W}$$

avec une étiquette binaire :

$$\begin{cases} y = 1 & \text{pneumonie} \\ y = 0 & \text{normal ou autre classe négative} \end{cases}$$

Pourquoi l'entrée est difficile. L'image brute contient à la fois le signal clinique et des facteurs parasites :

- variations d'intensité et de contraste selon l'appareil ;
- bruit, annotations, câbles et autres artefacts ;
- cadrage, résolution et structures normales parfois trompeuses.

Exemple : deux clichés de même classe peuvent avoir un contraste ou un centrage très différents ; le modèle doit ignorer cette variabilité non pathologique.




Figure 2.4. Échantillon brut provenant du dataset

Solution proposée — Étape 2 : prétraitement

Rôle : Standardiser l'image avant son entrée dans les deux branches du modèle
Développement / préparation des données

Étape du projet :

Transformation

Le prétraitement applique une chaîne de standardisation :

$$\tilde{X} = T(X) = A(R(N(X)))$$

où N normalise les intensités, R redimensionne et A peut améliorer localement le contraste.

Ce que la donnée devient

normalisation : $X_{norm} = \frac{X - \mu}{\sigma}$

redimensionnement : $X \in \mathbb{R}^{H \times W}$
 $\longrightarrow \tilde{X} \in \mathbb{R}^{H_0 \times W_0}$

Exemple : $1024 \times 1024 \rightarrow 384 \times 384$. Cette étape réduit le coût mémoire, homogénéise les entrées et diminue le risque que le modèle prenne une différence d'acquisition pour une pneumonie.




Figure 2.5. Image après normalisation et redimensionnement

Solution proposée — Étape 3 : branche CNN locale

Rôle : Extraire les motifs fins et localisés par une lecture convolutive
Étape du projet : Modélisation de la branche locale

Lecture locale par CNN

La branche locale produit :

$$F_c = \Phi_c(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_c}$$

Une convolution applique un filtre sur un voisinage restreint :



$$F_{i,j,c'}^{(\ell)} = \sum_{u,v,c} W_{u,v,c,c'}^{(\ell)} F_{i+u,j+v,c}^{(\ell-1)} + b_{c'}^{(\ell)}$$

Ce que la branche voit réellement.

- bords pleuraux, côtes, contours pulmonaires ;
- textures diffuses ou focales ;
- petites consolidations et opacités locales ;
- transitions fines entre tissu sain et tissu suspect.

Exemple : une opacité basale discrète peut être amplifiée par la comparaison locale entre intensités voisines.

Image / Feature Map



Couche suivante

Champ récepteur local ($k \times k$)

Figure 2.6. Représentation locale extraite par la branche CNN

Solution proposée — Étape 4 : branche Swin globale

Rôle : Extraire une représentation de contexte capable de relier des régions éloignées
Modélisation de la branche globale

Étape du projet :

Lecture globale par Swin

L'image prétraitée est découpée en patches puis projetée :

$$z_i = E x_i + e_i^{pos}$$

La branche globale calcule ensuite :


$$F_s = \Phi_s(\tilde{X}) \in \mathbb{R}^{H' \times W' \times C_s}$$

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Dans Swin, cette attention est calculée par fenêtres, puis les fenêtres sont décalées pour reconnecter les régions voisines. **Ce que la branche globale apporte.** Elle relie des zones éloignées : apex, bases, hémithorax droit/gauche, médiastin. Si une anomalie n'a de sens que par sa **distribution spatiale**, Swin la capture mieux qu'un CNN purement local.

Attention Globale (Longue distance)



Patches d'image

Figure 2.7. Représentation globale extraite par la branche Swin

Solution proposée — Étape 5 : fusion guidée

Rôle : Combiner les indices locaux et globaux sans imposer un poids fixe à chaque branche
Étape du projet : Conception du coeur de fusion

Porte de fusion et interprétation

On résume d'abord chaque branche par un vecteur global :

$$\bar{F}_c = \text{GAP}(F_c), \quad \bar{F}_s = \text{GAP}(F_s)$$

Puis on apprend un coefficient de fusion :

$$g = \sigma(W_g[\bar{F}_c, \bar{F}_s] + b_g)$$

$$F = g \odot F_c + (1 - g) \odot F_s$$

Si $g \approx 1$, le modèle privilégie l'indice local ; si $g \approx 0$, il privilégie le contexte global. **Exemples. Exemple 1 :** foyer net et compact $\Rightarrow g \approx 0.8$.

Exemple 2 : atteinte diffuse ou bilatérale $\Rightarrow g \approx 0.3$.

La fusion n'est donc pas une moyenne fixe : elle s'adapte à la structure réelle de l'image.




Figure 2.8. Fusion adaptative entre la branche locale et la branche globale

Solution proposée — Étape 6 : classification

Rôle : Transformer la représentation fusionnée en probabilité de pneumonie
Tête de décision

Étape du projet :

Score de classe
La représentation fusionnée est condensée en un vecteur : $z = \text{GAP}(F)$ puis convertie en probabilité : $p(y = 1 X) = \sigma(w^\top z + b)$
Décision pratique
Avec un seuil τ : $\hat{y} = \begin{cases} 1 & \text{si } p(y = 1 X) \geq \tau \\ 0 & \text{sinon} \end{cases}$ Exemple : si $p = 0.91$ et $\tau = 0.5$, la prédiction est positive avec une forte marge. Si $p = 0.54$, la décision reste positive mais devient fragile : elle doit être lue avec la heatmap et l'incertitude.




Figure 2.9. Passage de la représentation fusionnée au score de classe

Solution proposée — Étape 7 : localisation et incertitude

Rôle : Produire une explication spatiale et mesurer la fiabilité de la décision interprétables

Étape du projet : Sorties

Localisation et incertitude
À partir des cartes finales A^k : $\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}$ $L^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right)$ La heatmap montre où le modèle a trouvé des indices pour la classe prédite. Incertainité. En répétant plusieurs passes avec dropout actif : $u = \text{Var}_t(p_t)$ Exemple : si $p_t = \{0.87, 0.88, 0.89\}$, la variance est faible ; si $p_t = \{0.42, 0.81, 0.57\}$, la décision est instable et doit être relue.




Figure 2.10. Heatmap explicative et estimation d'incertitude

Solution proposée — Étape 8 : apprentissage

Rôle : Définir exactement ce qui est optimisé pendant l'entraînement

Étape du projet : Développement / entraînement

Fonction objectif
$\mathcal{L} = \mathcal{L}_{cls} + \lambda_1 \mathcal{L}_{loc} + \lambda_2 \mathcal{L}_{cons} + \lambda_3 \mathcal{L}_{cal}$
Sens de chaque terme
$\mathcal{L}_{cls}$: apprendre la bonne classe. $\mathcal{L}_{loc}$: contraindre la heatmap à rester cliniquement plausible. $\mathcal{L}_{cons}$: garder une prédiction stable sous augmentation. $\mathcal{L}_{cal}$: mieux aligner confiance prédite et fréquence réelle d'erreur. Exemple : sur un dataset déséquilibré, $\mathcal{L}_{cls}$ peut être une Focal Loss afin de mieux traiter les cas rares ou difficiles.




Figure 2.11. Schéma de la perte totale et de ses composantes

Solution proposée — Étape 9 : sortie clinique

Rôle : Montrer comment les sorties du modèle deviennent une aide concrète pour le workflow médical **Étape du projet** : Validation métier / déploiement

Sortie exploitable pour le clinicien
Pour une image X, le modèle renvoie : $(p(y = 1 X), L^c, u)$ soit un score de pneumonie, une heatmap explicative et une estimation d'incertitude. Comment cela aide le clinicien. — score élevé + faible incertitude : cas à prioriser ; — score modéré + incertitude élevée : revue humaine prioritaire ; — score faible + faible incertitude : cas probablement normal. Limite : une heatmap plausible reste un support de lecture, pas une preuve diagnostique.




Figure 2.12. Sortie finale utilisable par le clinicien

Modélisation — Protocole d'entraînement et d'évaluation

Rôle : Expliquer comment le modèle apprend puis comment sa précision est calculée
Conception fonctionnelle / apprentissage

Étape du projet :

Entraînement du modèle	Test et calcul de précision
Le modèle apprend en minimisant une fonction de coût combinée : $\mathcal{L} = \lambda_{cls} \mathcal{L}_{cls} + \lambda_{cal} \mathcal{L}_{cal} + \lambda_{reg} \mathcal{L}_{reg}$ La composante principale $\mathcal{L}_{cls}$ pousse le réseau à distinguer les classes NORMAL et PNEUMONIA. Les autres termes servent à améliorer la cali-	Une fois entraîné, le modèle est évalué sur un jeu de test indépendant. Les indicateurs calculés sont notamment : $\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$ $\text{Recall} = \frac{TP}{TP + FN}$ $\text{Precision} = \frac{TP}{TP + FP}$ Ces mesures permettent de quantifier à la fois la justesse globale et la capacité à détecter les cas malades.
bration et la stabilité.	

Chapitre 3

Conception technique et réalisation

Technologies, architecture et mise en œuvre

Implémentation — Dataset Chest X-Ray

Rôle : Justifier la sélection et les caractéristiques des données d'apprentissage **Étape du projet :** Préparation des données

Spécifications & Accès aux données

Dataset Kaggle de Paul Mooney (5 856 images).

- **Classes :** *NORMAL* vs *PNEUMONIA*.
- **Défi :** Déséquilibre fort (plus de cas malades).
- **Choix :** Utilisation de la *Focal Loss* pour corriger le biais de majorité et focaliser sur les cas difficiles.



Lien Kaggle :
(Scanner pour accéder
au dataset)




Figure 3.1. Répartition et flux des données d'imagerie

Implémentation — Choix Technologiques

Rôle : Exposer et justifier la stack matérielle et logicielle du projet

Étape du projet : Configuration de l'environnement

Framework & Langage
Code source intégral en Python 3 . L'orchestration du Deep Learning repose sur l'écosystème PyTorch .
Environnement et Accélération
Face aux contraintes matérielles de machine locale (crash mémoire liés aux larges matrices <i>Swin</i>), le modèle a migré sur Google Colab :
— Accès direct aux GPU (T4 ou A100).
— Injection de l'AMP (<i>Automatic Mixed Precision</i>) pour basculer en <code>float16</code> et réduire drastiquement la consommation VRAM.




Figure 3.2. Pile Technologique du système MedFusionNet

Implémentation — Architecture du Projet

Rôle : Montrer la robustesse de l'arborescence et la modularité des composants **Étape du projet :** Gestion de Projet

Séparation des responsabilités
Notre socle algorithmique sépare rigoureusement la donnée, la logique métier, l'entraînement et l'inférence. Cette compartimentation favorise une évolutivité sans bugs spatiaux :
— Dossiers <code>checkpoints/</code> isolant les poids sauvegardés des écrasements.
— Fichiers modulaires <code>.py</code> clairs et réutilisables.
— Carnet <code>MedFusionNet_Colab.ipynb</code> agissant comme un orchestrateur important l'environnement ciblé du Cloud vers nos scripts natifs.




Figure 3.3. Arborescence du répertoire de travail (Git)

Implémentation — Les Modules de Code (API)

Rôle : Documenter les scripts métiers Python principaux et leurs relations **Étape du projet :** Architecture Logicielle

Cœur Algorithmique
preprocessing.py & dataset.py : Pipeline de normalisation (CLAHE) et orchestration PyTorch <i>DataLoaders</i> fournissant des batches au GPU en parallèle. model.py & losses.py : Définition déclarative de la double branche (CNN + Swin + Gate) et des équations de la fonction <i>Objective</i> (Focal Loss, ...). inference.py : API finale (<i>MedFusionInference</i>) destinée au clinicien : génère le score, calcule l'incertitude via MC-Dropout en 20 passes rapides, puis tisse la masque explicative (Heatmap).





Figure 3.4. Interaction logique entre les fichiers source principaux

Implémentation — API REST locale

Rôle : Montrer comment le moteur d'inférence a été exposé à des clients externes sans casser l'interface web
Étape du projet : Architecture Logicielle

Composants d'exposition
api.py : Blueprint Flask sous <code>/api/v1</code> exposant <code>/health</code>, <code>/predict</code>, <code>/predict/gradcam</code> et <code>/benchmark</code>. app.py : Enregistre le Blueprint sans toucher aux routes HTML déjà utilisées par l'interface Flask. service.py : Conserve <code>model_store</code> : le chargement du checkpoint reste <i>lazy</i> et partagé. client.py : CLI local pour tester l'API, afficher les métriques et exporter les images Grad-CAM.
Intérêt pratique
— même moteur d'inférence pour le navigateur, <code>curl</code> et les scripts externes ; — point d'intégration propre pour une future interface plus riche ; — smoke tests simples via <code>/api/v1/health</code> et le client CLI.



Implémentation — Workflow d'une requête API

Rôle : Expliquer le cycle complet d'une requête, la validation de l'image et la structure des réponses JSON
Étape du projet : Déploiement local / intégration

Cycle de traitement	Routes exposées
1. Entrée : multipart/form-data ou octets image bruts. 2. Validation : extension autorisée, ouverture PIL, conversion RGB. 3. Traitement : engine.predict(...) ou run_benchmark(max_images). 4. Sortie : réponse JSON avec probabilités, métadonnées et temps d'inférence.	— GET /api/v1/health — POST /api/v1/predict — POST /api/v1/predict/gradcam — GET /api/v1/benchmark?max_images=20
Choix d'implémentation	Exemples d'appel
— /predict : score simple, sans heatmap. — /predict/gradcam : overlay et heatmap en PNG Base64. — /benchmark : métriques seulement, graphes exclus.	curl /api/v1/health curl -X POST /api/v1/predict -F "image=@radio.jpeg" python client.py predict image.jpeg -gradcam -save overlay.png

Implémentation — Exécution et Hyperparamètres

Rôle : Justifier les variables d'ajustement du code lors de l'apprentissage

Étape du projet : Lancement de l'Entraînement

Lancement via train.py

L'exécution de l'entraînement a été finement calibrée sur l'environnement Colab :

— -epochs 50 : Temps de chauffe suffisant pour stabiliser le réseau Transformer.

— -batch_size 16 : Contrainte optimale GPU allégeant la VRAM tout en maintenant le batch normalization fonctionnel.

— -lr 1e-4 & AdamW : Taux d'apprentissage modéré afin d'éviter l'oubli catastrophique du pré-entraînement CNN.

python train.py

Opt : AdamW
Epochs : 50 | BZ : 16

Mixed Prec : ENABLED

best.pth (Modèle final)

Métriques CSV
(Recall, Accuracy)

Figure 3.5. Flux d'exécution de l'entraînement et enregistrements

Tests, résultats et validation

Résultats obtenus — synthèse quantitative

Rôle : Donner les performances finales du modèle sur le jeu de test et les interpréter	Étape du projet : Évaluation finale
---	--

Protocole d'évaluation	Classe PNEUMONIA
— Jeu de test final : 624 radiographies. — Répartition : 234 cas NORMAL et 390 cas PNEUMONIA. — Checkpoint évalué : Model_19Apr26.pth.	— Recall / Sensibilité : 96.92% — Precision : 91.97% — F1-score : 94.38%
Indicateurs globaux	Classe NORMAL
— Accuracy : 92.79% — AUC-ROC : 0.976 — Average Precision : 0.984 — Erreurs totales : 45 images sur 624 seulement	— Recall / Spécificité : 85.90% — Precision : 94.37% — F1-score : 89.93%

Résultats obtenus — matrice de confusion et lecture métier

Rôle : Expliquer précisément où le modèle se trompe et pourquoi ces erreurs comptent **Étape du projet :** Analyse détaillée des sorties


Matrice de confusion	Interprétation									
<table><tr><th>Vrai / Prédit</th><th>NORMAL</th><th>PNEUMONIA</th></tr><tr><th>NORMAL</th><td>201</td><td>33</td></tr><tr><th>PNEUMONIA</th><td>12</td><td>378</td></tr></table> Table 3.1. Matrice de confusion finale sur le jeu de test	Vrai / Prédit	NORMAL	PNEUMONIA	NORMAL	201	33	PNEUMONIA	12	378	— Sur 390 cas de pneumonie, le système en détecte 378. — Le taux de cas pneumonie manqués est de 12 / 390 = 3.08%. — Sur 234 images normales, 33 sont surclassées à tort en pneumonie. — Le modèle est donc volontairement plus sensible que spécifique : il déclenche plus facilement une alerte plutôt que de laisser passer une pneumonie. — En contexte de triage, ce compromis reste cohérent médicalement.
Vrai / Prédit	NORMAL	PNEUMONIA								
NORMAL	201	33								
PNEUMONIA	12	378								
Bilan chiffré										
— Vrais positifs : 378 — Vrais négatifs : 201 — Faux positifs : 33 — Faux négatifs : 12										

Résultats obtenus — benchmark visuel sur le jeu de test

Rôle : Montrer visuellement la qualité de séparation du modèle à l'échelle du test complet **Étape du projet :** Benchmark final

Benchmark final — Test set (624 images)


Accuracy 92.79% | AUC 0.976 | AP 0.984 | Recall pneumo 96.92%

**Ce que montrent les courbes**

- **ROC** : courbe très proche du coin supérieur gauche.
- **PR** : AP = **0.984**, donc très bon classement des cas pneumonie.
- Les scores sont **bien séparés** ; peu d'ambiguïté autour du seuil 0.5.

Résultats obtenus — comportement durant l'entraînement


Rôle : Lire les courbes d'apprentissage et signaler les limites de validation **Étape du projet** : Analyse du run conservé

**Lecture des courbes**

- La **train loss** baisse régulièrement : le modèle apprend effectivement.
- La **val loss** oscille davantage : la validation est plus instable.
- Les métriques montent vite, mais la validation ne contient que **16 images**.
- La conclusion finale doit donc s'appuyer sur le **test set à 624 images**.

Résultats obtenus — validation qualitative par Grad-CAM

Rôle : Montrer comment l'explicabilité visuelle aide à valider le comportement du modèle **Étape du projet** : Interprétabilité



Finalisation du projet

Rôle : Résumer les livrables concrets du projet et la suite logique production locale	Étape du projet : Clôture / mise en
--	--

Livrables finalisés — Modèle final entraîné et checkpoint exporté. — Runtime Python modulaire avec CLI et API locale. — Interface web Flask pour charger une image, lancer l'inférence et voir le Grad-CAM. — Benchmark local avec ROC, PR, matrice de confusion et distribution des scores.	Conclusion technique — Le système est fonctionnel de bout en bout. — Les performances sont suffisamment fortes pour démontrer la viabilité de l'approche hybride Swin + DenseNet. — Le compromis retenu favorise la détection des cas positifs, ce qui est cohérent avec l'objectif médical.
	Améliorations futures — augmenter la taille du jeu de validation — renforcer la spécificité — tester sur un dataset externe et améliorer la calibration

Mots clés

Rôle : Synthétiser les thèmes techniques majeurs couverts par le document documentaire

Étape du projet : Clôture

Intelligence Artificielle

Deep Learning

Vision par Ordinateur

Radiographie Thoracique (CXR)

Pneumonie

CNN / Transformers

Transfer Learning

Interprétabilité (Grad-CAM)

Valorisation entrepreneuriale

Entrepreneuriat — Vision de valorisation

Rôle : Introduire simplement comment une idée technique peut devenir un projet entrepreneurial **Étape du projet :** Ouverture business / entrepreneuriat

Le point de départ

- Les hôpitaux et centres d'imagerie doivent traiter beaucoup d'examens en peu de temps.
- Une radiographie thoracique peut être difficile à interpréter rapidement.
- Un outil d'aide peut donc avoir une vraie utilité pratique.

Notre idée

- signaler les cas suspects,
- aider à prioriser les urgences,
- montrer une explication visuelle.

Ce que l'on vend

- une aide au triage,
- une aide à la lecture,
- un service utile pour les structures médicales.

Idée clé

On ne vend pas un “médecin automatique”, mais une **solution d'assistance** qui aide les professionnels à travailler plus vite et plus sereinement.

Entrepreneuriat — Clients cibles et vente

Rôle : Présenter simplement le marché visé et la logique commerciale du projet
Valorisation du projet

Étape du projet :

Clients potentiels

- hôpitaux publics et privés,
- cliniques,
- centres de radiologie,
- plateformes de téléradiologie.

Démarche simple de vente

1. montrer le besoin,
2. faire une démonstration,
3. proposer un pilote,
4. recueillir les retours,
5. transformer le test en offre.

Positionnement
Le projet se vend en B2B : il s'adresse à des établissements de santé et non directement au grand public.

Entrepreneuriat — Budget simple et modalités de vente

Rôle : Donner une vision accessible du budget de départ et des revenus possibles Faisabilité économique	Étape du projet :
---	--------------------------

Poste	Estimation
Hébergement / cloud / GPU	30 000 MAD
Développement / amélioration	50 000 MAD
Tests / pilote / documentation	25 000 MAD
Communication / déplacement	20 000 MAD
Total simplifié	125 000 MAD

Modes de vente
— pilote payant, — abonnement mensuel, — licence annuelle.

Table 3.2. Budget simplifié de lancement de la solution MedFusionNet

Exemple simple
— Pilote : 10 000 à 20 000 MAD — Abonnement : 3 000 à 6 000 MAD / mois

Lecture entrepreneuriale
Pour notre niveau, l'essentiel est de montrer qu'il existe un marché possible , un mode de vente simple et un budget de départ raisonnable .

Annexes

Références techniques

Annexe A — Convolution, stride et pooling

Rôle : Définir les opérations de base des CNN utilisées dans les architectures étudiées Annexe technique	Étape du projet :
---	--------------------------

Definitions	Formules utiles
Convolution $k \times k$: Filtre local glissant sur l'image ou sur une carte de features. Stride s : Pas de déplacement du filtre ; quand s augmente, la résolution baisse plus vite. Padding : Bordure ajoutée pour contrôler la taille de sortie. MaxPool : Conserve la plus forte activation dans une fenêtre locale. AvgPool : Remplace une fenêtre locale par sa moyenne.	$Y_{i,j,c'} = \sum_{u,v,c} W_{u,v,c,c'} X_{i+u,j+v,c} + b_{c'}$ $H_{out} = \left\lfloor \frac{H + 2p - k}{s} \right\rfloor + 1$
	Intuition
	Les convolutions extraient des motifs locaux. Le pooling résume l'information et réduit la taille spatiale pour rendre le calcul plus efficace.

Annexe B — BN, ReLU, bottleneck et connexions

Rôle : Clarifier les briques de stabilisation et d'efficacité citées dans DenseNet et EfficientNet projet : Annexe technique	Étape du
---	-----------------

Stabilisation	Efficacité
BN : Normalise les activations d'un mini-batch pour stabiliser et accélérer l'entraînement. ReLU : Garde les valeurs positives et annule les négatives, ce qui introduit une non-linéarité simple. Skip connection : Réinjecte une information plus tôt dans le réseau pour faciliter le gradient.	Bottleneck : Réduit les canaux avant une opération coûteuse, puis projette de nouveau si besoin. Growth rate k : Nombre de nouveaux canaux ajoutés par chaque couche dense. SE : Mécanisme qui ré-pondère les canaux selon leur importance. Fused-MBConv : Version simplifiée de MB-Conv, souvent plus rapide à entraîner sur GPU dans les premiers étages.

Annexe C — DenseNet et MBConv

Rôle : Reprendre proprement les blocs spécifiques les plus utilisés dans l’analyse SOTA

Étape du projet : Annexe technique

Bloc dense	MBConv
DenseNet concatène les sorties précédentes au lieu de simplement les additionner. $x_\ell = H_\ell([x_0, \dots, x_{\ell-1}])$ Cela favorise la réutilisation des features et un meilleur flux de gradient.	MBConv combine : — une expansion 1×1, — une convolution depthwise, — un module SE, — une projection finale 1×1. L’objectif est d’obtenir une bonne expressivité à coût réduit.

Annexe D — Vocabulaire Transformer

Rôle : Définir les notions de patches, tokens et embeddings utilisées dans ViT et Swin

Étape du projet : Annexe technique

Definitions	Formule de tokenisation
Patch : Sous-image locale de taille $P \times P$. Token : Vecteur obtenu après projection d’un patch. Embedding : Représentation vectorielle dense envoyée dans le Transformer. Encodage positionnel : Information ajoutée pour conserver l’ordre spatial des patches.	$N = \frac{HW}{P^2}, \quad z_i = E x_i + e_i^{pos}$
	Intuition Le Transformer traite l’image comme une séquence de morceaux visuels, de la même façon qu’un modèle de langage traite une phrase comme une séquence de mots.

Annexe E — Attention et Swin

Rôle : Détailler le calcul d’attention et la logique des fenêtres décalées de Swin

Étape du projet : Annexe technique

Attention	Pourquoi Swin
$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$ $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$ Q : Ce que le token courant cherche. K : Ce que les autres tokens proposent pour être reliés à lui. V : L'information qui sera effectivement transmise.	Fenêtre : Sous-ensemble local de tokens traité ensemble. Fenêtres décalées : Décalage d'une couche à la suivante pour reconnecter des zones voisines. Bénéfice : Réduire le coût du contexte global tout en conservant des interactions spatiales utiles.
	Complexité
	L'attention globale est quadratique en nombre de tokens. Swin réduit ce coût en limitant l'attention à des fenêtres locales.

Annexe F — Entraînement complémentaire

Rôle : Définir les notions d'entraînement mentionnées sans détail dans la solution proposée **Étape du projet** : Annexe technique

Concepts de base	Pourquoi c'est utile
Transfer learning : Réutiliser un modèle pré-entraîné puis l'adapter à la radiographie thoracique. Augmentation : Modifier l'image pendant l'entraînement pour rendre le modèle plus robuste. Pseudo-masque : Zone approximative utilisée comme supervision faible quand on n'a pas d'annotation pixel exacte. Logit : Score brut avant application de la sigmoïde ou du softmax.	Ces mécanismes servent à : — mieux généraliser, — réduire la dépendance à un seul centre hospitalier, — exploiter des annotations incomplètes, — stabiliser l'apprentissage quand les données sont déséquilibrées.

Annexe G — Pertes et calibration

Rôle : Définir les fonctions objectif et la notion de confiance calibrée **Étape du projet** : Annexe technique

Fonctions de perte	Calibration
BCE : Binary Cross-Entropy, perte standard de classification binaire. Focal loss : Version de BCE qui met davantage l'accent sur les exemples difficiles ou rares. $\mathcal{L}_{cons}$: Impose des sorties proches pour deux vues augmentées d'une même image. $\mathcal{L}_{loc}$: Contraint la carte explicative à rester cohérente avec une zone plausible.	Calibration : Une probabilité 0.8 devrait correspondre à environ 80% de prédictions correctes. Temperature scaling : Correction post-hoc des logits par un scalaire de température. ECE : Mesure l'écart entre confiance moyenne et précision réelle.
$ECE = \sum_{m=1}^M \frac{ B_m }{n} \text{acc}(B_m) - \text{conf}(B_m) $	

$$\mathcal{L}_{BCE} = -(y \log p + (1 - y) \log(1 - p))$$

Annexe H — Fusion, explicabilité et incertitude

Rôle : Documenter les sorties avancées de la solution proposée

Étape du projet : Annexe technique

Fusion et gating	Explicabilité et confiance
Le gating apprend le poids relatif des branches locale et globale. $g = \sigma(W_g[\text{GAP}(F_c), \text{GAP}(F_s)])$ $F = g \odot F_c + (1 - g) \odot F_s$ Si g est grand, la branche CNN domine ; sinon la branche Swin domine.	Grad-CAM : Carte visuelle des zones qui contribuent positivement au score choisi. MC-Dropout : Plusieurs passes avec dropout actif à l'inférence pour estimer l'incertitude. Variance prédictive : Plus elle est grande, moins la décision est fiable. $u = \text{Var}_t(p_t)$

Annexe I — Métriques d'évaluation

Rôle : Définir précisément les mesures de performance et leur lecture clinique

Étape du projet : Annexe technique

Definitions	Formules
Accuracy : Proportion totale de prédictions correctes. Recall / Sensibilité : Capacité à retrouver les cas positifs. Spécificité : Capacité à rejeter les cas négatifs. AUC-ROC : Qualité de séparation entre classes quand on fait varier le seuil. Faux positif : Cas sain déclaré malade. Faux négatif : Cas malade déclaré sain.	$\text{Recall} = \frac{TP}{TP+FN}, \quad \text{Specificite} = \frac{TN}{TN+FP}$ $\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$
	Lecture en contexte médical En dépistage de pneumonie, réduire les faux négatifs est souvent prioritaire : manquer un cas pathologique est généralement plus grave que sur-appeler un cas douteux.